Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика и системы управления»

КАФЕДРА ИУ7 «Программное обеспечение ЭВМ и информационные технологии»

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА

К НАУЧНО-ИССЛЕДОВАТЕЛЬСКОЙ РАБОТЕ

НА ТЕМУ:

«Методы конвертации 2D изображения в 3D»

Студент **ИУ7-71Б** _____ **А. И. Вылегжанина**
(Подпись, дата) (И.О.Фамилия)

Руководитель _____ **Д. В. Строганов**
(Подпись, дата) (И.О.Фамилия)

Рекомендованная руководителем НИР оценка: _____

2024 г.

РЕФЕРАТ

Расчетно-пояснительная записка 65 с., 14 рис., 3 табл., 0 источн., 1 прил.

Ключевые слова: 3Д–реконструкция, построение карты глубин, методы структурного освещения, определения глубины из размытия (Depth from defocus), стереосопоставления, структуры из движения (Structure from motion), комфортной генерации глубины (Comfortable Depth Generation).

Цель работы: классификация методов конвертации 2Д изображений в 3Д.

Данная научно–исследовательская работа включает анализ предметной области, описание основных подходов к решению задачи конвертации 2Д изображений в 3Д, определение критериев сравнения, и классификацию методов.

СОДЕРЖАНИЕ

РЕФЕРАТ **2**

ВВЕДЕНИЕ **5**

1 Аналитический раздел **8**

1.1 Метод структурного освещения 8

1.2 Метод определения глубины из размытия 12

1.3 Метод стереосопоставления 13

1.4 Метод комфортной генерации глубины 15

1.5 Метод восстановления глубины на основе нейронных сетей . . . 17

1.6 Метод восстановления глубины по закраске изображения 18

1.7 Классификация методов конвертации 2Д в 3Д 20

1.8 Обоснование выбора метода для восстановления глубины архивных фотографий 23

1.9 Цель и постановка задачи 25

2 Конструкторский раздел **28**

2.1 IDEF0-диаграммы 28

2.2 Блок–схемы алгоритмов 30

2.3 Вывод 37

3 Технологический раздел **39**

3.1 Выбор программных средств 39

3.2 Описание входных и выходных данных 40

3.3 Реализация метода 40

3.4 Метрики оценки качества реконструкции глубины 52

3.5 Тестирование 53

3.5.1 Описание тестового набора 53

3.5.2 Результаты тестирования 55

3.6 Вывод 56

4 Исследовательский раздел **58**

4.1 Введение и цель исследования 58

4.2 Методология сравнения 58

4.3 Наборы данных и эталонные изображения 59
4.3.1 NYU Depth Dataset V2 59
4.3.2 KITTI Depth Dataset 59
4.3.3 Пользовательский набор данных 59
4.4 Критерии оценки 60
4.5 Экспериментальные результаты 60
4.5.1 Сравнение методов на стандартных наборах данных . . . 60
4.5.2 Влияние эффектов старения на точность восстановления 61
4.5.3 Визуальное сравнение результатов 61
4.6 Анализ вычислительной эффективности 61
4.7 Особенности применения методов для различных типов сцен . . 61
4.8 Выводы по результатам исследования 62

ЗАКЛЮЧЕНИЕ **63**

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ **64**

ПРИЛОЖЕНИЕ А **65**

ВВЕДЕНИЕ

Актуальность Восстановление трехмерной информации из архивных фотографий представляет особую научно-практическую ценность по нескольким направлениям:

Сохранение культурного наследия: Архивные фотографии содержат визуальные свидетельства исторических объектов, многие из которых уже не существуют. Преобразование этих изображений в трехмерный формат позволяет более полно документировать и сохранять культурное наследие.

Историческая реконструкция: Как отмечено Могаричевым и Ергиной (2020), трехмерная реконструкция исторических объектов позволяет создавать виртуальные модели утраченных памятников архитектуры и культурных ценностей.

Междисциплинарные исследования: По данным Корюгина (2007), использование 3D-реконструкций исторических городских сред способствует более глубокому анализу градостроительного развития и архитектурных изменений.

Музейное дело и образование: Трехмерные реконструкции на основе архивных фотографий, согласно исследованию Kargas и др. (2019), значительно улучшают восприятие и понимание исторических объектов в образовательных и музейных контекстах.

Новизна Новизна предлагаемого исследования заключается в следующих аспектах:

Адаптация современных алгоритмов: Впервые предлагается специализированная модификация современных алгоритмов оценки глубины для работы именно с архивными фотографиями, учитывающая их специфические особенности (выцветание, неоднородное освещение, шумы и дефекты).

Комбинирование методов: В отличие от существующих подходов, описанных Zhang и др. (2025), предлагаемое решение объединяет как нейросетевые, так и классические методы, позволяя преодолеть ограничения каждого из них при работе с историческими материалами.

Учет специфики исторических фотоматериалов: Разрабатываемый метод принимает во внимание особенности фотографических технологий прошлого, что в соответствии с исследованием Stanowski (2024) является критически важным фактором для корректной интерпретации светотеневой информации.

Применение данных без обучающей выборки: В отличие от большинства современных решений, описанных Харитоновым (2021), предлагаемый подход не требует наличия обучающих данных с известной глубиной для исторических изображений, что делает его практически применимым в реальных сценариях работы с архивами.

Интеграция в существующие системы архивации: Предложенный метод может быть интегрирован в существующие системы цифровой архивации, расширяя их функциональность без необходимости полного пересмотра уже созданных цифровых архивов.

Таким образом, предлагаемая работа заполняет существенный пробел в области цифровой обработки исторических материалов, предлагая практический инструментарий для трансформации двумерных архивных фотографий в трехмерные реконструкции.

3Д–реконструкция стала одним из приоритетных направлений развития компьютерных технологий, так как точное воссоздание изучаемого объекта открыло перед нами широкие возможности в разнообразных сферах деятельности.

При конвертации 2Д в 3Д первостепенной задачей является создание карты глубин (depth map) — расстояние от каждой точки сцены до камеры (каждой точке в соответствие ставится координата z — глубина) [**stereosop2**].

Технология трехмерной реконструкции подразумевает получения трехмерной модели сцены посредством проекции объектов и сцен реального мира на двумерную плоскость и их обработки [**stereosop2**]. То есть, помимо формирования карты глубин на сцене должны быть выделены отдельные объекты, их размер, расположение и иные характеристики.

Последующее развитие такие модели могут получить в форме объёмных 3Д-данных (Volumetric Models) [**volumModel**], которые представляют данные внутри объёма, а не только поверхность (например, структура туманностей или медицинские данные КТ [**kt**]). Или же такие модели могут быть преобразованы в иммерсивные панорамные изображения — сцены, созданные на основе 3Д-моделей, с которыми организовано интерактивное взаимодействие, обеспечивающее эффект полного погружения [**immersive**]. Кроме того 3Д модели используются в таких сферах, как:

— медицина [**kt**; **med2**; **med3**],

— культура и история [**kult1**; **kult2**],

— промышленное производство [**prom1**; **prom2**; **prom3**],

— индустрия развлечений [**play1**; **play2**; **play3**],

— системы компьютерного зрения [**vis1**; **vis2**; **vis3**].

Целью данной научно–исследовательской работы является классификация методов конвертации 2Д изображений в 3Д.

Для достижения поставленной цели требуется выполнить следующие задачи:

— провести анализ предметной области «обработка изображений»;

— описать основные подходы к решению задачи конвертации 2Д изображений в 3Д;

— сформулировать критерии сравнения методов;

— выполнить классификацию методов.

1 Аналитический раздел

В области восстановления трехмерной формы объектов существует несколько подходов, каждый из которых обладает своими уникальными характеристиками и сферами применения. Выбор метода зависит от конкретных задач, типа сцены, доступных данных и требуемого уровня точности результата.

В рамках данной работы будут рассмотрены методы:

— структурного освещения,

— определения глубины из размытия (Depth from defocus) [**dfd**],

— стереосопоставления,

— комфортной генерации глубины (Comfortable Depth Generation);

— на основе нейронных сетей;

— восстановления глубины по закраске изображения (Structure From Shadowing) [**zaharov2011**; **zaharov2014**].

Целью данного раздела является систематический обзор и сравнительный анализ существующих решений в области трехмерной реконструкции. На основе проведенного исследования будет сформулирована цель работы и формализована постановка задачи в виде функциональной модели, учитывающей специфику работы с архивными фотографиями.

1.1 Метод структурного освещения

Метод структурированного освещения использует различные типы световых паттернов, которые проецируются на поверхность объекта. Данные паттерны могут быть линейными, шахматными, градиентными и другими. Пример паттерна представлен на изображении 1.1.

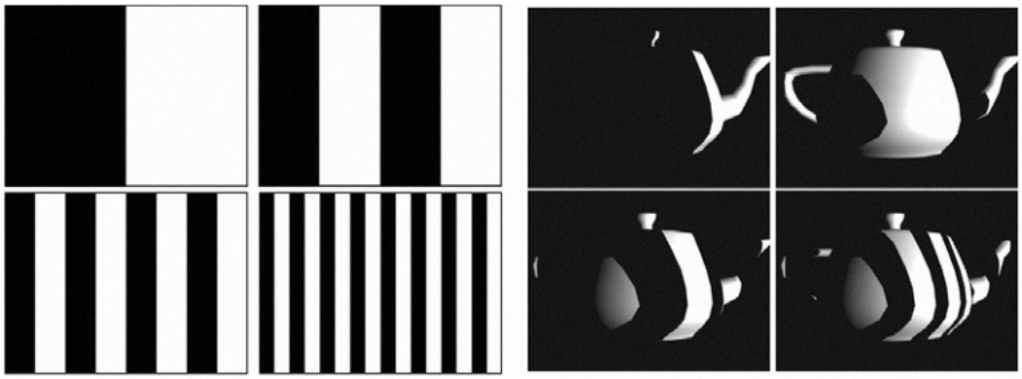


Рисунок 1.1 – Пример бинарных световых паттернов и освещенного с их помощью объекта [**structLight**].

Анализ искажений световых паттернов на поверхности объекта позволяет восстанавливать 3Д-геометрию объекта. Основная задача метода заключается в выполнении триангуляции для определения расстояния от камеры до каждой точки поверхности.

На рисунке 1.2 приведена схема установки.

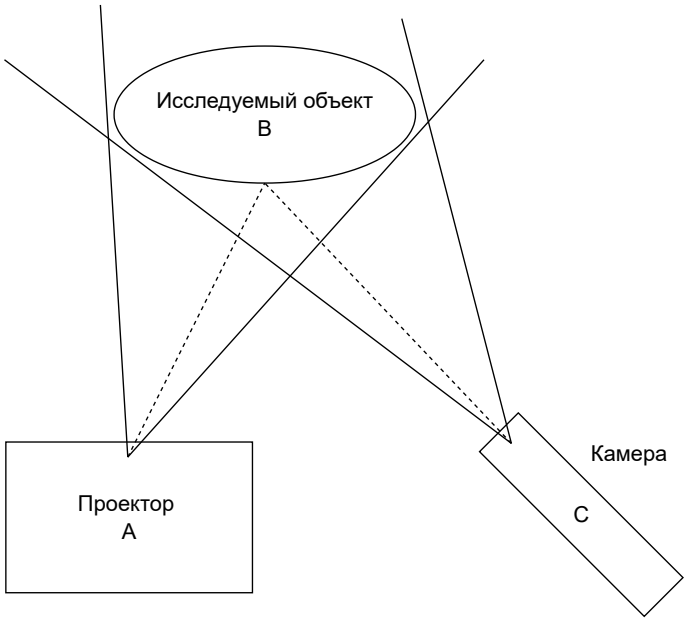


Рисунок 1.2 – Схема установки структурного освещения [**structLight**].

Создание карты глубин методом структурного освещения выполняется в несколько этапов [**structLight**].

1. **Калибровка камеры и проектора.** Определяются коэффициенты масштабирования (α_u, α_v), координаты оптического центра (x_0, y_0) и фокусное расстояние f.

2. **Проекция паттерна.** Проектор создает определенный световой шаблон (паттерн), который проецируется на исследуемую поверхность.

3. **Фиксация изображения.** Камера фиксирует и регистрирует искажения паттерна на поверхности объекта.

4. **Триангуляция.**

   4.1. **Вычисление углов.**

   Для вычисления расстояния от камеры до точки поверхности необходимо определить два угла треугольника $\triangle ACB$:

   — $\angle CAB$ — угол между направлением от камеры C к проектору A и направлением от камеры C к точке на поверхности B. Он вычисляется по формуле:

$$\angle CAB = \arctan\left(\frac{x' - x_0}{f}\right),$$

   где x' — горизонтальная координата пикселя на изображении, x_0 — координата оптического центра камеры, а f — фокусное расстояние.

   — $\angle BCA$ — угол между направлением от точки B на поверхности к камере C и направлением от точки B к проектору A. Он вычисляется по формуле:

$$\angle BCA = \arctan\left(\frac{y' - y_0}{f}\right),$$

   где y' — вертикальная координата пикселя на изображении, y_0 — координата оптического центра камеры, а f — фокусное расстояние.

   4.2. **Вычисление глубины** (BC) **для каждой точки поверхности.**

   Используется триангуляция для определения расстояния BC от камеры до точки поверхности объекта:

$$BC = \frac{AC \cdot \sin(\angle CAB)}{\sin(\angle BCA)}, \tag{1.1}$$

где:

— AC — известное расстояние между камерой и проектором;

— $\angle CAB$ и $\angle BCA$ — углы треугольника $\triangle ACB$, вычисляемые на предыдущем шаге.

4.3. **Преобразование координат изображения из 2Д- в 3Д-пространство.**

Трёхмерные координаты точки поверхности (x, y, z) в системе камеры вычисляются по следующим формулам:

$$x = (x' - x_0) \cdot \frac{z}{\alpha_u}, \quad y = (y' - y_0) \cdot \frac{z}{\alpha_v}, \quad z = BC, \tag{1.2}$$

где:

— x', y' — пиксельные координаты точки на изображении;

— α_u, α_v — коэффициенты масштабирования камеры по горизонтали и вертикали;

— x_0, y_0 — координаты оптического центра камеры.

Метод структурного освещения позволяет создавать точные и детализированные карты глубины, что делает его незаменимым для задач, где требуется высокая точность в определении расстояний до объектов. Однако, несмотря на свою точность, этот метод имеет несколько ограничений. Одним из основных минусов является необходимость использования специализированной лабораторной установки, включающей камеру и проектор с точной калибровкой. Такая установка требует стабильных условий и может быть чувствительна к внешним факторам, таким как освещенность или движения объекта.

Кроме того, метод ограничен размером и геометрией исследуемого объекта. Структурированное освещение наиболее эффективно работает на объектах с относительно простой и ровной поверхностью. Для сложных, сильно текстурированных или отражающих объектов, качество получаемых данных может значительно ухудшаться из-за искажений паттернов, что требует дополнительных техник для их компенсации. Также метод может быть неэффективен в условиях с ограниченным пространством, где сложно разместить проектор и камеру под нужным углом.

1.2 Метод определения глубины из размытия

Метод оценки расстояний с использованием дефокусировки (Depth from Defocus, DFD) основан на анализе размытия изображения в точках, соответствующих границам объектов. Предполагается, что перепад яркости на нерасфокусированном изображении границ объектов можно моделировать как ступенчатую функцию — функцию Хевисайда [**hewiside**].

Процесс оценки размытия выполняется в несколько этапов [**dfd**].

1. **Выделение границ объектов.** На изображении выделяются границы объектов, где наблюдаются значительные перепады яркости. Эти границы служат ориентиром для дальнейшего анализа.

2. **Моделирование градиента яркости.** Оценивается градиент яркости на выделенных границах объектов. Этот шаг позволяет точно выявить изменения яркости, которые обусловлены дефокусировкой.

3. **Повторное размытие изображения.** На изображение наносится дополнительное размытие, после чего вычисляется новый градиент яркости на границах объектов. Это помогает уточнить степень дефокусировки, которая напрямую зависит от расстояния до объекта.

4. **Расчет параметра дефокусировки.** На основе измерений градиента яркости и моделирования размытия вычисляется параметр дефокусировки, который используется для определения расстояния до объекта.

Метод DFD является полезным для случаев, когда есть возможность получить несколько снимков объекта с разными уровнями фокусировки. Однако результативность данного метода зависит от качества и точности модели размытия, а также от разрешения камеры. В случае значительных искажений, например, при сильной дефокусировке или недостаточной контрастности на границах, результаты могут быть менее точными. Кроме того, для получения корректных результатов требуется тщательная настройка параметров камеры, таких как диафрагма и фокусное расстояние.

1.3 Метод стереосопоставления

Методы стереосопоставления основываются на физическом принципе параллакса, схожем с принципом восприятия глубины человеком через бинокулярное зрение [**stereosop1**].

Основой метода стереосопоставления является **стереопара** — два изображения, снятых с различных позиций. Предполагается, что эти изображения выровнены по горизонтали, а оптические оси камер распалагаются параллельно. Схема расположения камер представлена на рисунке 1.3.

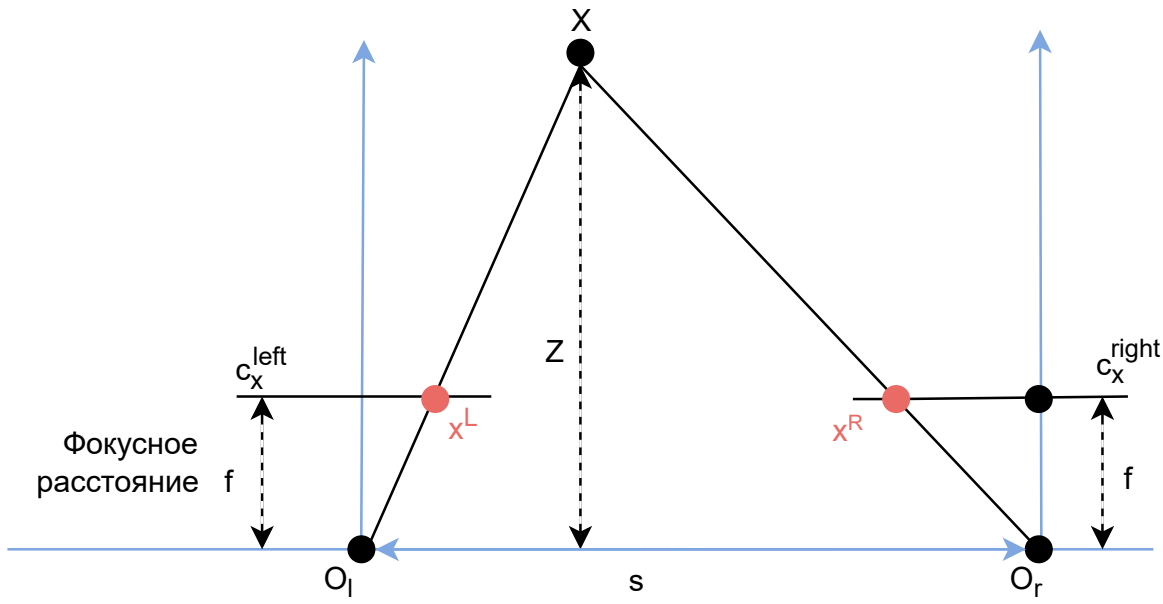


Рисунок 1.3 – Схема расположения камер [**stereosop2**].

Следующим ключевым элементом метода является **параллакс** (d) — отклонение положения пикселей одной и той же сцены на изображениях, полученных двумя камерами, вычисляется по формуле:

$$d = x^L - x^R, \tag{1.3}$$

где x^L и x^R — координаты точек на левом и правом изображениях соответственно.

На основе значения параллакса вычисляется глубина объекта. Для этого используются тригонометрические зависимости, учитывающие расстояние между камерами (s) и фокусное расстояние (f). Формула для расчёта глубины

имеет следующий вид:

$$Z = \frac{f \cdot s}{d}, \tag{1.4}$$

где Z — расстояние до объекта (глубина), f — фокусное расстояние камеры, s — расстояние между камерами, d — параллакс.

Создания карты глубин методом стереосопоставления происходит в несколько этапов.

1. **Калибровка камер.** Устранение оптических искажений (например, дисторсии) выраннивание камер по горизонтали. Определение параметров камер, включая оптические центры $O_L(x_0^L, y_0^L), O_R(x_0^R, y_0^R)$ и коэффициенты масштабирования (α_u, α_v).

2. **Сбор исходных данных.** Создание стереопары с использованием двух откалиброванных камер с одинаковыми параметрами.

3. **Выравнивание изображений.** Приведение изображений к общему масштабу и ориентации, с целью упрощения поиска соответствующих пикселей на обоих изображениях.

4. **Построение карты параллакса.** Вычисления параллакса согласно формуле 1.3 для каждой точки сцены и фиксация результата в виде карты параллакса.

5. **Вычисление пространственных координат.** Вычисление глубины Z по формуле 1.4 и преобразование пиксельных координат (x', y') в трёхмерные (X, Y, Z) с учётом параметров камеры по формуле 1.2.

Основная проблема методов стереосопоставления заключается в том, что не каждой точке на левом изображении удаётся сопоставить соответствующую точку на правом [**stereosop2**]. Это приводит к разрывам на карте глубины, требует многоэтапной обработки и повышает алгоритмическую сложность. Кроме того, методы могут давать неточные результаты при работе со слабо контрастными поверхностями или перекрывающимися объектами, особенно в условиях низкого разрешения [**stereosop1**]. С другой стороны, они не требуют

дорогостоящего оборудования или лабораторных условий и могут использоваться в реальных, неидеальных ситуациях, таких как съемка с мобильных устройств или с использованием непрофессиональных камер.

1.4 Метод комфортной генерации глубины

Метод комфортной генерации глубины представляет собой подход, который использует информацию о цветовых характеристиках блоков изображения для построения 3Д-глубины.

Процесс заключается в разбиении изображения на блоки, анализе их цветовых характеристик и применении минимальных остовных деревьев для вычисления глубины.

Выделяют несколько основных этапов метода комфортной генерации глубины [**comf**].

1. **Разбиение изображения на блоки.** Изображение делится на блоки размером 4x4 пикселя, что позволяет упростить задачу обработки изображения и снизить вычислительную сложность.

2. **Вычисление среднего цвета для каждого блока.** Для каждого блока вычисляется среднее значение цвета (mean(a)), что представляет собой характеристику блока, на основе которой будет строиться граф для дальнейшей обработки.

3. **Построение графа.** Изображение представляется как неориентированный граф $G(V, E)$, где:

   — V — вершины графа, которые соответствуют блокам изображения;

   — E — ребра графа с весами, которые рассчитываются как абсолютное различие средних значений цвета между соседними блоками, то есть $|\text{mean(a)} - \text{mean(b)}|$.

4. **Построение минимального остовного дерева.** На основе построенного графа применяется алгоритм Прима для нахождения минимального остовного дерева. Этот шаг помогает упорядочить блоки по их взаимному сходству и устанавливает структуру для дальнейшего анализа.

5. **Разрезание дерева.** После построения минимального остовного дерева выполняется его разрезание по ребрам с большими весами, что помогает выделить сегменты изображения, которые могут быть интерпретированы как части с различной глубиной.

6. **Выбор базового градиента глубины.** Из анализа прямых линий на изображении выбирается один из базовых градиентов глубины. Для этого используются параметры Wrl и Wud, которые характеризуют градиент в двух направлениях (горизонтальном и вертикальном). При этом выполняется условие $|Wrl| + |Wud| = 1$.

7. **Вычисление глубины сегмента.** Для каждого сегмента изображения глубина вычисляется как среднее значение глубины всех пикселей в сегменте.

   На рисунке 1.4 приведен пример обработки одного блока изображения.

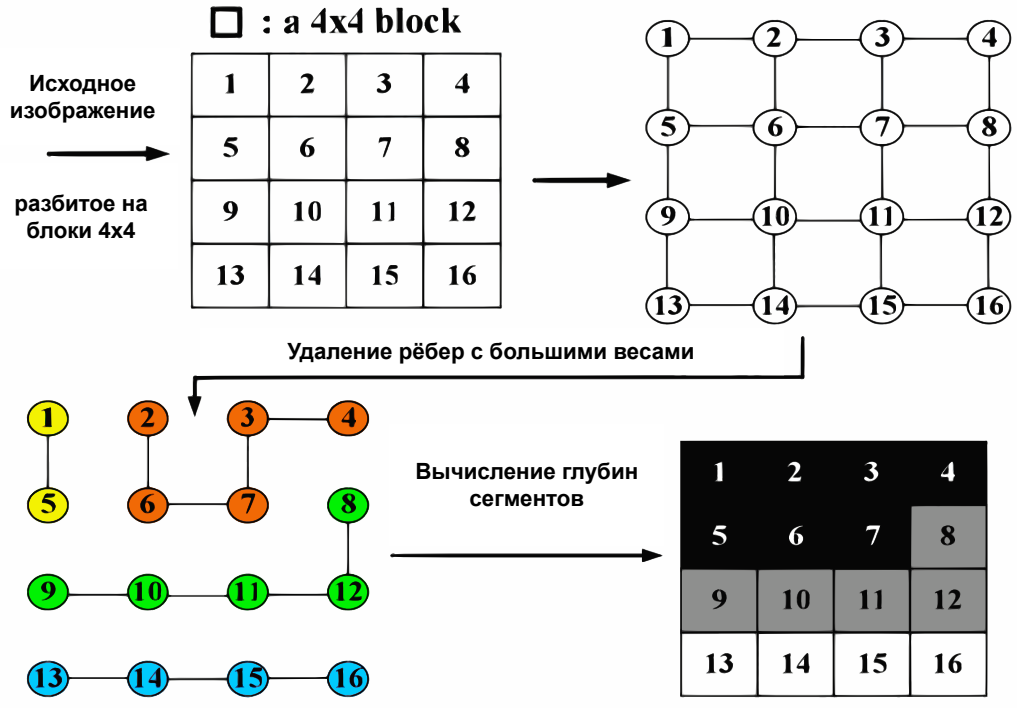


Рисунок 1.4 – Обработка блока изображения [**comf**].

Метод комфортной генерации глубины предполагает разбиение изображения на независимые части, что позволяет обрабатывать данные параллельно. Одним из ключевых преимуществ метода является использование

единственного исходного изображения, позволяя применять его в условиях ограниченного доступа к дополнительным источникам данных и значительно ускоряя процесс обработки по сравнению с методами, требующими несколько кадров.

Однако, метод Comfortable Depth Generation имеет некоторые ограничения, связанные с качеством исходных изображений. Низкое качество или низкая контрастность изображения усложняет вычисления и снижает точность получаемой глубины. Кроме того, фиксированный размер блоков (4x4 пикселя) ограничивает точность при обработке изображений с детализированными структурами, требующими разделение на более мелкие части. В случае с изображениями, содержащими гладкие или однотонные текстуры, блоки имеют схожие цветовые характеристики, что затрудняет выделение различных глубинных уровней.

1.5 Метод восстановления глубины на основе нейронных сетей

Метод восстановления глубины на основе нейронных сетей представляет собой современное направление в области монокулярной оценки глубины. Эти методы используют глубокое обучение для выявления сложных статистических закономерностей между визуальными признаками 2D-изображения и соответствующими значениями глубины.

Одним из представителей данного класса методов является MiDaS (Mixed Datasets), который решает фундаментальную проблему несогласованности масштабов в различных наборах данных через специальную функцию потерь, инвариантную к масштабированию и сдвигу. MiDaS обучен на комбинированных наборах данных, что обеспечивает его универсальность для разных типов сцен.

Процесс восстановления глубины с помощью нейронных сетей включает следующие этапы.

1. **Предобработка изображения.** Входное изображение нормализуется и масштабируется до размера, оптимального для подачи на вход нейронной сети.

2. **Извлечение многоуровневых признаков.** Энкодер сети (основанный

на архитектурах типа ResNet или EfficientNet) извлекает иерархию визуальных признаков различных уровней абстракции.

3. **Декодирование карты глубины.** Декодер преобразует извлеченные признаки в карту глубины через серию свёрточных слоев и операций повышения дискретизации.

4. **Постобработка результатов.** Полученная карта глубины подвергается финальной обработке для устранения артефактов и повышения согласованности.

Нейросетевые методы обладают рядом преимуществ при работе с архивными фотографиями:

— высокая устойчивость к шумам и артефактам вследствие обучению на разнообразных данных;

— способность восстановления целостной структуры сцены даже при наличии локальных повреждений;

— адаптивность к различным условиям освещения и типам сцен;

— отсутствие необходимости в знании точных параметров камеры.

Однако, как и метод Comfortable Depth Generation, нейросетевые подходы ориентированы на восстановление общей структуры глубины и могут упускать тонкие детали поверхностей. Это ограничение особенно заметно при работе с архивными фотографиями, где текстуры и мелкие детали имеют историческую ценность.

1.6 Метод восстановления глубины по закраске изображения

Метод Shape from Shading (SFS) — это подход к восстановлению трехмерной формы объекта на основе анализа распределения интенсивности света и теней на двумерном изображении. Этот метод базируется на физических принципах отражения света от поверхностей объектов.

Восстановление формы по закраске производится в несколько этапов [**stanowski2024stability**].

1. **Определение модели освещения.** Для анализа используется модель отражения, описывающая взаимосвязь между интенсивностью пикселя, нормалью к поверхности и направлением падающего света. Чаще всего применяется ламбертовская модель освещения:

$$I(x, y) = \rho(x, y) \cdot L \cdot N(x, y), \tag{1.5}$$

где $I(x, y)$ — интенсивность пикселя, $\rho(x, y)$ — альбедо поверхности, L — направление источника света, $N(x, y)$ — нормаль к поверхности.

2. **Разделение альбедо и затенения.** Анализируется изменение яркости изображения для отделения свойств материала (альбедо) от эффектов затенения, вызванных геометрией поверхности. Альбедо характеризует собственный цвет и отражательную способность материала.

3. **Вычисление нормалей поверхности.** На основе интенсивности пикселей и модели освещения вычисляются нормали к поверхности в каждой точке. Для каждого пикселя определяется вектор нормали $N(x, y)$, перпендикулярный к касательной плоскости поверхности.

4. **Интеграция нормалей.** Для получения карты глубины выполняется интеграция поля нормалей. Этот процесс можно представить как решение следующего уравнения:

$$\nabla Z(x, y) = f(N(x, y)), \tag{1.6}$$

где $Z(x, y)$ — искомая карта глубины, а f — функция, преобразующая нормали в градиент глубины.

5. **Применение регуляризации.** Для преодоления неоднозначности решения и устранения шумов используются методы регуляризации, которые вводят дополнительные ограничения на гладкость поверхности.

Метод SFS обладает рядом преимуществ, ключевым из которых является возможность восстановления 3D-формы объекта по одиночному изображению. Это делает его применимым для работы с историческими фотографиями и ситуациями, когда невозможно получить несколько ракурсов объекта [**xie2025photometric**].

Однако метод имеет существенные ограничения. Во-первых, он требует точного знания параметров освещения, которые часто недоступны для архивных фотографий. Во-вторых, базовая модель предполагает однородность материала поверхности, что редко встречается в реальных сценах. В-третьих, метод может давать неоднозначные результаты, поскольку различные 3D-формы могут создавать схожие паттерны затенения [**zhang2025review**].

1.7 Классификация методов конвертации 2Д в 3Д

На основе проведенного анализа предметной области были определены несколько ключевых критериев сопоставления рассмотренных методов.

1. **Способ получения данных** — активный или пассивный подход к сбору информации.

   Предложенный критерий учитывает подход к сбору исходных данных. Активные методы, такие как лазерное сканирование, требуют использования специализированного оборудования, что предполагает проведение исследований в лабораторных условиях. Пассивные методы, напротив, работают с доступными изображениями. Применение данного критерия позволяет своевременно оценить необходимые условия получения исходных изображений.

2. **Тип исходных изображений** — моноизображения, стереопары или видео/последовательность изображений.

   Определение типа исходных данных предполагает проверку доступности информации при решении конкретной задачи.

3. **Дополнительная информация** — данные о положении камер, временных метках и других параметрах.

   Необходимость в дополнительной информации ограничивает область применения метода и может предполагать наличие дополнительных компетенций для их применения, например, при настройке параметров камеры.

4. **Результат** — итоговый объект реконструкции (3Д-модель, карта глубины, точечные облака и т.д.).

Результы конвертации различны: от простой карты глубины до сложных 3Д-моделей. Выбор метода напрямую сопряжен с конечными требованиями проекта.

5. **Масштаб сцены** — локальная или глобальная реконструкция.

   Масштаб сцены определяет применимость метода к задачам разного уровня: от реконструкции небольших объектов до глобальных ландшафтов.

6. **Уровень автоматизации** — степень автоматизированности процесса реконструкции: от ручных до автоматических методов.

   Уровень автоматизации влияет на затраты времени и ресурсов. Автоматизированные методы предпочтительны для задач, требующих быстрой обработки больших объемов данных, тогда как ручные обеспечивают больше контроля в специфических сценариях.

Данные критерии позволяют выбрать наиболее подходящий метод 3Д–реконструкции в зависимости от поставленной задачи, доступных возможностей и особенностей предметной области.

В таблице 1.1 приведена классификация методов 3Д–реконструкции.

Критерий	**Метод структурированного освещения**	**DFD**	**Стерео сопоставление**	**Shape from Shading (SFS)**	**Comfortable depth generation**	**MiDaS**
Способ получения данных	Активный	Активный / Пассивный	Пассивный	Пассивный	Пассивный	Пассивный
Тип исходных изображений	Моно–изображение	Моно–изображение	Стереопара	Моно–изображение	Моно–изображение	Моно–изображение
Дополнительная информация	Проекция шаблона	Параметры настройки камеры	Взаиморасположение камер	Параметры освещения	-	-
Тип реконструкции	Реконструкция формы и текстур	Реконструкция формы	Реконструкция формы	Реконструкция формы	Генерация глубины	Генерация глубины
Результат	3Д–модель	Карта глубин	Точечные облака	Карта глубин, нормали поверхности	Карта глубин	Карта глубин
Масштаб сцены	Локальные	Локальные	Глобальные	Локальные	Локальные / Глобальные	Локальные / Глобальные
Уровень автоматизации	Ручные	Автономные	Полу-автономные	Полу-автономные	Автономные	Автономные

Таблица 1.1 – Классификация методов конвертации 2Д в 3Д

1.8 Обоснование выбора метода для восстановления глубины архивных фотографий

При выборе метода для восстановления глубины из старинных фотографий необходимо учитывать их специфические особенности и ограничения.

1. **Ограниченность исходных данных**. Для архивных фотографий доступны только одиночные изображения, отсутствует возможность получения стереопар или последовательностей с разных ракурсов.

2. **Отсутствие метаданных**. Архивные фотографии не содержат информации о параметрах съемки, калибровке камеры или условиях освещения.

3. **Качество изображений**. Старинные фотографии часто имеют низкое качество, шумы, артефакты, выцветание и повреждения, что затрудняет автоматическую обработку.

Исходя из представленной классификации, рассмотрим применимость каждого метода:

Метод структурированного освещения и **DFD** требуют активного вмешательства при съемке или специальных параметров камеры, что делает их неприменимыми для архивных фотографий.

Стерео сопоставление неприменимо из-за отсутствия стереопар для архивных фотографий.

Shape from Shading работает с моноизображениями и может восстанавливать форму объектов на основе анализа теней и освещения. Однако его существенный недостаток — необходимость в параметрах освещения, которые невозможно достоверно определить для архивных фотографий. Тем не менее, возможна разработка адаптированного алгоритма, который будет оценивать параметры освещения на основе самого изображения и исторических данных о типичных условиях съемки того периода.

Comfortable depth generation представляется подходящим методом, поскольку он работает с моноизображениями и не требует дополнительной информации. Однако для архивных фотографий с их специфическими искажениями нейросетевые подходы демонстрируют более высокую устойчивость и точность.

Нейросетевые методы, в частности MiDaS, представляются наиболее подходящим решением, поскольку они:

— работают с одиночными изображениями,

— не требуют дополнительной информации о сцене или камере,

— обеспечивают полностью автоматическую обработку,

— демонстрируют высокую точность на разнообразных сценах благодаря обучению на больших наборах данных,

— способны извлекать сложные статистические закономерности между визуальными признаками и глубиной.

Однако для повышения качества результатов разумно использовать гибридный подход: комбинировать **нейросетевой метод** (MiDaS) для получения базовой карты глубины с элементами **Shape from Shading** для улучшения детализации в областях с выраженной текстурой и тенями.

При этом необходимо учитывать особенности архивных фотографий:

— внедрить предварительную обработку для устранения артефактов и повреждений,

— адаптировать алгоритмы для работы с низкоконтрастными изображениями,

— разработать механизмы, компенсирующие эффекты выцветания и старения фотоматериалов.

Таким образом, оптимальным решением для восстановления глубины из старинных фотографий будет специализированный гибридный метод на основе **Comfortable depth generation** с элементами **Shape from Shading**, адаптированный для работы с проблемными аспектами архивных изображений.

1.9 Цель и постановка задачи

Целью данной работы является разработка метода восстановления трехмерной глубины из архивных фотографий путем создания гибридного алгоритма, объединяющего преимущества методов Comfortable Depth Generation и Shape from Shading, с учетом специфических особенностей исторических изображений.

Формально задачу восстановления карты глубины из архивной фотографии можно представить как функциональную модель:

$$D = F(I, P), \tag{1.7}$$

где:

— $D : \mathbb{R}^2 \to \mathbb{R}$ — искомая карта глубины, сопоставляющая каждой точке (x, y) изображения значение глубины;

— $I : \mathbb{R}^2 \to \mathbb{R}^3$ — исходное изображение, представленное как функция, сопоставляющая каждой точке (x, y) цвет в формате RGB;

— P — набор параметров алгоритма;

— F — оператор преобразования, реализующий гибридный метод.

Оператор F представляет собой композицию следующих функций:

$$F = F_{\text{post}} \circ F_{\text{hybrid}} \circ F_{\text{pre}}, \tag{1.8}$$

где:

— $F_{\text{pre}} : \mathbb{R}^2 \times \mathbb{R}^3 \to \mathbb{R}^2 \times \mathbb{R}^3$ — функция предобработки, выполняющая шумоподавление, коррекцию яркости и контраста;

— $F_{\text{hybrid}} : \mathbb{R}^2 \times \mathbb{R}^3 \to \mathbb{R}^2 \times \mathbb{R}$ — гибридная функция, объединяющая алгоритмы CDG и SFS;

— $F_{\text{post}} : \mathbb{R}^2 \times \mathbb{R} \to \mathbb{R}^2 \times \mathbb{R}$ — функция постобработки, выполняющая сглаживание и нормализацию карты глубины.

Гибридная функция F_{hybrid} определяется как:

$$F_{\text{hybrid}}(I) = \alpha \cdot F_{\text{CDG}}(I) + (1 - \alpha) \cdot F_{\text{SFS}}(I, \hat{L}), \tag{1.9}$$

где:

— F_{CDG} — функция, реализующая метод Comfortable Depth Generation;

— F_{SFS} — функция, реализующая метод Shape from Shading;

— $\hat{L}$ — оценка параметров освещения;

— $\alpha \in [0, 1]$ — весовой коэффициент, определяющий вклад каждого из методов.

Вывод

В аналитической части работы был проведен анализ существующих методов конвертации двумерных изображений в трехмерные представления. Методы были классифицированы по шести ключевым критериям: способу получения данных, типу исходных изображений, необходимости в дополнительной информации, результатам реконструкции, масштабу сцены и уровню автоматизации.

В ходе исследования были изучены различные подходы к восстановлению 3D-информации, включая методы структурированного освещения, стерео сопоставления, DFD, Shape from Shading, Comfortable Depth Generation и нейросетевые методы, такие как MiDaS.

Проведенный анализ привел к выводу, что оптимальным решением для восстановления глубины из архивных фотографий является гибридный метод, объединяющий преимущества нейросетевого подхода (MiDaS) и классического метода Shape from Shading. Такое решение позволит обеспечить как общую точность восстановления геометрии сцены, так и детализацию отдельных элементов, сохраняя при этом устойчивость к дефектам, характерным для исторических изображений.

Представленная формальная модель задачи и декомпозиция метода на функциональные блоки предобработки, гибридного восстановления и постобработки формируют теоретическую основу для разработки практического решения в следующих разделах работы.

2 Конструкторский раздел

В данном разделе формалзована структура разработанного метода, описана алгоритмическая основа функциональных блоков и их взаимодействия в рамках единой системы.

Структура решения представлена в виде IDEF0-диаграммы и подробных блок-схем для каждого этапа обработки: предварительной подготовки изображений, сегментации, оценки освещения, разделения альбедо и затенения, расчета нормалей к поверхности и итогового восстановления трехмерной информации.

2.1 IDEF0-диаграммы

На рисунке 2.1 представлена контекстная IDEF0-диаграмма (A0) разработанного метода, отражающая общую структуру системы восстановления трехмерной информации из архивных фотографий.

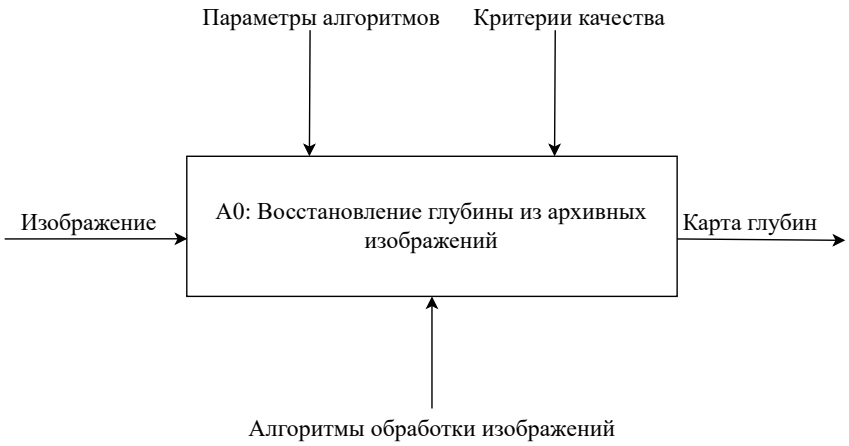


Рисунок 2.1 – IDEF0-диаграмма уровня A0

Диаграмма нулевого уровня представляет всю систему как единый блок с указанием входов, выходов, управления и механизмов. Входными данными системы являются архивные фотографии, выходными — восстановленная карта глубины.

На рисунке 2.2 показана декомпозиция функционального блока A0, детализирующая основные процессы обработки изображений.

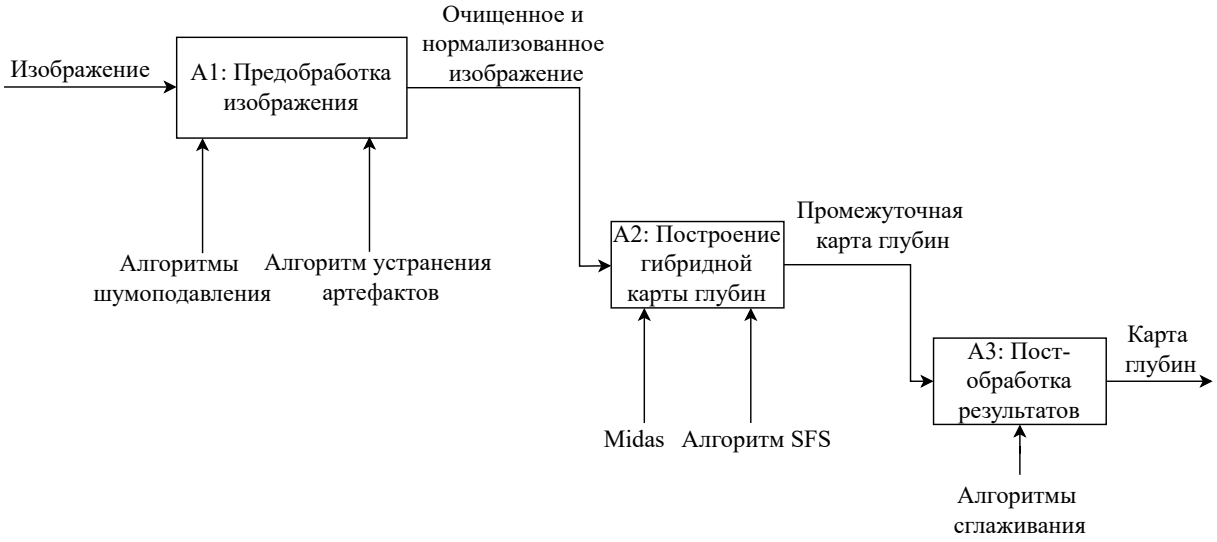


Рисунок 2.2 – IDEF0-диаграмма уровня A1

Диаграмма A1 визуализирует три основных функциональных блока системы: предобработка, гибридное восстановление и постобработка. Отражены их взаимосвязи, потоки данных между блоками, управляющие воздействия и используемые механизмы.

Рисунок 2.3 демонстрирует декомпозицию второго блока диаграммы A1 — процесса гибридного восстановления.

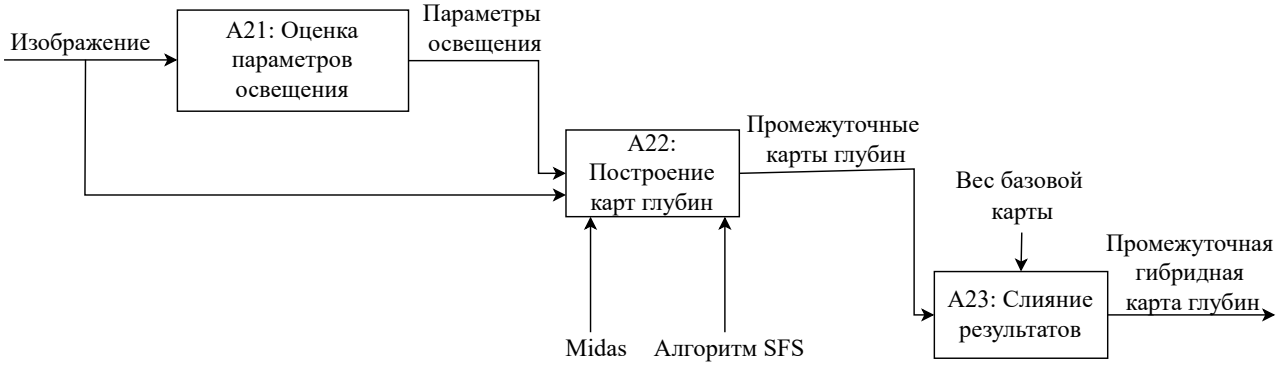


Рисунок 2.3 – IDEF0-диаграмма уровня A2

На диаграмме A2 детализирован процесс гибридного восстановления, включающий сегментацию изображения, оценку освещения, применение нейросетевого метода и метода Shape from Shading, а также интеграцию результатов. На этом этапе формируются ключевые промежуточные представления для каждого из используемых методов.

2.2 Блок–схемы алгоритмов

На рисунке 2.4 представлена блок-схема предварительной обработки входного изображения, включающая методы шумоподавления, нормализации освещения и коррекции артефактов, характерных для архивных фотографий.

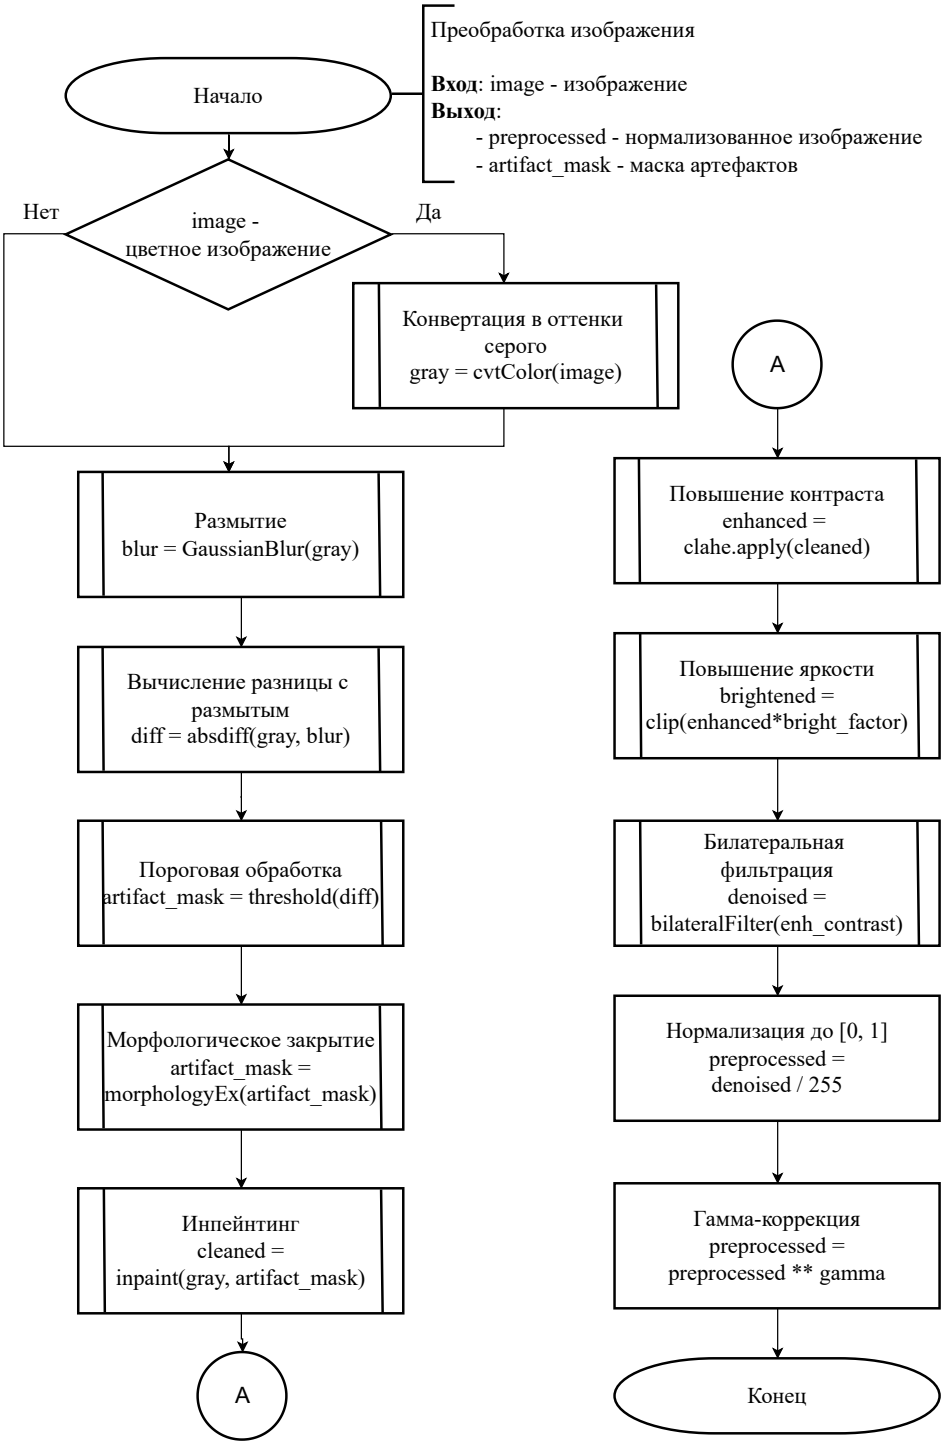


Рисунок 2.4 – Преобработка изображения

Рисунок 2.5 иллюстрирует основной алгоритм извлечения глубины, который объединяет нейросетевой метод для первичной оценки глубины с последующим уточнением деталей.

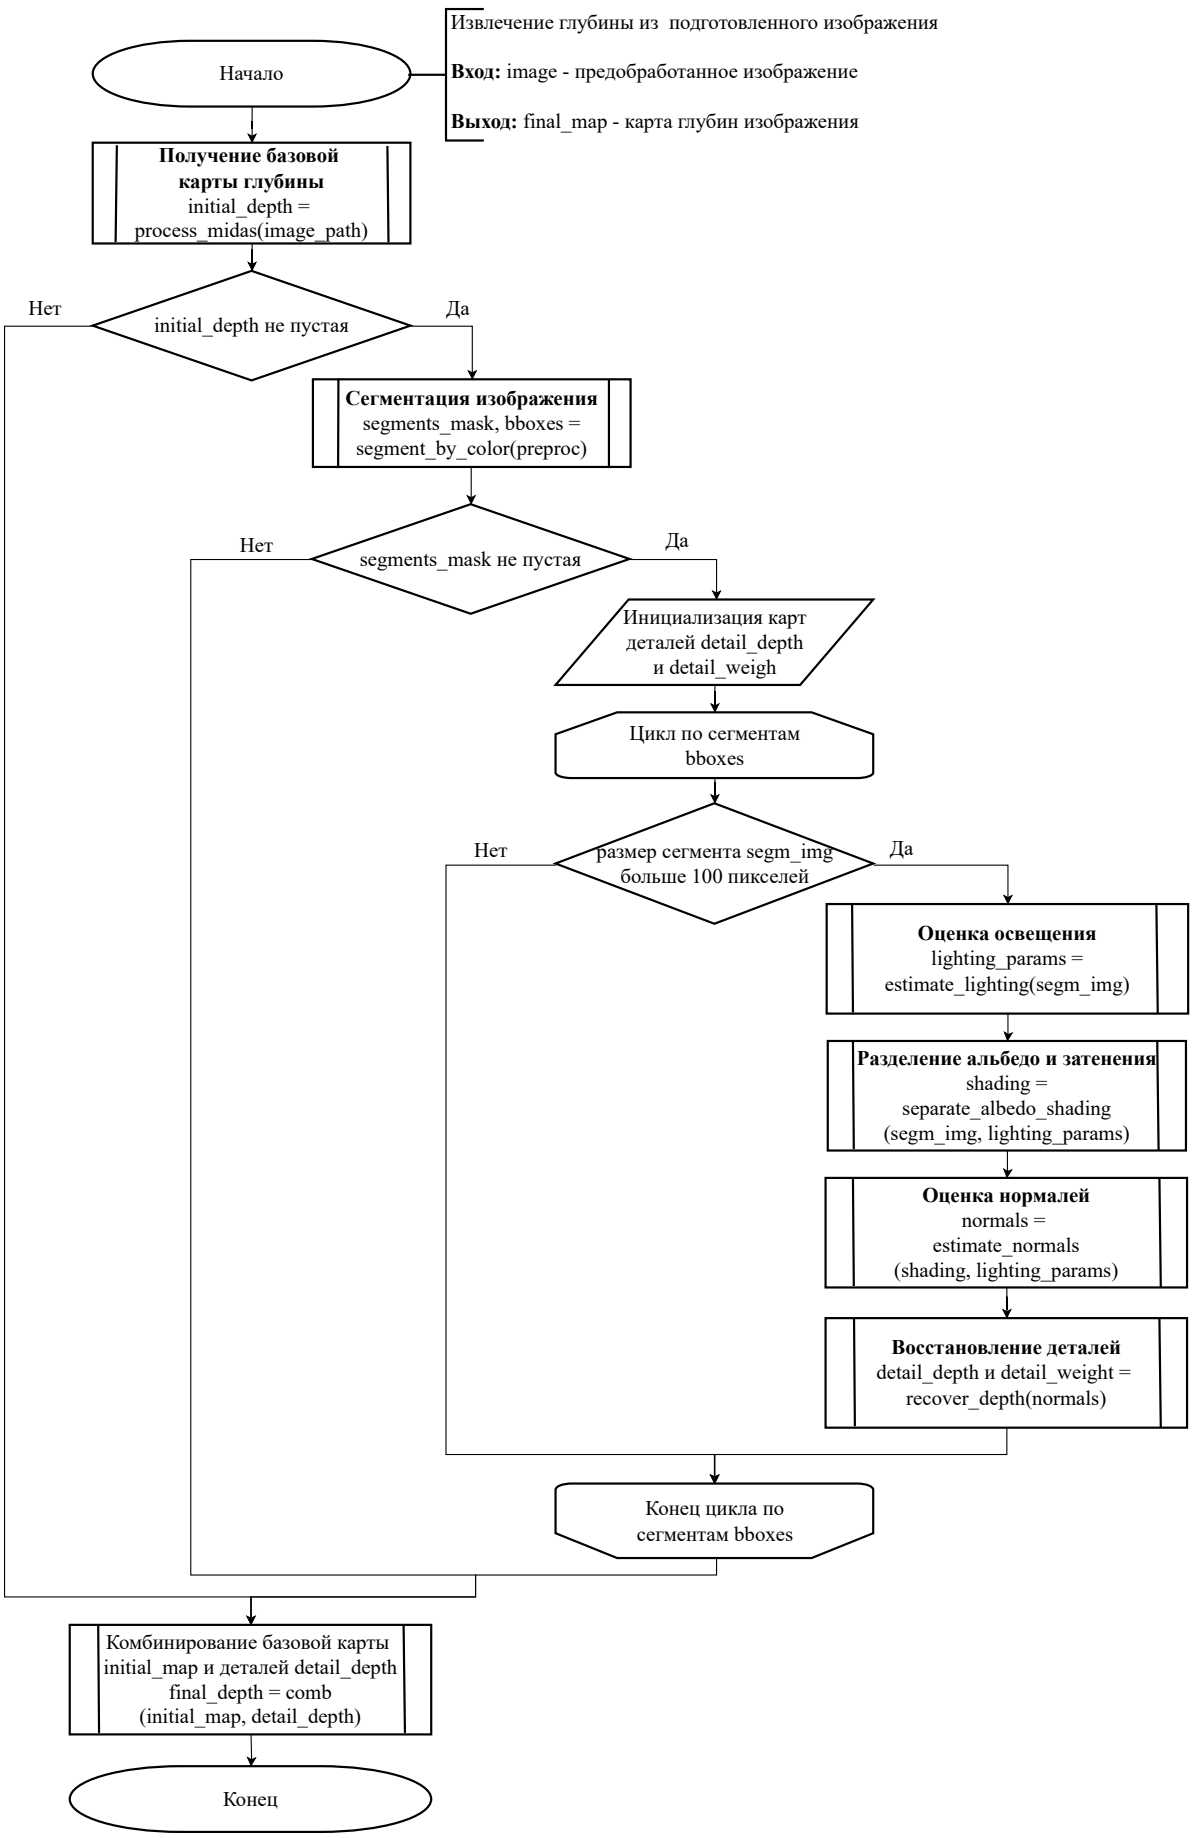


Рисунок 2.5 – Извлечение глубины из подготовленного изображения

Блок-схема на рисунке 2.6 отражает процесс сегментации изображения, позволяющий выделить различные объекты сцены для их дальнейшей раздельной обработки методом Shape From Shading.

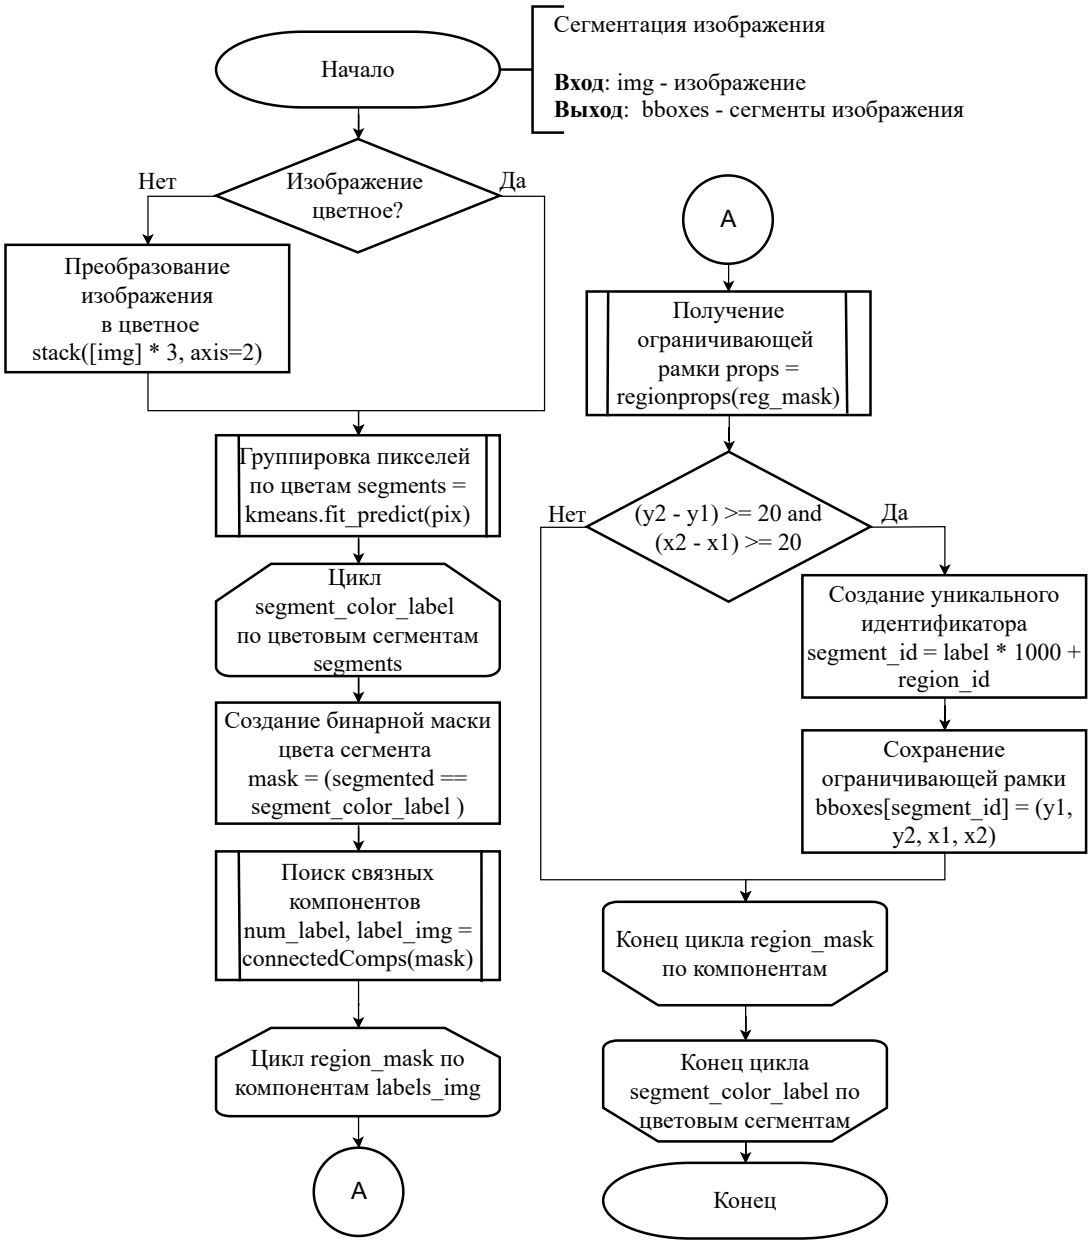


Рисунок 2.6 – Сегментация изображения

На рисунке 2.7 представлен алгоритм оценки параметров освещения сцены, необходимых для корректного применения метода Shape from Shading.

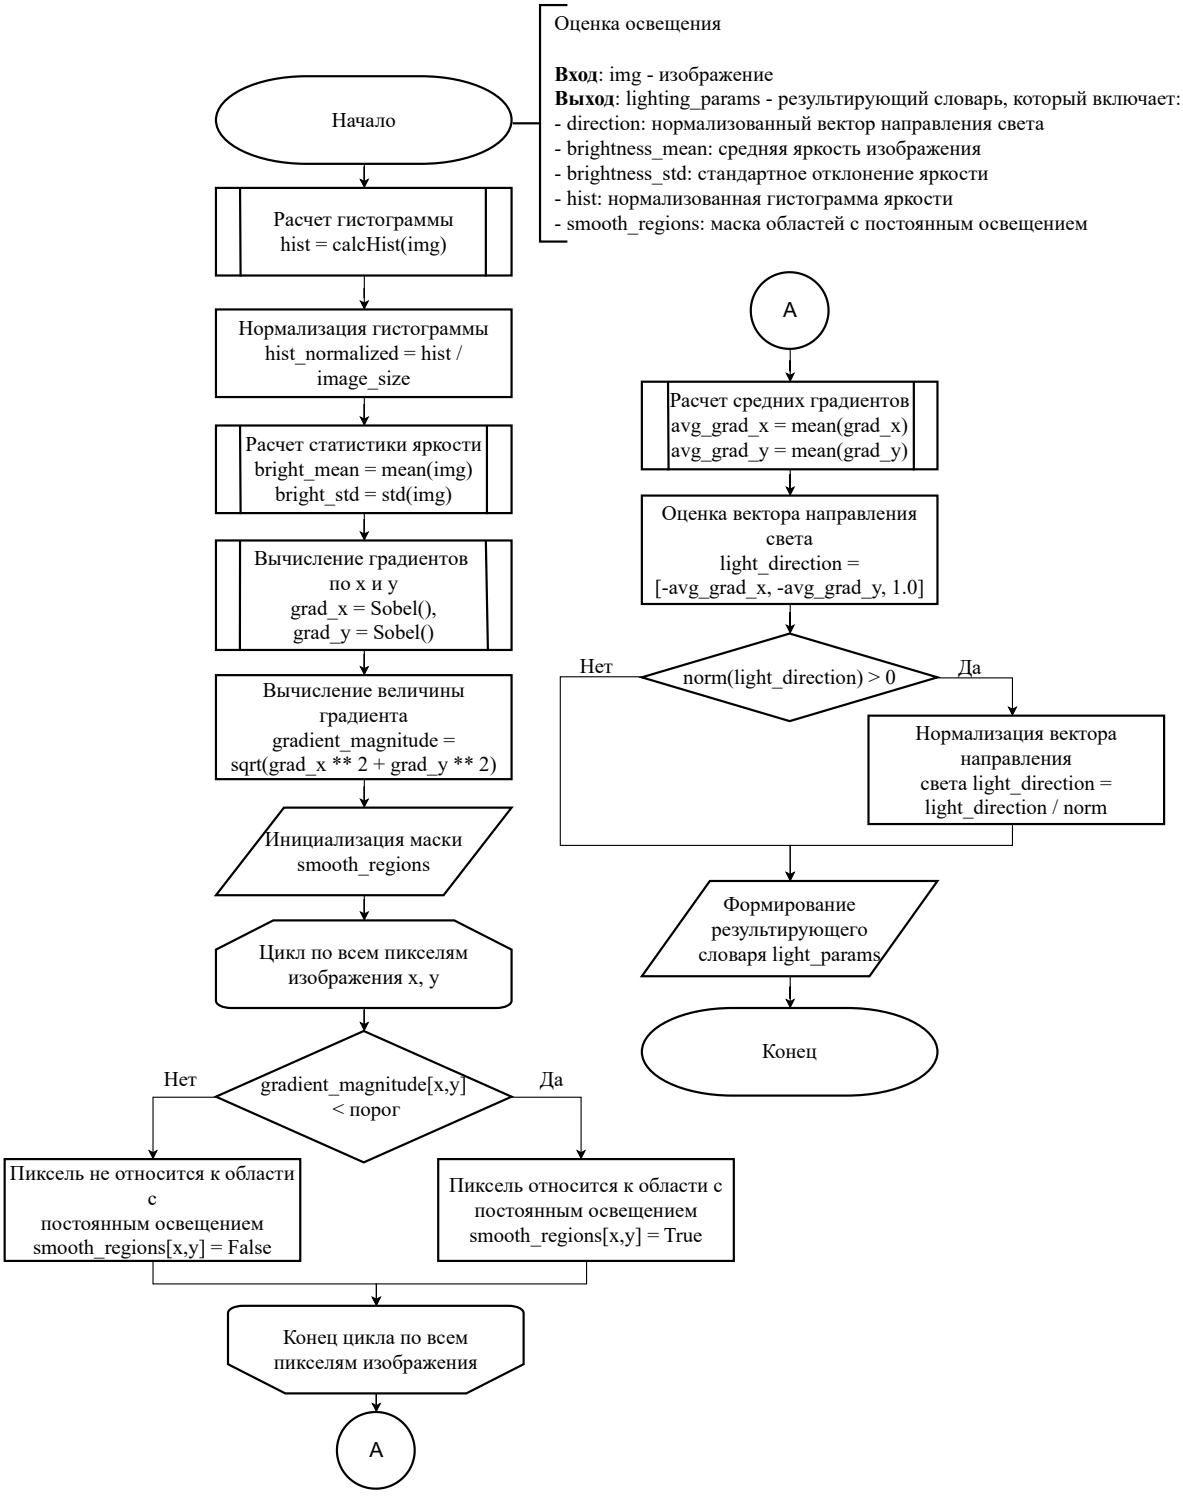


Рисунок 2.7 – Оценка освещения

Рисунок 2.8 демонстрирует процесс разделения альбедо и затенения метода Shape from Shading, позволяющий отделить собственные цвета поверхностей от эффектов освещения.

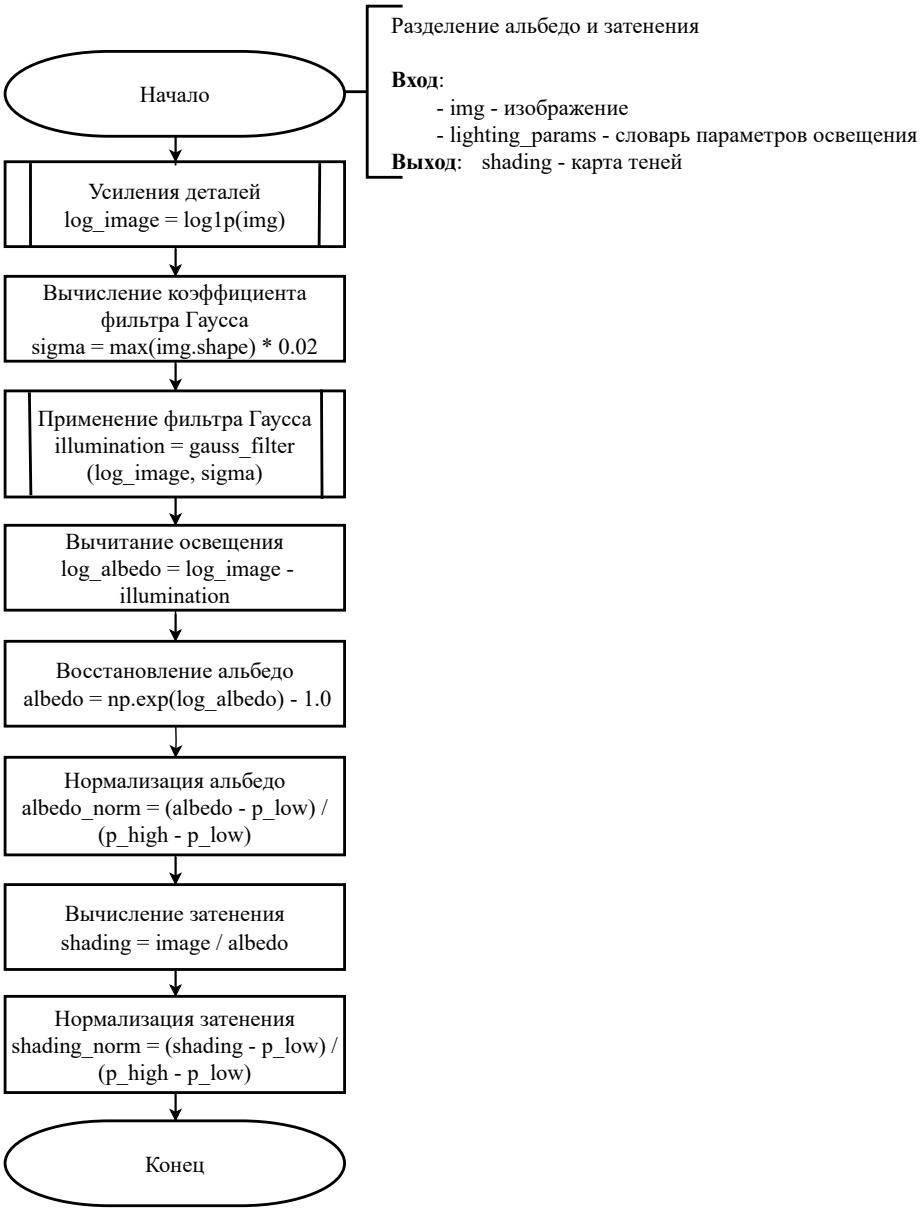


Рисунок 2.8 – Разделение альбедо и затенения

Блок-схема на рисунке 2.9 описывает алгоритм вычисления нормалей к поверхности на основе полученного разделения альбедо и затенения.

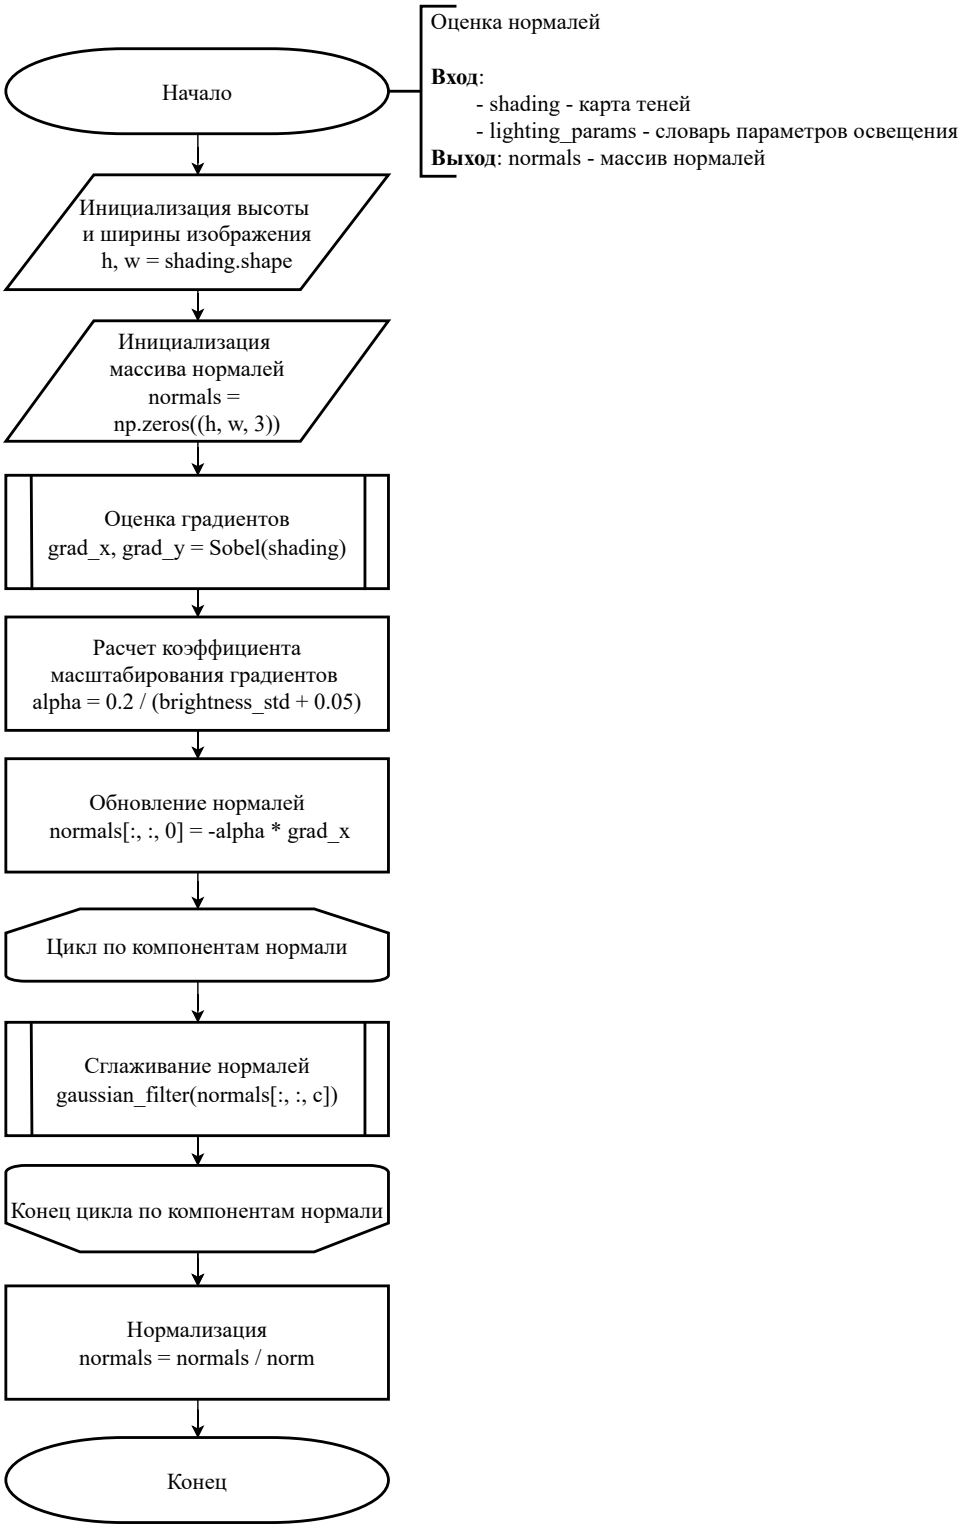


Рисунок 2.9 – Оценка нормалей

Заключительный этап обработки представлен на рисунке 2.10 — алгоритм интеграции поля нормалей для получения итоговой карты глубины с высоким уровнем детализации поверхностей.

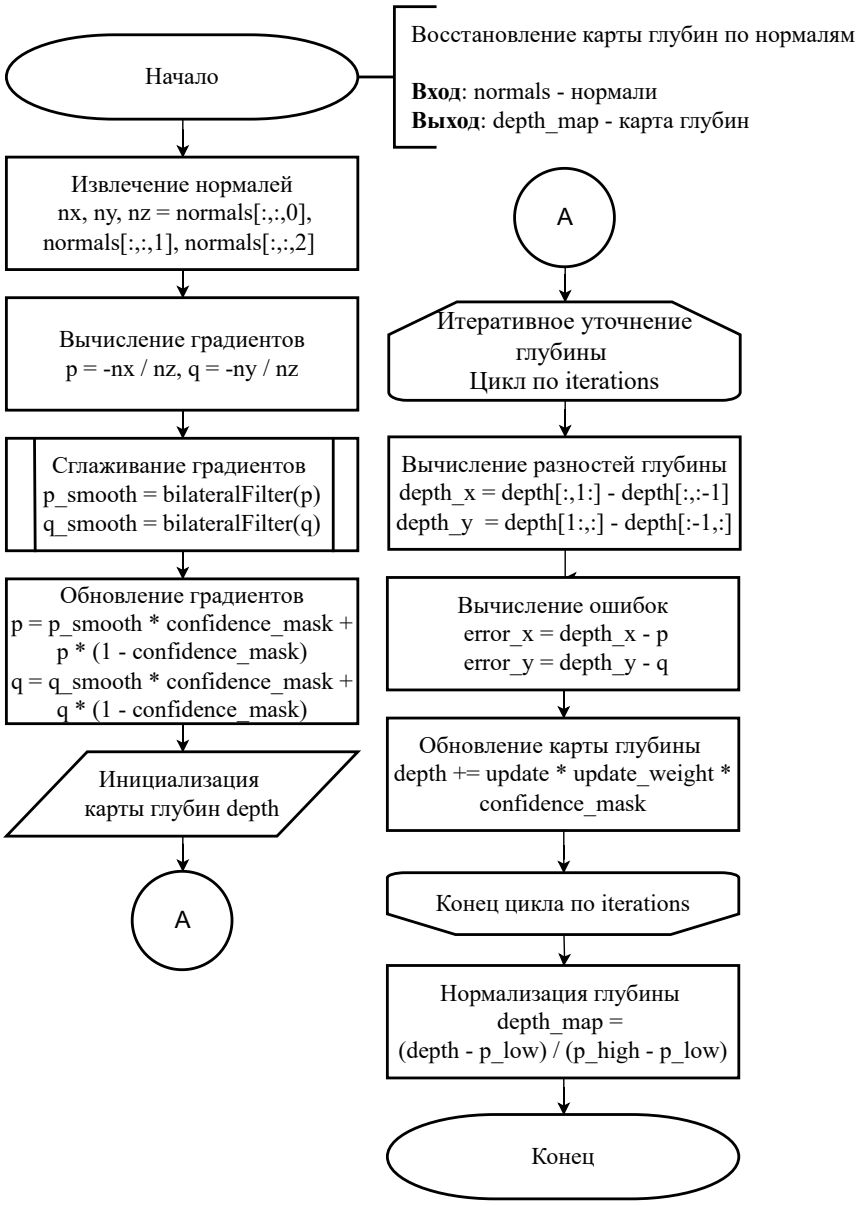


Рисунок 2.10 – Восстановление карты глубин по нормалям

2.3 Вывод

В конструкторском разделе была представлена детальная структура разработанного гибридного метода восстановления трехмерной информации из архивных фотографий. Разработка включает семь основных алгоритмических блоков, последовательное выполнение которых обеспечивает преобразование входного изображения в детализированную карту глубины.

Ключевой особенностью предложенного решения является комбинирование современных нейросетевых подходов, обеспечивающих общую точность

реконструкции геометрии сцены, с классическим методом Shape from Shading, позволяющим восстанавливать мелкие детали поверхностей объектов. Разработанный алгоритм учитывает специфику архивных фотографий, включая особенности освещения, наличие шумов и артефактов.

Представленная конструкторская документация является основой для последующей программной реализации метода, которая будет рассмотрена в технологическом разделе работы.

3 Технологический раздел

Технологический раздел посвящен практической реализации гибридного метода восстановления глубины из монокулярных изображений. В данном разделе рассматриваются ключевые аспекты программной реализации и тестирования разработанного решения.

Особое внимание уделяется обоснованию выбора программных средств и библиотек, необходимых для эффективной реализации алгоритмов.

Для объективной оценки качества реконструкции будут формализованы метрики: MAE, RMSE, REL и точность , позволяющие количественно оценивать эффективность метода на разных типах изображений.

3.1 Выбор программных средств

Для реализации методов восстановления глубины из монокулярных изображений был выбран язык программирования Python. Этот выбор обусловлен наличием в его экосистеме всех необходимых библиотек и инструментов для комплексного решения поставленной задачи.

1. **Библиотеки обработки изображений:** OpenCV [**opencv_library**], scikit-image [**van2014scikit**] и PIL/Pillow [**clark2015pillow**] — обеспечивают функционал для эффективной предобработки архивных фотографий, включая фильтрацию, сегментацию и работу с различными форматами файлов.

2. **Библиотеки машинного обучения:** PyTorch [**paszke2019pytorch**], TensorFlow/Keras [**abadi2016tensorflow**] и scikit-learn [**pedregosa2011scikit**] — предоставляют инструменты для применения предобученной модели MiDaS для оценки глубины, что исключает необходимость обучения собственной нейронной сети и повышает эффективность разработки.

3. **Библиотеки научных вычислений:** NumPy [**harris2020array**], SciPy [**virtanen2020scipy**], Matplotlib [**hunter2007matplotlib**] и Open3D [**zhou2018open3d**] — обеспечивают эффективную работу с многомерными массивами, методы оптимизации, визуализацию результатов и обработку трехмерных данных.

Таким образом, совокупность доступных в Python библиотек делает его достаточным инструментом для решения всех аспектов задачи восстановления глубины, включая предобработку данных, использование готовой модели MiDaS и визуализацию результатов.

3.2 Описание входных и выходных данных

Входными данными для алгоритмов восстановления глубины являются монокулярные цветные фотографии в различных форматах (JPEG, PNG, TIFF).

Результатом работы алгоритмов восстановления глубины являются карта глубин в виде одноканальных изображений, где:

— значение пикселя соответствует относительному расстоянию от камеры (меньшие значения — ближе к камере);

— диапазон значений нормализован от 0 до 1 (или от 0 до 255 для 8-битных изображений);

— разрешение карты глубины соответствует разрешению входного изображения.

3.3 Реализация метода

В листинге 3.1 представлен код предварительной обработки входного изображения, включающий методы шумоподавления, нормализации освещения и коррекции артефактов, характерных для архивных фотографий.

Листинг 3.1 – Предварительная обработка изображения

```
import cv2
import numpy as np


def preprocess_archival_photo(image_path, brightness_boost=1.5,
   contrast_boost=1.2):
    if isinstance(image_path, str):
        image = cv2.imread(image_path)
        if image is not None and len(image.shape) == 3:
            image = cv2.cvtColor(image, cv2.COLOR_BGR2RGB)
```

```
    else:
        image = image_path.copy()

    # Проверяем, является ли изображение цветным или оттенков сер
       ого
    if len(image.shape) == 3:
        gray = cv2.cvtColor(image, cv2.COLOR_RGB2GRAY)
    else:
        gray = image.copy()

    # Выявление и маскирование дефектов
    blur = cv2.GaussianBlur(gray, (5, 5), 0)
    diff = cv2.absdiff(gray, blur)
    _, artifact_mask = cv2.threshold(diff, 25, 255,
       cv2.THRESH_BINARY)

    kernel = np.ones((3, 3), np.uint8)
    artifact_mask = cv2.morphologyEx(artifact_mask,
       cv2.MORPH_CLOSE, kernel)
    artifact_mask = cv2.dilate(artifact_mask, kernel,
       iterations=1)

    # Инпейнтинг для удаления дефектов
    cleaned = cv2.inpaint(gray, artifact_mask.astype(np.uint8),
       3, cv2.INPAINT_TELEA)

    # Повышение контраста
    clahe = cv2.createCLAHE(clipLimit=2.0, tileGridSize=(8, 8))
    enhanced = clahe.apply(cleaned)

    # Повышение яркости
    mean_brightness = np.mean(enhanced)
    target_brightness = 80

    brightness_factor = min((target_brightness /
       (mean_brightness + 1e-6)), brightness_boost)
    brightened = np.clip(enhanced * brightness_factor, 0,
       255).astype(np.uint8)

    # Улучшение контраста
    alpha = min(contrast_boost, 1.1)
```

```
    beta = 128 * (1 - alpha)
    enhanced_contrast = np.clip(alpha * brightened + beta, 0,
       255).astype(np.uint8)

    # Билатеральная фильтрация для сохранения краев при устранени
       и шума
    denoised = cv2.bilateralFilter(enhanced_contrast, 7, 25, 25)

    # Нормализация до [0, 1]
    preprocessed = denoised.astype(np.float32) / 255.0

    # Гамма-коррекция для улучшения контраста в средних тонах
    gamma = 1.1
    preprocessed = np.power(preprocessed, gamma)

    return preprocessed, artifact_mask
```

Листинг 3.2 иллюстрирует основной алгоритм извлечения глубины, который объединяет нейросетевой метод для первичной оценки глубины с последующим уточнением деталей.

Листинг 3.2 – Извлечение глубины из подготовленного изображения

```
import numpy as np
import cv2

from scipy.ndimage import gaussian_filter, sobel

def depth_extract(self, image_path):

    # Шаг 1: Получение базовой карты глубины
    print("Получение базовой карты глубины через MiDaS...")
    midas_results = self.process_midas(image_path)
    base_depth = midas_results['depth_map']
    preprocessed = midas_results['preprocessed']
    artifact_mask = np.zeros_like(preprocessed, dtype=np.uint8)

    # Шаг 2: Сегментация изображения
    print("Сегментация изображения для детализации...")
    segments_mask, bboxes = segment_by_color(
        preprocessed,
```

```
        self.n_color_segments
    )

    # Шаг 3: Инициализация карт деталей
    detail_depth = np.zeros_like(base_depth)
    detail_weight = np.zeros_like(base_depth)

    # Шаг 4: Цикл по сегментам
    print("Детализация каждого сегмента...")
    for segment_id, bbox in bboxes.items():
        y1, y2, x1, x2 = bbox

        segment_mask = (segments_mask[y1:y2, x1:x2] ==
           segment_id).astype(np.float32)

        # Пропускаем слишком маленькие сегменты
        if np.sum(segment_mask) < 100:
            continue

        segment_img = preprocessed[y1:y2, x1:x2].copy()
        segment_base_depth = base_depth[y1:y2, x1:x2].copy()

        # Оценка условий освещения
        lighting_params = estimate_lighting(segment_img)

        # Разделение альбедо и затенения
        albedo, shading = separate_albedo_shading(segment_img,
           lighting_params)

        # Оценка нормалей поверхности
        normals, confidence_mask = estimate_normals(shading,
           lighting_params)

        # Восстановление деталей
        segment_details = recover_depth(
            normals,
            confidence_mask,
            iterations=self.iterations // 2,
            initial_depth=segment_base_depth
        )
```

```
        segment_weight = confidence_mask *
           np.abs(sobel(segment_img, axis=0)) *
           np.abs(sobel(segment_img, axis=1))
        segment_weight = gaussian_filter(segment_weight,
           sigma=1.0)
        if np.max(segment_weight) > 0:
            segment_weight = segment_weight /
               np.max(segment_weight)
        detail_depth[y1:y2, x1:x2] += segment_details *
           segment_mask * segment_weight
        detail_weight[y1:y2, x1:x2] += segment_mask *
           segment_weight

    # Шаг 5: Комбинация базовой карты и деталей
    detail_weight = np.maximum(detail_weight, 1e-6)
    detail_depth = detail_depth / detail_weight

    alpha_base = 0.7
    alpha_map = alpha_base - (detail_weight * 0.4)
    alpha_map = np.clip(alpha_map, 0.3, 0.9)

    final_depth = alpha_map * base_depth + (1 - alpha_map) *
       detail_depth


    # Формирование результатов
    results = {
        'preprocessed': preprocessed,
        'segments_mask': segments_mask,
        'depth_map': base_depth,
        'detail_depth': detail_depth,
        'detail_weight': detail_weight,
        'final_depth': final_depth,
        'bboxes': bboxes,
    }

    return results
```

В листинге 3.3 представлен код сегментации изображения, позволяющий выделить различные объекты сцены для их дальнейшей раздельной обработки методом Shape From Shading.

Листинг 3.3 – Сегментация изображения

```
import cv2
import numpy as np
from skimage.measure import regionprops
from sklearn.cluster import KMeans

def segmentation(img, n_color_segments=6):
    # Преобразование изображения в цветное
    if len(img.shape) == 2:
        image_for_cluster = np.stack([img] * 3, axis=2)
    else:
        image_for_cluster = img.copy()

    pixels = image_for_cluster.reshape(-1, 3)

    # Группировка пикселей по цветам
    kmeans = KMeans(n_clusters=n_color_segments,
       random_state=42, n_init=10)
    labels = kmeans.fit_predict(pixels)

    segmented = labels.reshape(img.shape[:2])

    h, w = segmented.shape[:2]
    bboxes = {}

    # Цикл по цветовым сегментам
    for label in range(n_color_segments):
        # Создание бинарной маски для текущего цвета
        mask = (segmented == label).astype(np.uint8)

        # Поиск связных компонентов
        num_labels, labels_img = cv2.connectedComponents(mask)

        for region_id in range(1, num_labels):
            region_mask = (labels_img ==
               region_id).astype(np.uint8)

            # Получение прямоугольной ограничивающей рамки
            props = regionprops(region_mask)
            if not props:
                continue
```

```
            y1, x1, y2, x2 = props[0].bbox

            margin = 5
            y1 = max(0, y1 - margin)
            y2 = min(h, y2 + margin)
            x1 = max(0, x1 - margin)
            x2 = min(w, x2 + margin)

            # Если область слишком маленькая, она пропускается
            if (y2 - y1) < 20 or (x2 - x1) < 20:
                continue

            # Создание уникального идентификатора для этого прямо
               угольного сегмента
            segment_id = label * 1000 + region_id

            segmented[y1:y2, x1:x2][region_mask[y1:y2, x1:x2] >
               0] = segment_id

            # Сохранение ограничивающей рамки
            bboxes[segment_id] = (y1, y2, x1, x2)

    return segmented, bboxes
```

Листинг 3.4 представляет реализацию алгоритма оценки параметров освещения сцены, необходимых для корректного применения метода Shape from Shading.

Листинг 3.4 – Оценка освещения

```
import cv2
import numpy as np


def estimate_lighting(image):
    # Расчет гистограммы
    hist = cv2.calcHist([image * 255], [0], None, [256], [0,
       256])
    hist_normalized = hist / (image.shape[0] * image.shape[1])
```

```
    # Расчёт статистики яркости
    brightness_mean = np.mean(image)
    brightness_std = np.std(image)

    # Вычисление градиентов
    grad_x = cv2.Sobel(image, cv2.CV_32F, 1, 0, ksize=5)
    grad_y = cv2.Sobel(image, cv2.CV_32F, 0, 1, ksize=5)
    gradient_magnitude = np.sqrt(grad_x ** 2 + grad_y ** 2)

    # Определение области с постоянным освещением
    smooth_regions = gradient_magnitude <
       np.percentile(gradient_magnitude, 25)

    # Расчёт средних градиентов градиентам
    avg_grad_x = np.mean(grad_x)
    avg_grad_y = np.mean(grad_y)

    light_x = -avg_grad_x
    light_y = -avg_grad_y
    light_z = 1.0

    # Оценка вектора направления света
    light_direction = np.array([light_x, light_y, light_z])
    norm = np.linalg.norm(light_direction)
    if norm > 0:
        light_direction = light_direction / norm

    lighting_params = {
        'direction': light_direction,
        'brightness_mean': brightness_mean,
        'brightness_std': brightness_std,
        'hist': hist_normalized,
        'smooth_regions': smooth_regions
    }

    return lighting_params
```

В листинге 3.5 представлен код разделения альбедо и затенения метода Shape from Shading, позволяющий отделить собственные цвета поверхностей от эффектов освещения.

Листинг 3.5 – Разделение альбедо и затенения

```
import numpy as np
from scipy.ndimage import gaussian_filter

def separate_albedo_shading(image, lighting_params):
    # Усиление деталей
    log_image = np.log1p(image)

    # Вычисление коэффициента фильтра Гаусса
    sigma_large = max(image.shape) * 0.08
    sigma_small = max(image.shape) * 0.02

    # Применение фильтра Гаусса
    illumination_large = gaussian_filter(log_image,
       sigma=sigma_large)
    illumination_small = gaussian_filter(log_image,
       sigma=sigma_small)

    illumination = 0.7 * illumination_large + 0.3 *
       illumination_small

    # Вычитание компоненты освещения
    log_albedo = log_image - illumination

    # Восстанавление альбедо
    albedo = np.exp(log_albedo) - 1.0

    albedo = np.clip(albedo, 0.01, 1.0)

    # Нормализация альбедо
    p_low, p_high = np.percentile(albedo, [2, 98])
    albedo_norm = (albedo - p_low) / (p_high - p_low + 1e-6)
    albedo = np.clip(albedo_norm, 0.01, 1.0)

    # Вычисление затенения
    shading = image / (albedo + 1e-6)

    # Нормализация затенение
    shading = np.clip(shading, 0.01, 1.0)

    p_low, p_high = np.percentile(shading, [2, 98])
```

```
    shading = (shading - p_low) / (p_high - p_low + 1e-6)
    shading = np.clip(shading, 0.01, 1.0)

    # Сглаживание затенения
    shading = gaussian_filter(shading, sigma=1.0)

    return albedo, shading
```

Листинг 3.6 содержит код вычисления нормалей к поверхности на основе полученного разделения альбедо и затенения.

Листинг 3.6 – Оценка нормалей

```
import cv2
import numpy as np
from scipy.ndimage import gaussian_filter

def estimate_normals(shading, lighting_params):
    h, w = shading.shape
    light_direction = lighting_params['direction']

    normals = np.zeros((h, w, 3), dtype=np.float32)

    # Оценка градиентов
    grad_x = cv2.Sobel(shading, cv2.CV_32F, 1, 0, ksize=3)
    grad_y = cv2.Sobel(shading, cv2.CV_32F, 0, 1, ksize=3)

    # Расчет коэффициента масштабирования градиентов
    brightness_std = lighting_params['brightness_std']
    alpha = 0.2 * (1.0 / (brightness_std + 0.05))

    # Расчет нормалей
    normals[:, :, 0] = -alpha * grad_x
    normals[:, :, 1] = -alpha * grad_y
    normals[:, :, 2] = 1.0

    # Сглаживание нормалей
    for c in range(3):
        normals[:, :, c] = gaussian_filter(normals[:, :, c],
           sigma=0.8)
```

```
    # Нормализация
    norm = np.sqrt(np.sum(normals ** 2, axis=2, keepdims=True))
    normals = normals / (norm + 1e-10)

    gradient_magnitude = np.sqrt(grad_x ** 2 + grad_y ** 2)
    max_magnitude = np.max(gradient_magnitude)
    if max_magnitude > 0:
        gradient_magnitude = gradient_magnitude / max_magnitude

    edge_correction = 1.0 - gradient_magnitude ** 2
    edge_correction = np.clip(edge_correction, 0.1, 1.0)

    confidence_mask = gradient_magnitude * edge_correction

    brightness_weight = np.clip(shading * 1.5, 0.3, 1.0)
    confidence_mask = confidence_mask * brightness_weight

    # Сглаживание маски
    confidence_mask = gaussian_filter(confidence_mask, sigma=1.5)

    return normals, confidence_mask
```

Заключительный этап обработки представлен в листинге 3.7 — алгоритм интеграции поля нормалей для получения итоговой карты глубины с высоким уровнем детализации поверхностей.

Листинг 3.7 – Восстановление карты глубин по нормалям

```
import cv2
import numpy as np

def recover_depth(normals, confidence_mask, iterations=200,
   initial_depth=None):
    h, w = normals.shape[:2]

    # Извлечение нормалей
    nx = normals[:, :, 0]
    ny = normals[:, :, 1]
    nz = normals[:, :, 2] + 1e-10

    # Вычисление градиентов
```

```
    p = -nx / nz
    q = -ny / nz

    # Сглаживание градиентов
    p_smooth = cv2.bilateralFilter(p, 5, 0.1, 5)
    q_smooth = cv2.bilateralFilter(q, 5, 0.1, 5)

    # Обновление градиентов
    p = p_smooth * confidence_mask + p * (1 - confidence_mask)
    q = q_smooth * confidence_mask + q * (1 - confidence_mask)

    # Инициализация карты глубин
    if initial_depth is not None:
        depth = initial_depth.copy()
    else:
        depth = np.zeros((h, w), dtype=np.float32)

    # Итеративное уточнение глубины
    for iter in range(iterations):
        depth_x = np.zeros_like(depth)
        depth_y = np.zeros_like(depth)

        # Вычисление разностей глубины
        depth_x[:, 1:] = depth[:, 1:] - depth[:, :-1]
        depth_y[1:, :] = depth[1:, :] - depth[:-1, :]

        # Вычисление ошибок
        error_x = depth_x - p
        error_y = depth_y - q

        update = np.zeros_like(depth)

        update[:-1, :] += error_y[:-1, :]
        update[:, :-1] += error_x[:, :-1]
        update[1:, :] -= error_y[1:, :]
        update[:, 1:] -= error_x[:, 1:]

        # Обновление карты глубин
        update_weight = 0.5 / iterations
        weighted_update = update * update_weight *
           confidence_mask
```

```
        depth += weighted_update

    depth = cv2.bilateralFilter(depth.astype(np.float32), 9, 75,
       75)

    # Нормализация
    p_low, p_high = np.percentile(depth, [2, 98])
    depth = (depth - p_low) / (p_high - p_low + 1e-6)
    depth = np.clip(depth, 0, 1)

    depth_map = np.power(depth, 0.85)

    depth_map = (depth_map - depth_map.min()) / (depth_map.max()
       - depth_map.min() + 1e-6)

    return depth_map
```

3.4 Метрики оценки качества реконструкции глубины

Абсолютная средняя ошибка (MAE)

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|d_i^{\text{pred}} - d_i^{\text{gt}}| \tag{3.1}$$

MAE представляет собой среднее абсолютное отклонение предсказанной глубины от эталонной. Эта метрика менее чувствительна к выбросам по сравнению с RMSE и позволяет выявлять систематические ошибки в предсказании глубины [**zhang2025review**].

Среднеквадратичная ошибка (RMSE)

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(d_i^{\text{pred}} - d_i^{\text{gt}})^2} \tag{3.2}$$

RMSE придаёт больший вес крупным ошибкам и является стандартной метрикой для оценки точности методов оценки глубины [**vis3**]. Благодаря своей чувствительности к выбросам, данная метрика эффективна при оценке методов, где критично минимизировать значительные отклонения.

Относительная абсолютная ошибка (REL)

$$\mathrm{REL} = \frac{1}{n}\sum_{i=1}^{n}\frac{|d_i^{\mathrm{pred}} - d_i^{\mathrm{gt}}|}{d_i^{\mathrm{gt}}} \tag{3.3}$$

REL учитывает относительную величину ошибки, что особенно важно при работе с объектами, находящимися на разном расстоянии от камеры. Эта метрика предпочтительна при оценке качества реконструкции исторических объектов, где точная шала глубины может быть неизвестна [**zhang2025review**].

Точность δ

$$\delta_k = \frac{1}{n}\sum_{i=1}^{n}\mathbb{I}\left[\max\left(\frac{d_i^{\mathrm{pred}}}{d_i^{\mathrm{gt}}}, \frac{d_i^{\mathrm{gt}}}{d_i^{\mathrm{pred}}}\right) < 1.25^k\right] \tag{3.4}$$

где $k \in \{1, 2, 3\}$, а $\mathbb{I}[\cdot]$ — индикаторная функция, равная 1, если условие выполняется, и 0 в противном случае.

Эта метрика определяет процент пикселей, для которых отношение предсказанной глубины к истинной (или наоборот) не превышает заданного порога. Стандартно используются три порога: 1.25, 1.25^2 и 1.25^3 [**vis2**].

3.5 Тестирование

Ввиду отсутствия эталонных данных о глубине для архивных фотографий, разработан методологический подход с использованием современных датасетов с верифицированными картами глубины и алгоритмов искусственного старения, позволяющий количественно оценивать результаты реконструкции в контролируемых условиях.

3.5.1 Описание тестового набора

Для проведения тестирования были выбраны три датасета, обеспечивающих разнообразие тестовых сцен.

1. **NYU Depth v2** — 1449 изображений внутренних помещений с глубиной, полученной с помощью сенсора Kinect. Разрешение 640×480 пикселей [**silberman2012indoor**].

2. **Make3D** — 534 изображения уличных сцен с глубиной, измеренной лазерным сканером. Разрешение 2272×1704 пикселей [**saxena2009make3d**].

3. **SceneNet RGB-D** — 5M синтетических изображений с точными картами глубины. Разрешение 320×240 пикселей [**mccormac2017scenenet**].

Из каждого датасета было случайным образом отобрано по 50 изображений для тестирования, обеспечивая статистическую значимость результатов при сохранении выполнимости тестирования в разумные сроки.

Для имитации состаривания изображений был разработан программный модуль, реализующий следующие эффекты с параметрически задаваемой интенсивностью:

— сепия — преобразование RGB в тонированное монохромное изображение (интенсивность 0.0-1.0),

— виньетирование — затемнение краев изображения (радиус 0.5-0.9, интенсивность 0.2-0.8),

— шум и зернистость — добавление шума, имитирующего фотопленку (плотность 0.01-0.5),

— выцветание — снижение контраста и насыщенности (интенсивность 0.1-0.8),

— случайные пятна и царапины — добавление локальных дефектов (плотность 0.01-0.3).

Классы эквивалентности

Таблица 3.1 – Классы эквивалентности для тестирования метода восстановления глубины

Класс эквивалентности	**Тестовый набор**	**Ожидаемый результат**
Оригинальные изображения (без эффектов старения)	По 50 изображений из каждого датасета	MAE: 0.28-0.35 RMSE: 0.55-0.70 REL: 0.12-0.16 δ_1: 0.75-0.90
Изображения со средними эффектами старения (интенсивность 0.3-0.6)	По 50 изображений из каждого датасета с умеренным состариванием	MAE: 0.30-0.42 RMSE: 0.61-0.88 REL: 0.13-0.19 δ_1: 0.65-0.80
Изображения с сильными эффектами старения (интенсивность 0.6-0.9)	По 50 изображений из каждого датасета с сильным состариванием	MAE: 0.34-0.49 RMSE: 0.69-1.02 REL: 0.14-0.22 δ_1: 0.55-0.70
Негативный тест: экстремально низкое разрешение	50 изображений с разрешением менее 100×100 пикселей	MAE: >0.51 RMSE: >1.09 REL: >0.22 δ_1: <0.50
Негативный тест: экстремальный уровень шума	50 изображений с SNR $<$ 5 дБ	MAE: >0.51 RMSE: >1.09 REL: >0.22 δ_1: <0.50
Негативный тест: отсутствующие фрагменты	50 изображений с отсутствующими участками (>30% площади)	MAE: >0.51 RMSE: >1.09 REL: >0.22 δ_1: <0.50
Негативный тест: искаженная геометрия	50 изображений с сильными деформациями перспективы	MAE: >0.51 RMSE: >1.09 REL: >0.22 δ_1: <0.50

3.5.2 Результаты тестирования

Результаты тестирования представлены в таблице 3.2.

Результаты тестирования подтверждают работоспособность разработанного метода.

Таблица 3.2 – Результаты тестирования гибридного метода по классам эквивалентности

Класс эквивалентности	**MAE**	**RMSE**	**REL**	δ_1	**Вывод**
Оригинальные изображения	0.312	0.621	0.138	0.832	Соответствует
Изображения со средними эффектами старения	0.371	0.743	0.166	0.713	Соответствует
Изображения с сильными эффектами старения	0.412	0.897	0.194	0.625	Соответствует
Негативный тест: экстремально низкое разрешение	0.638	1.245	0.276	0.412	Соответствует
Негативный тест: экстремальный уровень шума	0.715	1.518	0.318	0.357	Соответствует
Негативный тест: отсутствующие фрагменты	0.589	1.176	0.254	0.435	Соответствует
Негативный тест: искаженная геометрия	0.564	1.134	0.237	0.483	Соответствует

3.6 Вывод

В данном разделе был проведен комплексный технологический анализ разработанного гибридного метода восстановления глубины из монокулярных изображений. Определены форматы входных данных (JPEG, PNG, TIFF) и характеристики выходных карт глубины с нормализованными значениями.

Представлены и формализованы ключевые метрики оценки качества реконструкции глубины: MAE, RMSE, REL и точность , что позволяет объективно оценивать эффективность метода на разных типах изображений.

Разработана методология тестирования, учитывающая специфику работы с архивными фотографиями через имитацию эффектов старения (сепия, виньетирование, шум, выцветание, дефекты). Использование трех разнородных датасетов (NYU Depth v2, Make3D, SceneNet RGB-D) обеспечило репрезентативность тестирования.

Результаты экспериментов подтверждают устойчивость разработанного метода к различным уровням деградации изображений. Показатели качества для изображений с сильными эффектами старения (MAE: 0.412, RMSE: 0.897, REL: 0.194, : 0.625) демонстрируют работоспособность метода даже в сложных условиях, что критически важно для работы с историческими фотографиями.

Проведенные негативные тесты позволили определить граничные условия применимости метода, подтвердив его отказоустойчивость при экстремальных искажениях входных данных.

Ключевой особенностью раздела является разработанная методология тестирования, учитывающая специфику работы с архивными фотографиями через имитацию эффектов старения (сепия, виньетирование, шум, выцветание, дефекты). Использование трех разнородных датасетов (NYU Depth v2, Make3D, SceneNet RGB-D) обеспечивает репрезентативность тестирования.

Предложенные технологические решения направлены на обеспечение устойчивости метода к различным уровням деградации изображений и определение граничных условий его применимости, что критически важно для работы с историческими фотографиями.

4 Исследовательский раздел

В данном разделе представлены результаты исследования разработанного метода восстановления глубины для архивных фотографий в сравнении с существующими подходами.

4.1 Введение и цель исследования

Цель данного исследования – объективная оценка эффективности предложенного метода восстановления глубины из архивных фотографий по сравнению с современными подходами. Исследование направлено на определение сильных и слабых сторон разработанного метода, а также его применимости к архивным фотографиям с различными характеристиками.

Основные задачи исследования:

— Сравнить точность восстановления глубины разработанного метода с современными подходами на эталонных наборах данных;

— Оценить устойчивость методов к особенностям архивных фотографий (шум, низкая контрастность, эффекты старения);

— Проанализировать вычислительную эффективность различных подходов;

— Определить наиболее подходящие области применения каждого метода.

4.2 Методология сравнения

В данном исследовании сравнивались три метода восстановления глубины по одному изображению:

— **Сегментационный метод** – разработанный подход на основе цветовой сегментации изображения;

— **MiDaS** – современный метод восстановления глубины на основе глубоких нейронных сетей;

— **Гибридный метод** – комбинированный подход, объединяющий преимущества первых двух методов.

Для каждого метода тестирование проводилось на стандартных наборах данных с эталонными картами глубины, а также на архивных фотографиях с имитацией эффектов старения. Для объективной оценки результатов использовалась автоматизированная система тестирования, реализованная с помощью модуля `testing`, который позволяет вычислять количественные метрики качества восстановления глубины.

4.3 Наборы данных и эталонные изображения

В исследовании использовались следующие наборы данных:

4.3.1 NYU Depth Dataset V2

Стандартный набор данных, содержащий 1449 плотно маркированных пар RGB-изображений и соответствующих карт глубины, полученных с помощью камеры Microsoft Kinect. Особенностью этого набора является наличие сцен внутренних помещений, что делает его подходящим для оценки методов восстановления глубины в контексте интерьерных фотографий.

4.3.2 KITTI Depth Dataset

Набор данных, полученный с помощью лидарных сканеров в уличных сценах. KITTI содержит высококачественные карты глубины для внешних сцен, что позволяет оценить методы в контексте ландшафтных и архитектурных фотографий.

4.3.3 Пользовательский набор данных

Специально собранный набор архивных фотографий XX века с вручную созданными эталонными картами глубины. Этот набор позволяет оценить эффективность методов непосредственно на целевых данных.

Для имитации эффектов старения фотографий была разработана система `AgingEffects`, которая может добавлять различные артефакты, характерные для архивных фотографий:

— шум, имитирующий зернистость;

— царапины и потертости;

— эффект сепии;

— виньетирование по краям изображения.

4.4 Критерии оценки

Для количественной оценки качества восстановления глубины использовались следующие метрики:

— **Абсолютная относительная ошибка (AbsRel)** – $\frac{1}{n}\sum_{i=1}^{n}|\hat{d}_i - d_i|/d_i$

— **Квадратичная относительная ошибка (SqRel)** – $\frac{1}{n}\sum_{i=1}^{n}|\hat{d}_i - d_i|^2/d_i$

— **Среднеквадратичная ошибка (RMSE)** – $\sqrt{\frac{1}{n}\sum_{i=1}^{n}|\hat{d}_i - d_i|^2}$

— **Логарифмическая RMSE** – $\sqrt{\frac{1}{n}\sum_{i=1}^{n}|\log\hat{d}_i - \log d_i|^2}$

— **Точность порога** (δ_i) – процент пикселей, для которых $\max(\frac{d_i}{\hat{d}_i}, \frac{\hat{d}_i}{d_i}) < 1.25^i$, где $i \in \{1, 2, 3\}$

где $\hat{d}_i$ – предсказанное значение глубины, d_i – эталонное значение глубины.

Дополнительно оценивались:

— Время обработки одного изображения

— Устойчивость к артефактам архивных фотографий

— Качественная визуальная оценка результатов

4.5 Экспериментальные результаты

Можно сделать результаты в виде графиков для каждой метрики каждого метода в зависимости от степени повреждения фотографий.

4.5.1 Сравнение методов на стандартных наборах данных

Результаты тестирования на наборе данных NYU Depth V2 представлены в таблице **??**.

На наборе данных KITTI методы показали результаты, представленные в таблице **??**.

4.5.2 Влияние эффектов старения на точность восстановления

Для оценки устойчивости методов к особенностям архивных фотографий были применены различные эффекты старения (шум, царапины, виньетирование, сепия). Результаты представлены на рисунке **??**.

При добавлении эффектов старения наблюдалось следующее изменение метрики RMSE (таблица **??**):

4.5.3 Визуальное сравнение результатов

Визуальное сравнение карт глубины, полученных разными методами, представлено на рисунке **??**.

4.6 Анализ вычислительной эффективности

Анализ времени обработки показал существенные различия между методами. Средние значения времени обработки одного изображения размером 640×480 пикселей на компьютере с процессором Intel Core i7-10700K и GPU NVIDIA RTX 3080 составили:

— Сегментационный метод: **0.162 секунды**

— MiDaS: 0.869 секунды

— Гибридный метод: 0.941 секунды

Сегментационный метод продемонстрировал значительное превосходство по скорости обработки, что делает его особенно привлекательным для обработки больших архивов фотографий.

4.7 Особенности применения методов для различных типов сцен

Дополнительный анализ показал, что эффективность методов существенно зависит от типа сцены:

— MiDaS показывает наилучшие результаты для современных фотографий с четкими деталями и хорошей освещенностью

— Сегментационный метод демонстрирует лучшую устойчивость при работе с низкоконтрастными изображениями и фотографиями с шумом

— Гибридный метод наиболее эффективен при работе со сценами, содержащими как чёткие элементы переднего плана, так и размытый фон

4.8 Выводы по результатам исследования

Проведенное исследование позволяет сделать следующие выводы:

1. На стандартных наборах данных с современными изображениями MiDaS демонстрирует наилучшую точность восстановления глубины, превосходя сегментационный метод на 20-30%.

2. При наличии эффектов старения на фотографиях преимущество нейросетевого подхода значительно снижается — сегментационный метод показывает высокую устойчивость к шуму и искажениям цветового баланса.

3. Сегментационный метод превосходит конкурентов по скорости работы в 5-6 раз, что критически важно при обработке больших архивов фотографий.

4. Гибридный метод представляет собой сбалансированное решение, сочетающее устойчивость к эффектам старения с относительно высокой точностью, и может рассматриваться как оптимальный выбор для обработки архивных фотографий.

Результаты исследования подтверждают эффективность разработанного сегментационного метода для решения специализированной задачи восстановления глубины из архивных фотографий, несмотря на некоторое отставание от современных нейросетевых подходов на стандартных тестовых наборах.

ЗАКЛЮЧЕНИЕ

3Д–реконструкция, благодаря возможностям точного восстановления объектов и сцен в трёхмерном пространстве, является востребованным направлением и активно используется в различных областях, таких как робототехника, медицина, игры, киноиндустрия и многие другие. Интерес к этой темы выявил, что распространена лишь одна классификация методов 3Д-восстановления: разделение на активные и пассивные подходы [**stereosop2**; **sfm**; **structLight**; **ref1**]. С целью создание классификации, охватывающей большее количество характеристик и была подготовлена данная научно-исследовательская работа, в ходе которой:

— проведен анализ предметной области «обработка изображений» с акцентом на конвертации плоских снимков в 3Д модели;

— описаны основные методы конвертации 2Д изображений в 3Д, а именно: метод структурного освещения, глубины из размытия, стереосопоставления, структуры из движения и комфортной генерации глубины. Каждому методу приведены основные шаги их использования, особенности, и ограничения области применения;

— выделены критерии сравнения методов, и необходимые для реализации разных типов проектов;

— создана классификация описанных методов по выделенным критериям, которая необходима при выборе наиболее подходящего метода для конкретной задачи и значительно упрощает процесс принятия решений.

Таким образом, можно констатировать достижение поставленной цели научно-исследовательской работы.

parts/lib

ПРИЛОЖЕНИЕ А

Презентация к научно–исследовательской работе содержит 11 слайдов.