РЕФЕРАТ

Расчетно-пояснительная записка 66 с., 16 рис., 4 табл., 44 источн., 1 прил.

Ключевые слова: 3Д–реконструкция, построение карты глубин, методы структурного освещения, определения глубины из размытия (Depth from defocus), структуры из движения (Structure from motion), комфортной генерации глубины (Comfortable Depth Generation).

СОДЕРЖАНИЕ

РЕФЕРАТ **2**

ВВЕДЕНИЕ **4**

1 Аналитический раздел **6**

1.1 Метод структурного освещения 6

1.2 Метод определения глубины из размытия 10

1.3 Метод комфортной генерации глубины 11

1.4 Метод восстановления глубины на основе нейронных сетей . . . 13

1.5 Метод восстановления глубины по закраске изображения 14

1.6 Классификация методов восстановления глубины 15

1.7 Выбор метода восстановления глубины архивных фотографий . 17

1.8 Цель и постановка задачи 19

2 Конструкторский раздел **22**

2.1 IDEF-0 диаграммы 22

2.2 Схемы алгоритмов 23

3 Технологический раздел **31**

3.1 Выбор программных средств 31

3.2 Реализация метода 31

3.3 Описание входных и выходных данных 44

3.4 Тестирование 44

4 Исследовательский раздел **48**

4.1 Описание входных данных 48

4.2 Метрики оценки качества 49

4.3 Исследование устойчивости метода к деградации изображений . 50

4.4 Сравнительный анализ методов 52

ЗАКЛЮЧЕНИЕ **58**

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ **65**

ПРИЛОЖЕНИЕ А **66**

ВВЕДЕНИЕ

Актуальность разработки методов трехмерной реконструкции — технологии восстановления информации о глубине и пространственной структуре объектов и сцен на основе двумерных изображений [1], обусловлена их широким применением в различных областях:

— медицине [2—4],

— культуре и образовании [5; 6],

— промышленном производстве [7—9],

— индустрии развлечений [10—12] и

— системах компьютерного зрения [13—15].

Представленная выпускная квалификационная работа раскрывает один из аспектов 3–д реконструкции — восстановление глубины из монокулярных изображений. Это технология построения карты глубин — структуры данных, где каждой точке сцены поставлено в соответствие расстояние от нее до камеры [1]. На основе подобных карт становится возможным восстановление объемной структуры сцены и создание моделей объектов [1; 8; 10].

Особый интерес представляет работа с архивными фотографиями, которые зачастую являются единственными свидетельствами существования утраченных культурных объектов и архитектурных сооружений. Их преобразование в трехмерный формат открывает новые возможности для реализации исторических и образовательных проектов [5; 6; 16].

Объект исследования — восстановление трехмерной информации из монокулярных изображений.

Предмет исследования — метод восстановления глубины из монокулярного изображения, основанный на комбинации нейросетевого подхода и классического метода восстановления глубины по закраске изображения.

В основе работы лежит **гипотеза** о том, что гибридный метод реконструкции глубины, объединяющий преимущества нейросетевого подхода и классических алгоритмов, позволит создать решение, которое обеспечит как

общую точность восстановления геометрии сцены, так и детализацию отдельных элементов, сохраняя при этом устойчивость к дефектам, характерным для исторических изображений.

Целью работы является разработка гибридного метода восстановления трехмерной информации из архивных фотографий.

Для достижения поставленной цели необходимо решить следующие **задачи**:

— проанализировать существующие методы восстановления глубины из монокулярных изображений;

— разработать формальную модель гибридного метода, объединяющего нейросетевой подход и классический метод определения глубины по закраске изображения;

— реализовать программный прототип предложенного метода с использованием современных технологий обработки изображений;

— провести исследование влияния степени состаривания изображения на точность полученной карты глубин;

— сформулировать рекомендации по применению предложенного метода.

Результаты дипломного проекта могут найти практическое применение в создания виртуальных реконструкций исторических объектов и архивных материалов, представления их в современных цифровых форматах, с целью развития интереса к истории и культурному наследию.

1 Аналитический раздел

В области восстановления трехмерной формы объектов существует несколько подходов, каждый из которых обладает своими особенностями и сферами применения. Выбор метода зависит от требований к результату реконструкции, типа сцены, доступных данных и способов их получения.

В рамках данной работы будут рассмотрены методы восстановления глубины по единственному изображению:

— структурного освещения,

— определения глубины из размытия (Depth from defocus) [17],

— комфортной генерации глубины (Comfortable Depth Generation),

— на основе нейронных сетей,

— восстановления глубины по закраске (Structure From Shadowing) [18; 19].

Задачами данного раздела являются:

— обзор и сравнительный анализ существующих решений в области трехмерной реконструкции,

— формулировка цели работы,

— описание задач ВКР в виде функциональной модели.

1.1 Метод структурного освещения

В методе структурированного освещения используются различные типы световых паттернов, которые проецируются на поверхность объекта. Данные паттерны могут быть линейными, шахматными, градиентными и другими. Пример паттерна представлен на изображении 1.1.

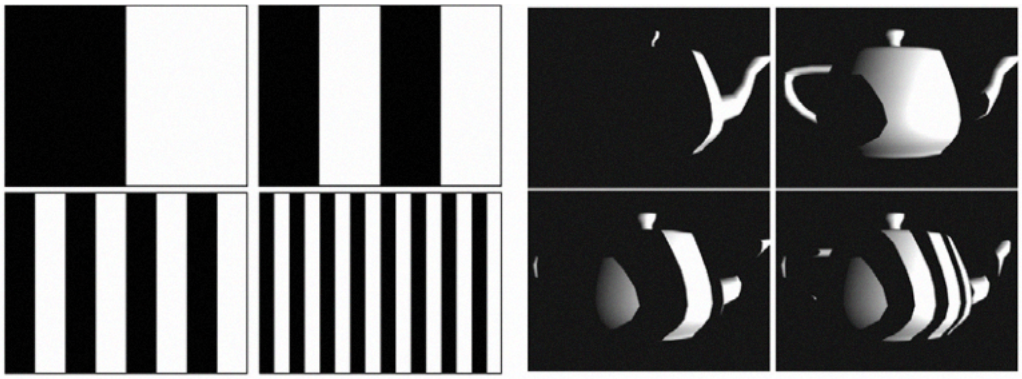


Рисунок 1.1 – Пример бинарных световых паттернов и освещенного с их помощью объекта [20].

Анализ искажений световых паттернов на поверхности объекта позволяет восстанавливать 3Д-геометрию объекта. Основная задача метода заключается в выполнении триангуляции для определения расстояния от камеры до каждой точки поверхности.

На рисунке 1.2 приведена схема установки.

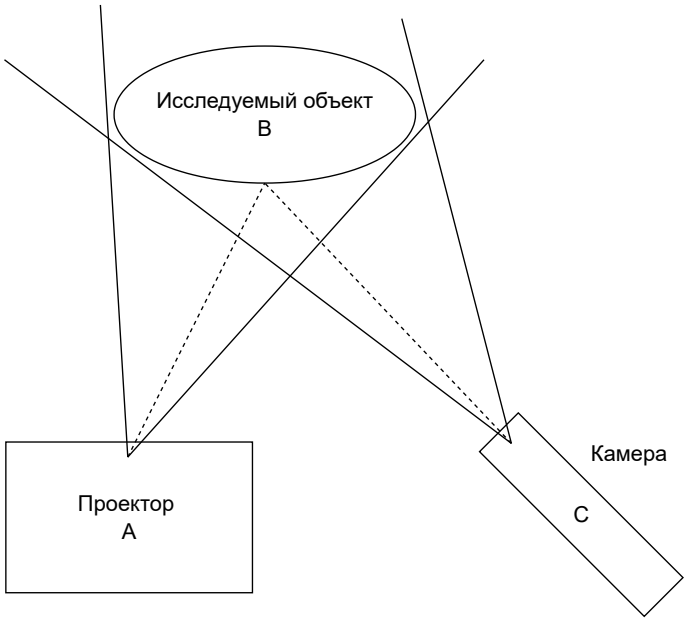


Рисунок 1.2 – Схема установки структурного освещения [20].

Создание карты глубин методом структурного освещения выполняется в несколько этапов [20].

1. **Калибровка камеры и проектора.** Определяются коэффициенты масштабирования (α_u, α_v), координаты оптического центра (x_0, y_0) и фокусное расстояние f.

2. **Проекция паттерна.** Проектор создает определенный световой шаблон (паттерн), который проецируется на исследуемую поверхность.

3. **Фиксация изображения.** Камера фиксирует и регистрирует искажения паттерна на поверхности объекта.

4. **Триангуляция.**

   4.1. **Вычисление углов.**

   Для вычисления расстояния от камеры до точки поверхности необходимо определить два угла треугольника $\triangle ACB$:

   — $\angle CAB$ — угол между направлением от камеры C к проектору A и направлением от камеры C к точке на поверхности B. Он вычисляется по формуле:

   $$\angle CAB = \arctan\left(\frac{x' - x_0}{f}\right),$$

   где x' — горизонтальная координата пикселя на изображении, x_0 — координата оптического центра камеры, а f — фокусное расстояние.

   — $\angle BCA$ — угол между направлением от точки B на поверхности к камере C и направлением от точки B к проектору A. Он вычисляется по формуле:

   $$\angle BCA = \arctan\left(\frac{y' - y_0}{f}\right),$$

   где y' — вертикальная координата пикселя на изображении, y_0 — координата оптического центра камеры, а f — фокусное расстояние.

   4.2. **Вычисление глубины** (BC) **для каждой точки поверхности.**

   Используется триангуляция для определения расстояния BC от камеры до точки поверхности объекта:

   $$BC = \frac{AC \cdot \sin(\angle CAB)}{\sin(\angle BCA)}, \tag{1.1}$$

где:

— AC — известное расстояние между камерой и проектором;

— $\angle CAB$ и $\angle BCA$ — углы треугольника $\triangle ACB$, вычисляемые на предыдущем шаге.

4.3. **Преобразование координат изображения из 2Д- в 3Д-пространство.**

Трёхмерные координаты точки поверхности (x, y, z) в системе камеры вычисляются по следующим формулам:

$$x = (x' - x_0) \cdot \frac{z}{\alpha_u}, \quad y = (y' - y_0) \cdot \frac{z}{\alpha_v}, \quad z = BC, \tag{1.2}$$

где:

— x', y' — пиксельные координаты точки на изображении;

— α_u, α_v — коэффициенты масштабирования камеры по горизонтали и вертикали;

— x_0, y_0 — координаты оптического центра камеры.

Метод структурного освещения позволяет создавать точные и детализированные карты глубин, что делает его незаменимым для решения задач, в которых требуется высокая точность в определении расстояний до объектов. Однако необходимым условием его использования является наличие специализированной лабораторной установки, включающей камеру и проектор с точной калибровкой. Такая установка требует стабильных условий и чувствительна к внешним факторам, таким как освещенность или движение объекта.

Кроме того, метод ограничен размером и геометрией исследуемого объекта. Структурированное освещение наиболее эффективно работает на объектах с относительно простой и ровной поверхностью. Для сложных, сильно текстурированных или отражающих объектов, качество получаемых данных значительно ухудшается из-за искажений паттернов, что требует дополнительных техник для их компенсации. Также метод неэффективен в условиях с ограниченным пространством, где сложно разместить проектор и камеру под нужным углом.

1.2 Метод определения глубины из размытия

Метод оценки расстояний с использованием дефокусировки (Depth from Defocus, DFD) основан на анализе размытия изображения в точках, соответствующих границам объектов. Предполагается, что перепад яркости на нерасфокусированном изображении границ объектов можно моделировать как ступенчатую функцию — функцию Хевисайда [21].

Процесс оценки размытия выполняется в несколько этапов [17].

1. **Выделение границ объектов.** На изображении выделяются границы объектов, где наблюдаются значительные перепады яркости. Эти границы служат ориентиром для дальнейшего анализа.

2. **Моделирование градиента яркости.** Оценивается градиент яркости на выделенных границах объектов. Этот шаг позволяет точно выявить изменения яркости, которые обусловлены дефокусировкой.

3. **Повторное размытие изображения.** На изображение наносится дополнительное размытие, после чего вычисляется новый градиент яркости на границах объектов. Это помогает уточнить степень дефокусировки, которая напрямую зависит от расстояния до объекта.

4. **Расчет параметра дефокусировки.** На основе измерений градиента яркости и моделирования размытия вычисляется параметр дефокусировки, который используется для определения расстояния до объекта.

Метод DFD показывает наилучшие результаты в случаях, когда есть возможность получить несколько снимков объекта с разными уровнями фокусировки. Однако, результативность данного метода зависит от качества и точности модели размытия, а также от разрешения камеры. В случае значительных искажений, например, при сильной дефокусировке или недостаточной контрастности на границах, результаты менее точные. Кроме того, для получения корректных результатов требуется тщательная настройка параметров камеры, таких как диафрагма и фокусное расстояние.

1.3 Метод комфортной генерации глубины

Метод комфортной генерации глубины представляет собой подход, который использует информацию о цветовых характеристиках блоков изображения для вычисления расстояния до объекта.

Процесс заключается в разбиении изображения на блоки, анализе их цветовых характеристик и применении минимальных остовных деревьев [22] для вычисления глубины.

Выделяют несколько основных этапов метода комфортной генерации глубины [23].

1. **Разбиение изображения на блоки.** Изображение делится на блоки размером 4x4 пикселя, что позволяет упростить задачу обработки изображения и снизить вычислительную сложность.

2. **Вычисление среднего цвета для каждого блока.** Для каждого блока вычисляется среднее значение цвета (mean(a)), что представляет собой характеристику блока, на основе которой будет строиться граф для дальнейшей обработки.

3. **Построение графа.** Изображение представляется как неориентированный граф $G(V, E)$, где:

   — V — вершины графа, которые соответствуют блокам изображения;

   — E — ребра графа с весами, которые рассчитываются как абсолютное различие средних значений цвета между соседними блоками, то есть $|\text{mean(a)} - \text{mean(b)}|$.

4. **Построение минимального остовного дерева.** На основе построенного графа применяется алгоритм Прима [24] для нахождения минимального остовного дерева. Этот шаг помогает упорядочить блоки по их взаимному сходству и устанавливает структуру для дальнейшего анализа.

5. **Разрезание дерева.** После построения минимального остовного дерева выполняется его разрезание по ребрам с большими весами, что помогает выделить сегменты изображения, которые могут быть интерпретированы как части с различной глубиной.

6. **Выбор базового градиента глубины.** Из анализа прямых линий на изображении выбирается один из базовых градиентов глубины. Для этого используются параметры Wrl и Wud, которые характеризуют градиент в двух направлениях (горизонтальном и вертикальном). При этом выполняется условие $|Wrl| + |Wud| = 1$.

7. **Вычисление глубины сегмента.** Для каждого сегмента изображения глубина вычисляется как среднее значение глубины всех пикселей в сегменте.

На рисунке 1.3 приведен пример обработки одного блока изображения.

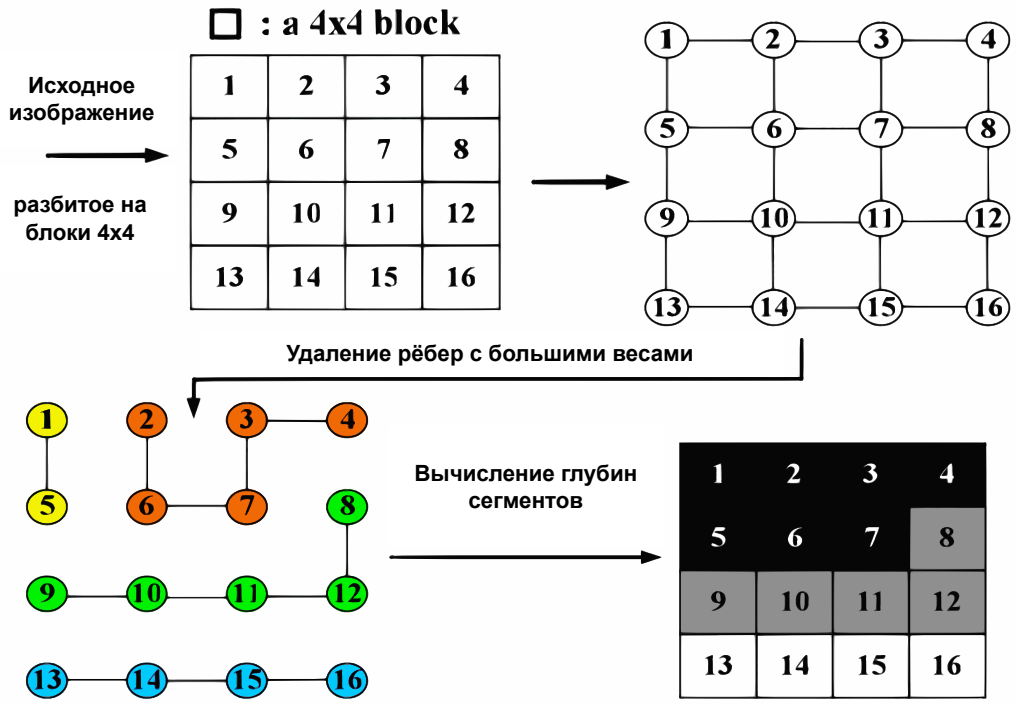


Рисунок 1.3 – Обработка блока изображения [23].

Метод комфортной генерации глубины предполагает разбиение изображения на независимые части, что позволяет обрабатывать данные параллельно. Этот подход отличается универсальностью применения, поскольку может обрабатывать как локальные, так и глобальные сцены, не требуя при этом дополнительной информации или специального подхода к сбору данных.

Однако, метод Comfortable Depth Generation имеет некоторые ограничения, связанные с качеством исходных изображений. Низкое качество

или низкая контрастность изображения снижает точность получаемой глубины. Кроме того, фиксированный размер блоков (4x4 пикселя) ограничивает точность при обработке изображений с детализированными структурами, требующими разделение на более мелкие части. В случае с изображениями, содержащими гладкие или однотонные текстуры, блоки имеют схожие цветовые характеристики, что затрудняет выделение различных глубинных уровней.

1.4 Метод восстановления глубины на основе нейронных сетей

Методы восстановления глубины на основе нейронных сетей используют глубокое обучение для выявления сложных статистических закономерностей между визуальными признаками 2D-изображения и соответствующими значениями глубины [25; 26].

Алгоритмы монокулярной оценки глубины можно разделить на несколько категорий в зависимости от их архитектуры и подходов [26]. Первая категория — это предсказание глубины на основе свёрточных нейронных сетей (CNN) [26; 27]. Свёрточные нейронные сети применяются для прямого предсказания карты глубин из изображения. Обычно этот процесс заключается в обучении сети на наборах данных, содержащих пары изображений и соответствующих им карт глубин, что позволяет модели эффективно улавливать глубинные характеристики сцены.

Второй тип архитектур — это кодировщик-декодировщик, в которых кодировщик отвечает за извлечение признаков из изображения, а декодировщик использует эти признаки для восстановления карты глубин [26; 28]. Такая структура позволяет более эффективно моделировать сложные зависимости в изображениях, что повышает точность результата [26].

Одним из представителей нейросетевых методов является модель MiDaS, предназначенная для оценки глубины на основе одиночных изображений, которая характеризуется гибридной архитектурой, объединяющей элементы кодера-декодера в рамках свёрточной нейронной сети [26; 28].

MiDaS обучен на комбинированных наборах данных, что обеспечивает его универсальность для разных типов сцен и устойчивость к шумам и артефактам. Кроме того, важным преимуществом является отсутствие необ-

ходимости в знании точных параметров камеры и какой-либо дополнительной информации. Однако, как и метод Comfortable Depth Generation, нейросетевые подходы ориентированы на восстановление общей структуры глубины, упуская детали поверхностей.

1.5 Метод восстановления глубины по закраске изображения

Метод Shape from Shading (SFS) — это подход к восстановлению трехмерной формы объекта на основе анализа распределения интенсивности света и теней на двумерном изображении. Этот метод базируется на физических принципах отражения света от поверхностей объектов.

Восстановление формы по закраске производится в несколько этапов [29].

1. **Определение модели освещения.** Для анализа используется модель отражения, описывающая взаимосвязь между интенсивностью пикселя, нормалью к поверхности и направлением падающего света. Чаще всего применяется ламбертовская модель освещения:

$$I(x, y) = \rho(x, y) \cdot L \cdot N(x, y), \tag{1.3}$$

   где $I(x, y)$ — интенсивность пикселя, $\rho(x, y)$ — альбедо поверхности, L — направление источника света, $N(x, y)$ — нормаль к поверхности.

2. **Разделение альбедо и затенения.** Анализируется изменение яркости изображения для отделения свойств материала (альбедо) от эффектов затенения, вызванных геометрией поверхности. Альбедо характеризует собственный цвет и отражательную способность материала.

3. **Вычисление нормалей поверхности.** На основе интенсивности пикселей и модели освещения вычисляются нормали к поверхности в каждой точке. Для каждого пикселя определяется вектор нормали $N(x, y)$, перпендикулярный к касательной плоскости поверхности.

4. **Интеграция нормалей.** Для получения карты глубин выполняется интеграция поля нормалей. Этот процесс можно представить как решение

следующего уравнения:

$$\nabla Z(x, y) = f(N(x, y)), \tag{1.4}$$

где $Z(x, y)$ — искомая карта глубины, а f — функция, преобразующая нормали в градиент глубины.

5. **Применение регуляризации.** Для преодоления неоднозначности решения и устранения шумов используются методы регуляризации, которые вводят дополнительные ограничения на гладкость поверхности.

Метод SFS обладает рядом преимуществ, ключевым из которых является возможность восстановления 3D-формы объекта по одиночному изображению. Это делает его применимым для работы с историческими фотографиями, когда невозможно получить несколько ракурсов объекта [30].

Однако метод имеет существенные ограничения. Во-первых, он требует точного знания параметров освещения, которые часто недоступны для архивных фотографий. Во-вторых, базовая модель предполагает однородность материала поверхности, что редко встречается в реальных сценах. В-третьих, метод дает неоднозначные результаты, поскольку различные 3D-формы могут создавать схожие паттерны затенения [31].

1.6 Классификация методов восстановления глубины

На основе проведенного анализа предметной области были определены несколько ключевых критериев сопоставления рассмотренных методов.

1. **Способ получения данных** — активный или пассивный подход к сбору информации.

   Предложенный критерий учитывает подход к сбору исходных данных. Активные методы, такие как лазерное сканирование, требуют использования специализированного оборудования, что предполагает проведение исследований в лабораторных условиях. Пассивные методы, напротив, работают с доступными изображениями. Применение данного критерия позволяет своевременно оценить необходимые условия получения исходных изображений.

2. **Дополнительная информация** — данные о положении камер, временных метках и других параметрах.

   Необходимость в дополнительной информации ограничивает область применения метода и может предполагать наличие дополнительных компетенций для их использования, например, при настройке параметров камеры.

3. **Результат** — итоговый объект реконструкции (карта глубин, информация о структуре объекта).

   Базовым результатом является карта глубин, однако некоторые методы предоставляют дополнительную информацию: форма объекта, нормали к поверхностям. Эти дополнительные данные могут быть критически важны для полноценной трёхмерной реконструкции сцены.

4. **Масштаб сцены** — локальная или глобальная реконструкция.

   Масштаб сцены определяет применимость метода к задачам разного уровня: от реконструкции небольших объектов до глобальных ландшафтов.

5. **Уровень автоматизации** — степень автоматизированности процесса реконструкции: от ручных до автоматических методов.

   Уровень автоматизации влияет на затраты времени и ресурсов. Автоматизированные методы предпочтительны для задач, требующих быстрой обработки больших объемов данных, тогда как ручные обеспечивают больше контроля в специфических сценариях.

Данные критерии позволяют выбрать наиболее подходящий метод восстановления глубины в зависимости от поставленной задачи, доступных возможностей и особенностей предметной области.

В таблице 1.1 приведена классификация методов восстановления глубины.

Метод	Способ получения данных	Доп. информация	Результат	Масштаб сцены	Уровень автоматизации
Метод структурного освещения	Активный	Проекция шаблона	Карта глубин, форма объекта	Локальные	Ручные
DFD	Активный или пассивный	Параметры настройки камеры	Карта глубин	Локальные	Автономные
Shape from Shading (SFS)	Пассивный	Параметры освещения	Карта глубин, нормали поверхности	Локальные	Полу-автономные
Comfortable depth generation	Пассивный	-	Карта глубин	Локальные или глобальные	Автономные
MiDaS	Пассивный	-	Карта глубин	Локальные или глобальные	Автономные

Таблица 1.1 – Классификация методов восстановления глубины из монокулярных изображений

1.7 Выбор метода восстановления глубины архивных фотографий

При выборе метода для восстановления глубины из старинных фотографий необходимо учитывать их специфические особенности и ограничения.

1. **Ограниченность исходных данных**. Для архивных фотографий доступны только одиночные изображения, отсутствует возможность получения стереопар или последовательностей с разных ракурсов.

2. **Отсутствие метаданных**. Архивные фотографии не содержат инфор-

мации о параметрах съемки, калибровке камеры или условиях освещения.

3. **Качество изображений**. Старинные фотографии часто имеют низкое качество, шумы, артефакты, выцветание и повреждения, что затрудняет автоматическую обработку.

Исходя из представленной классификации, рассмотрим применимость каждого метода.

Метод структурированного освещения и **DFD** требуют активного вмешательства при съемке или специальных параметров камеры, что делает их неприменимыми для архивных фотографий.

Shape from Shading работает с моноизображениями и может восстанавливать форму объектов на основе анализа теней и освещения. Однако метод имеет существенные ограничения: необходимость в параметрах освещения, которые невозможно достоверно определить для архивных фотографий, и применимость преимущественно к локальным сценам с четко выраженными текстурами и тенями. Тем не менее, возможна разработка адаптированного алгоритма, в котором параметры освещения оцениваются на основе самого изображения, а область применения включает более сложные сцены за счет сегментации изображения.

Comfortable depth generation представляется подходящим методом, поскольку он работает с моноизображениями и не требует дополнительной информации. Однако, для архивных фотографий с их специфическими искажениями нейросетевые подходы предположительно демонстрируют более высокую устойчивость и точность.

Нейросетевые методы, в частности MiDaS, представляются наиболее подходящим решением, поскольку они:

— работают с одиночными изображениями,

— не требуют дополнительной информации о сцене или камере,

— обеспечивают полностью автоматическую обработку,

— демонстрируют высокую точность на разнообразных сценах благодаря обучению на больших наборах данных,

— эффективно работают как с локальными, так и с глобальными сценами, хотя качество детализации при работе с глобальными сценами снижается.

Таким образом, для повышения качества результатов разумно использовать гибридный подход: комбинировать **нейросетевой метод** (MiDaS) для получения базовой карты глубин с элементами **Shape from Shading** для улучшения детализации в областях с выраженной текстурой и тенями.

При этом необходимо учитывать особенности архивных фотографий, реализовав предварительную обработку для устранения артефактов и повреждений, снижения шума, повышения контраста, восстановления насыщенности и других параметров изображения.

1.8 Цель и постановка задачи

Целью данной работы является разработка метода восстановления трехмерной глубины из архивных фотографий путем создания гибридного алгоритма, объединяющего преимущества нейросетевого метода и Shape from Shading, с учетом специфических особенностей исторических изображений.

Формально задачу восстановления карты глубины из архивной фотографии можно представить как функциональную модель:

$$D = F(I, P), \tag{1.5}$$

где:

— $D : \mathbb{R}^2 \to \mathbb{R}$ — искомая карта глубин, сопоставляющая каждой точке (x, y) изображения значение глубины;

— $I : \mathbb{R}^2 \to \mathbb{R}^3$ — исходное изображение, представленное как функция, сопоставляющая каждой точке (x, y) цвет в формате RGB;

— P — набор параметров алгоритма;

— F — оператор преобразования, реализующий гибридный метод.

Оператор F представляет собой композицию следующих функций:

$$F = F_{\text{post}} \circ F_{\text{hybrid}} \circ F_{\text{pre}}, \tag{1.6}$$

где:

— $F_{\text{pre}} : \mathbb{R}^2 \times \mathbb{R}^3 \to \mathbb{R}^2 \times \mathbb{R}^3$ — функция предобработки, выполняющая шумоподавление, коррекцию яркости и контраста;

— $F_{\text{hybrid}} : \mathbb{R}^2 \times \mathbb{R}^3 \to \mathbb{R}^2 \times \mathbb{R}$ — гибридная функция, объединяющая методы MiDaS и SFS;

— $F_{\text{post}} : \mathbb{R}^2 \times \mathbb{R} \to \mathbb{R}^2 \times \mathbb{R}$ — функция постобработки, выполняющая сглаживание и нормализацию карты глубин.

Гибридная функция F_{hybrid} определяется как:

$$F_{\text{hybrid}}(I) = \alpha_{map} \cdot F_{\text{MiDaS}}(I) + (1 - \alpha_{map}) \cdot F_{\text{SFS}}(I), \tag{1.7}$$

где:

— F_{MiDaS} — базовая карта глубин, полученная методом MiDaS;

— F_{SFS} — карта деталей, полученная методом Shape from Shading;

— $w_{detail}(x, y)$ — карта весов деталей, определяющая их значимость;

— $\alpha_{map}(x, y)$ — адаптивный весовой коэффициент, уменьшающийся в областях с высокой детализацией.

Вывод

В аналитической части работы проведен обзор существующих способов восстановления глубины по единственной фотографии, а именно методы структурного освещения, Depth from defocus, Shape from Shading, Comfortable Depth Generation и нейросетевые методы, такие как MiDaS.

Рассмотренные подходы классифицированы по ключевым критериям: способу получения данных, необходимости в дополнительной информации, результатам реконструкции, масштабу сцены и уровню автоматизации.

Проведенный анализ позволяет сделать вывод, что оптимальным решением для восстановления глубины из архивных фотографий является гибридный метод, объединяющий преимущества нейросетевого подхода (MiDaS) и классического метода Shape from Shading. Такой подход обеспечивает как общую точность восстановления геометрии сцены, так и детализацию отдельных

элементов, сохраняя при этом устойчивость к дефектам, характерным для исторических изображений.

Представленное формализованное описание задач в виде функциональной модели, включающей блоки предобработки, гибридного восстановления и постобработки, формируют теоретическую основу для разработки практического решения в следующих разделах работы.

2 Конструкторский раздел

В данном разделе формализована структура разработанного метода, описана алгоритмическая основа функциональных блоков и их взаимодействия в рамках единой системы.

Структура решения представлена в виде IDEF0–диаграммы и подробных схем для каждого этапа обработки: предварительной подготовки изображений, сегментации, оценки освещения, разделения альбедо и затенения, расчета нормалей к поверхности и итогового восстановления трехмерной информации.

2.1 IDEF-0 диаграммы

На рисунке 2.1 представлена диаграмма IDEF0 уровня A0 разработанного метода.

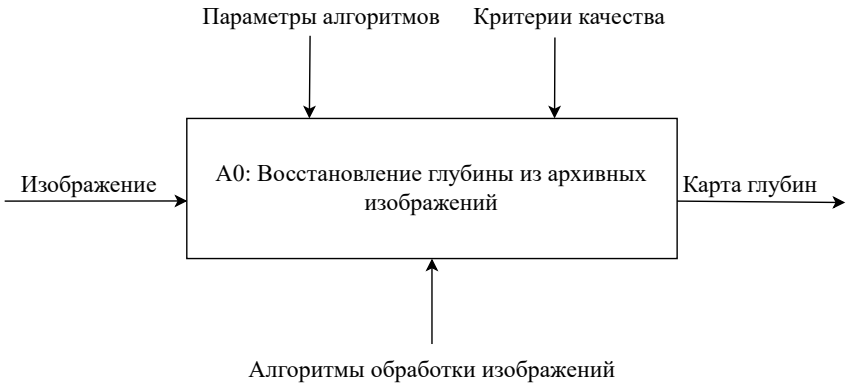


Рисунок 2.1 – IDEF0-диаграмма уровня A0

Диаграмма нулевого уровня представляет всю систему как единый блок с указанием входов, выходов, управления и механизмов. Входными данными системы являются архивные фотографии, выходными — восстановленная карта глубин.

На рисунке 2.2 показана декомпозиция функционального блока A0, детализирующая основные процессы обработки изображений.

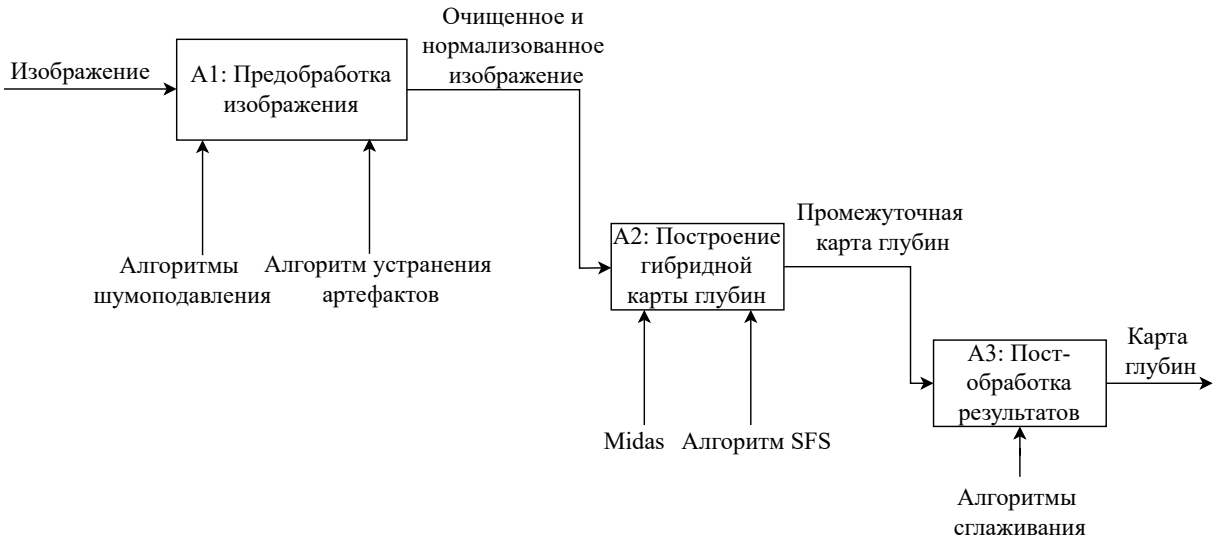


Рисунок 2.2 – IDEF0-диаграмма уровня A1

Диаграмма уровня A1 визуализирует три основных функциональных блока системы: предобработка, гибридное восстановление и постобработка. Отражены их взаимосвязи, потоки данных между блоками, управляющие воздействия и используемые механизмы.

2.2 Схемы алгоритмов

На рисунке 2.3 представлена схема предварительной обработки входного изображения, включающая методы шумоподавления, нормализации освещения и коррекции артефактов, характерных для архивных фотографий.

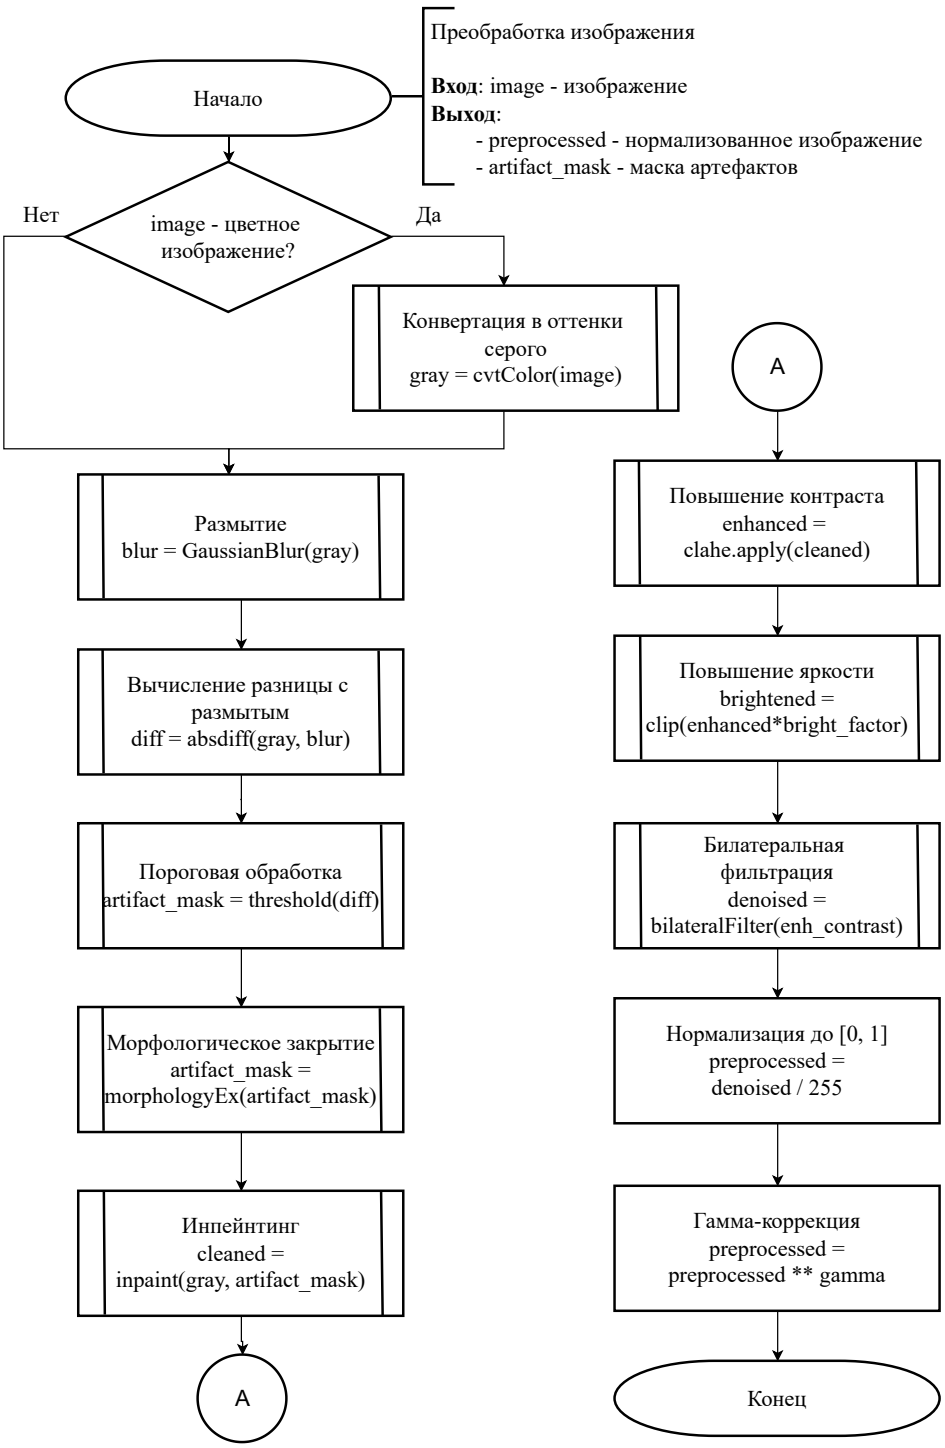


Рисунок 2.3 – Преобработка изображения

Рисунок 2.4 иллюстрирует основной алгоритм извлечения глубины, который объединяет нейросетевой метод для первичной оценки глубины с последующим уточнением деталей.

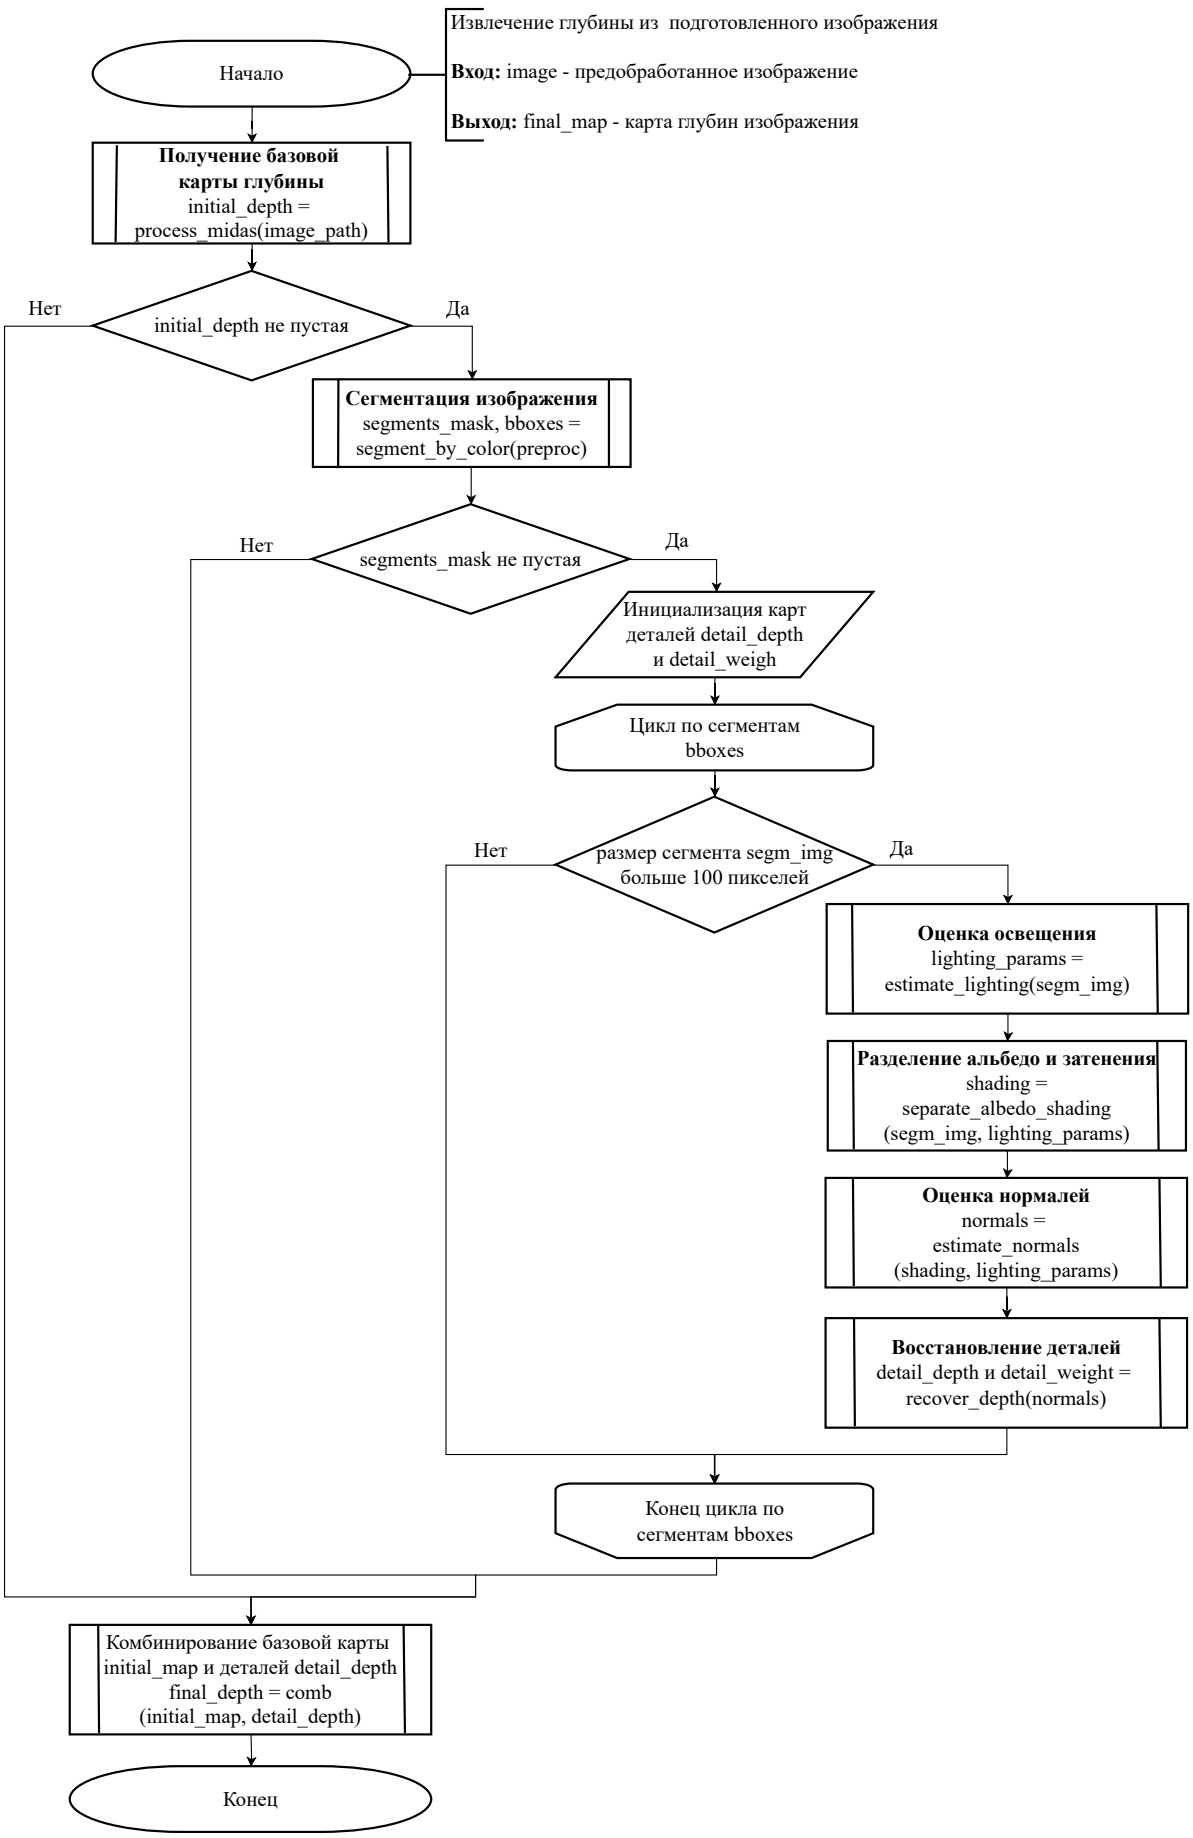


Рисунок 2.4 – Извлечение глубины из подготовленного изображения

Схема на рисунке 2.5 отражает процесс сегментации изображения, позволяющий выделить различные объекты сцены для их дальнейшей раздельной обработки методом Shape From Shading.

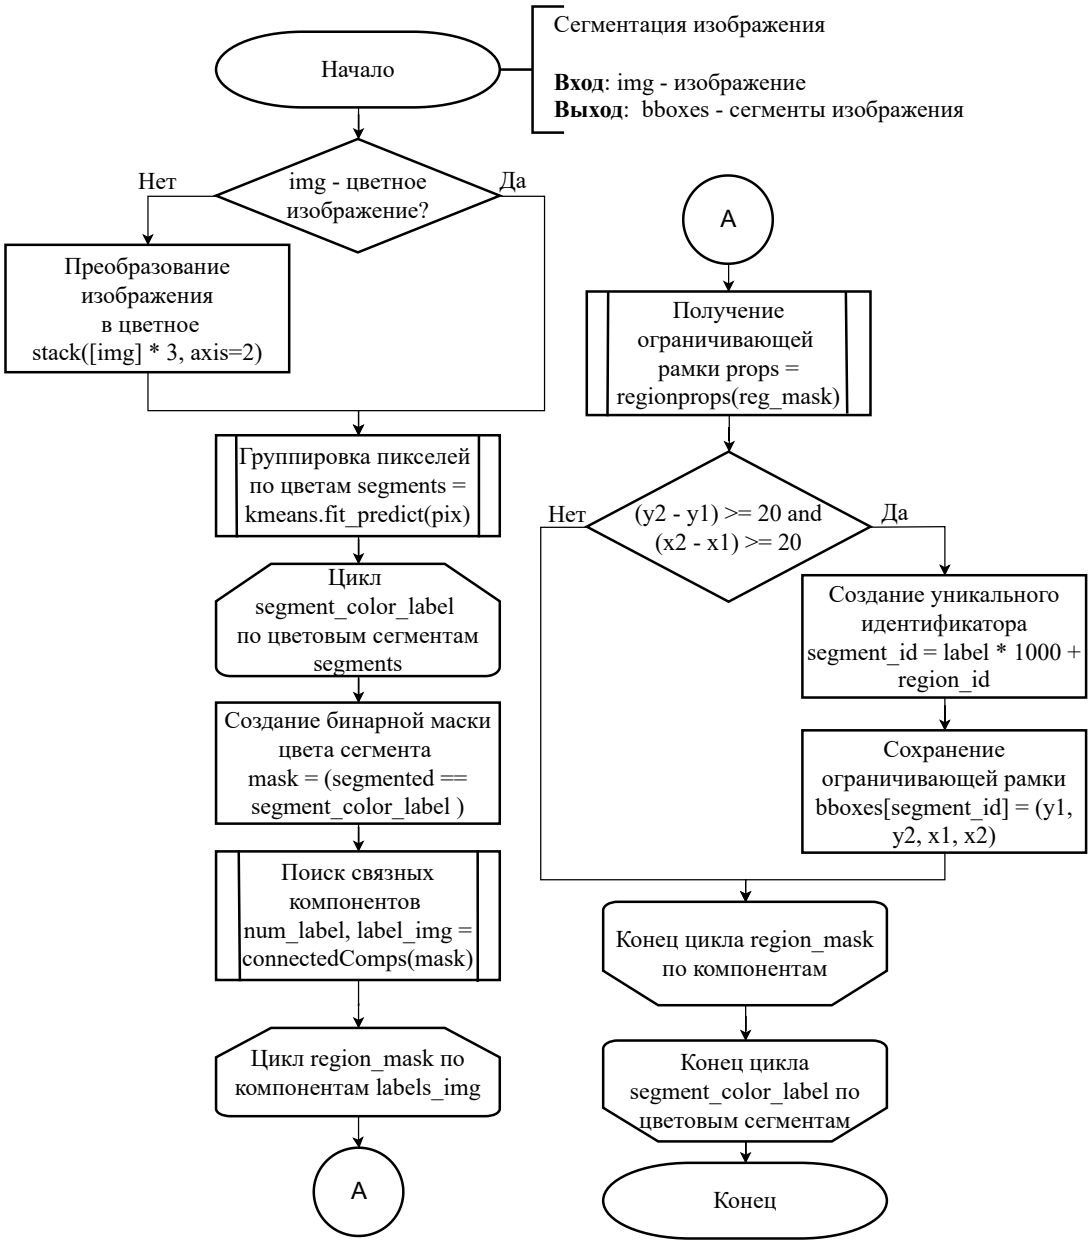


Рисунок 2.5 – Сегментация изображения

На рисунке 2.6 представлен алгоритм оценки параметров освещения сцены, необходимых для корректного применения метода Shape from Shading.

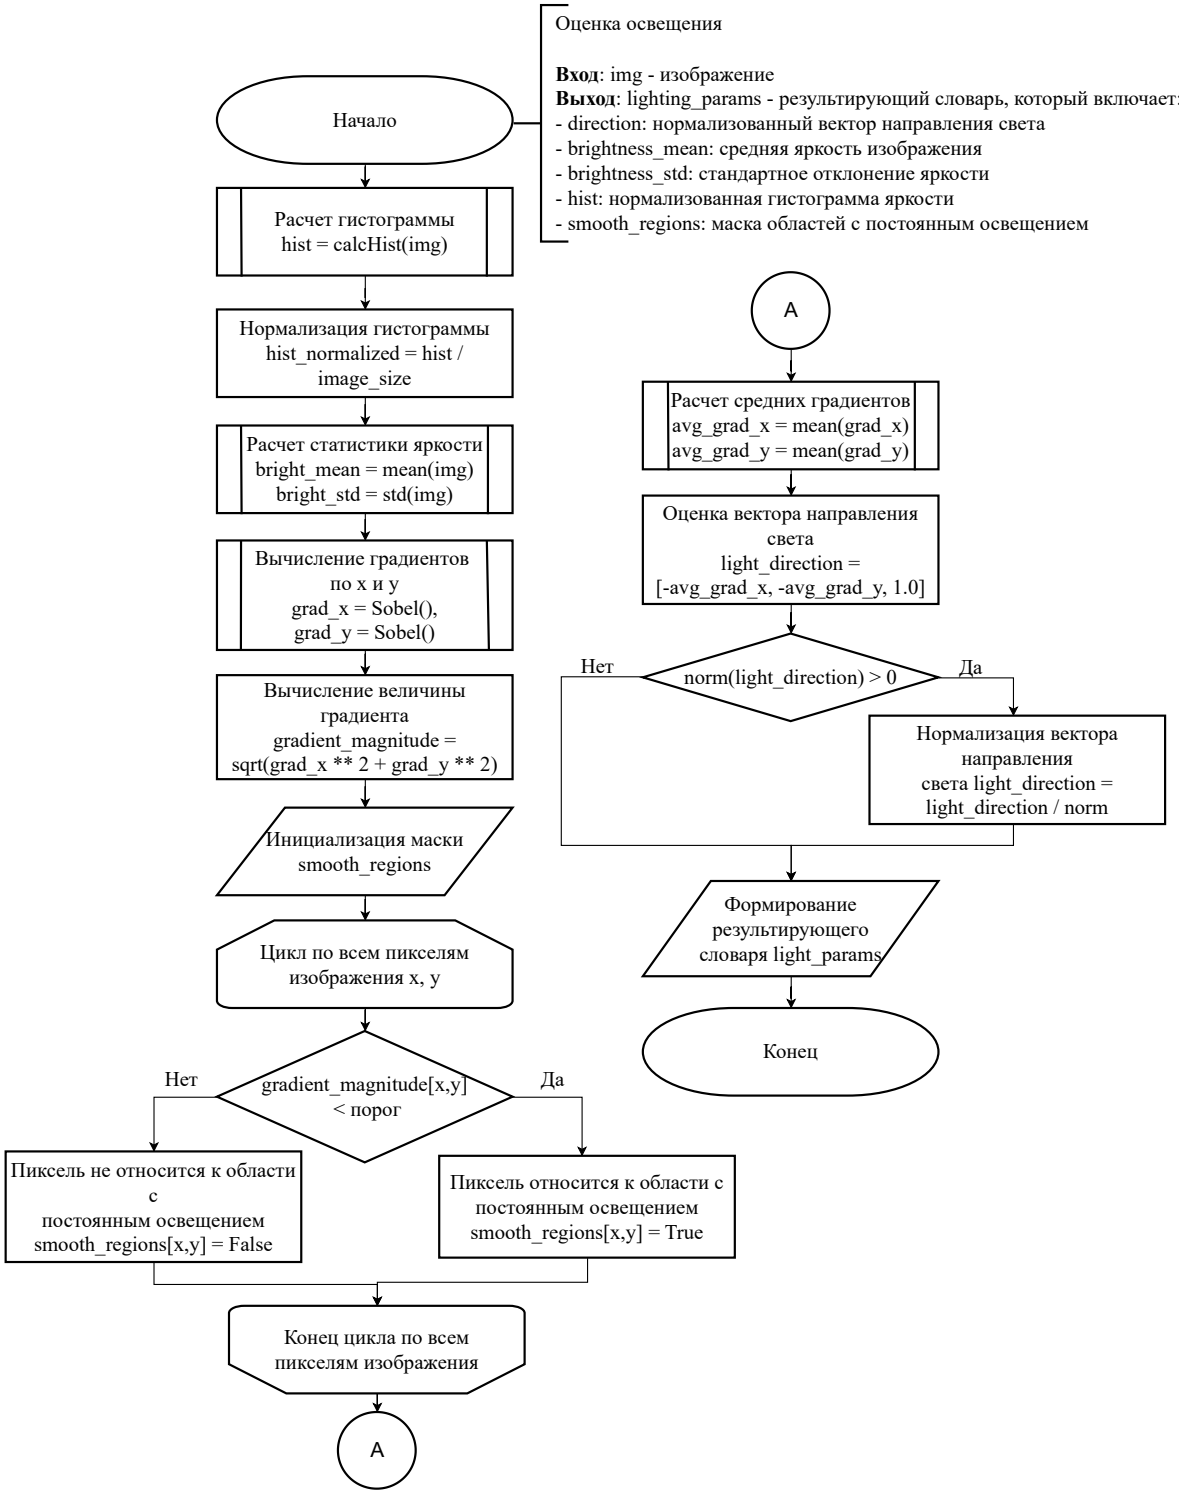


Рисунок 2.6 – Оценка освещения

Рисунок 2.7 демонстрирует процесс разделения альбедо и затенения метода Shape from Shading, позволяющий отделить собственные цвета поверхностей от эффектов освещения.

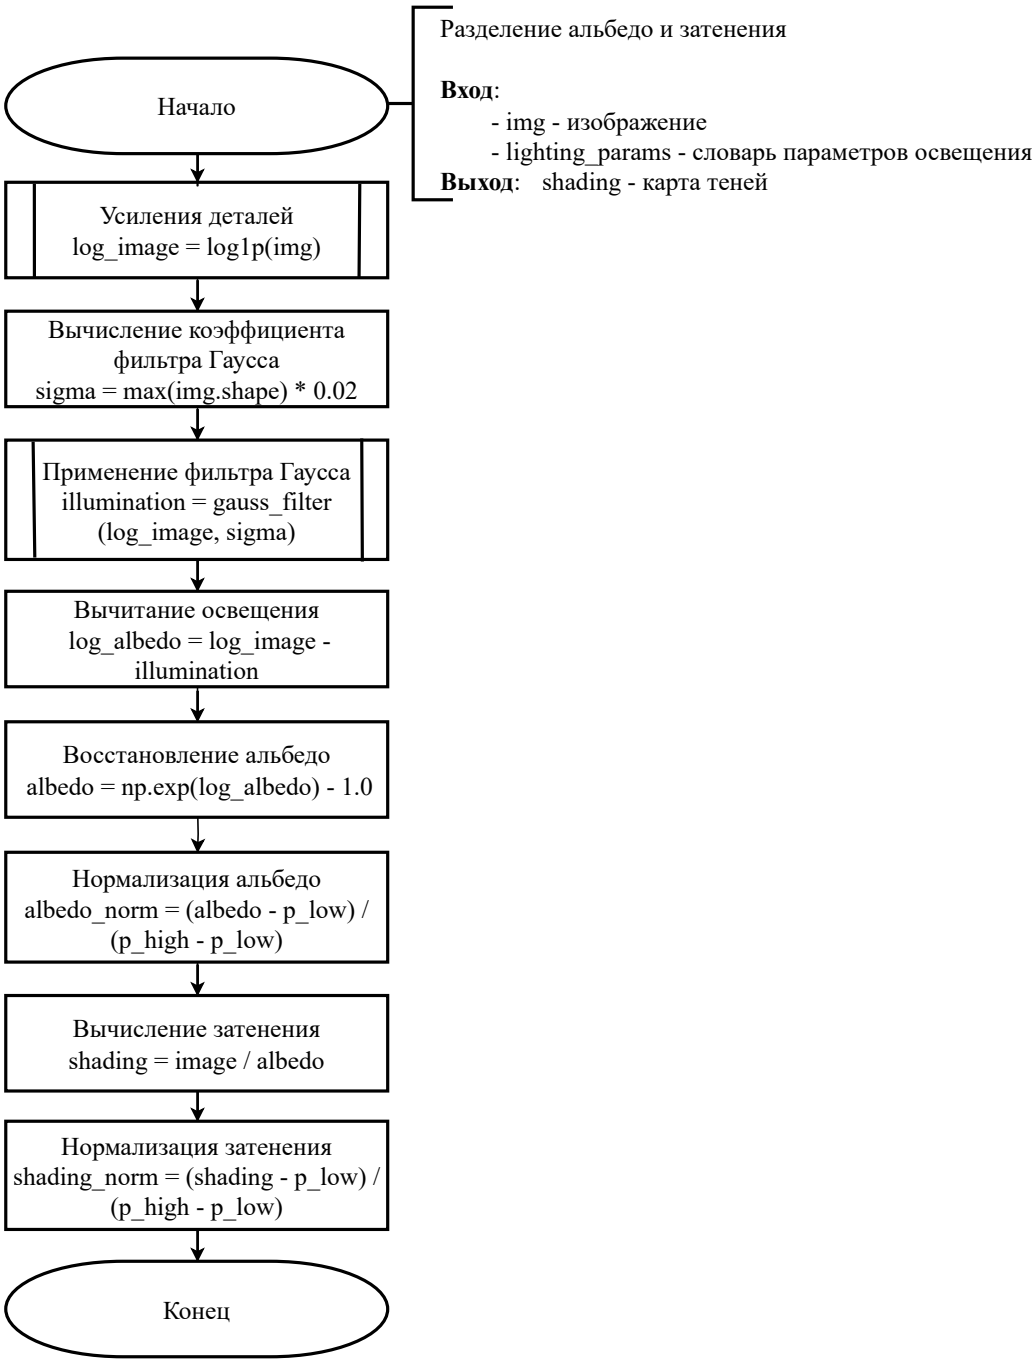


Рисунок 2.7 – Разделение альбедо и затенения

Схема на рисунке 2.8 описывает алгоритм вычисления нормалей к поверхности на основе полученного разделения альбедо и затенения.

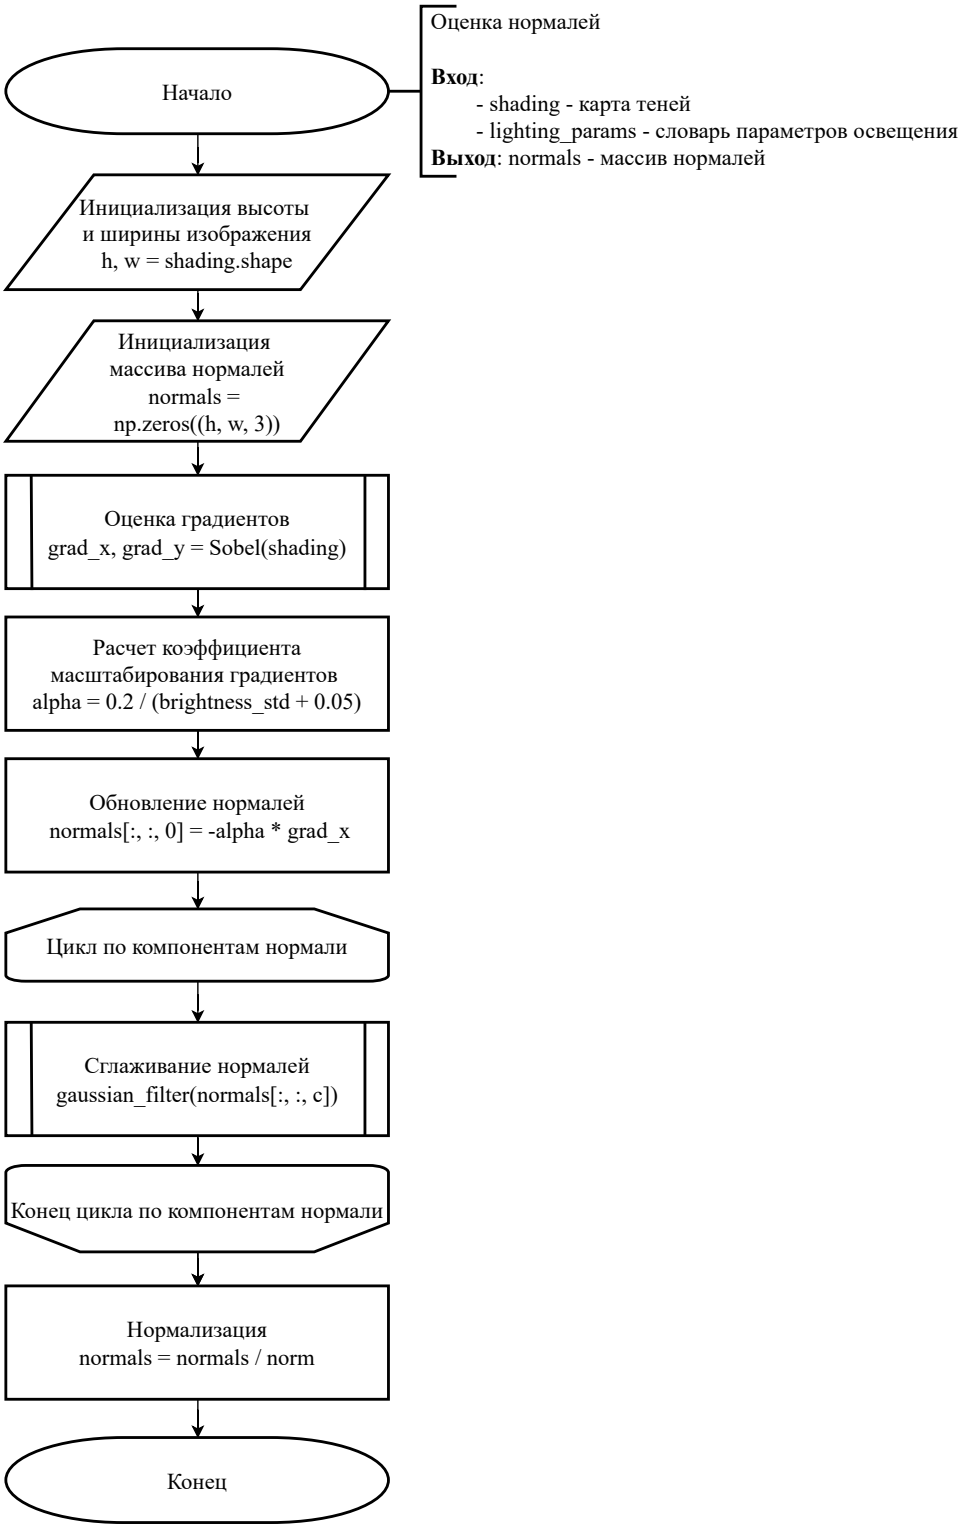


Рисунок 2.8 – Оценка нормалей

Заключительный этап обработки представлен на рисунке 2.9 — алгоритм интеграции поля нормалей для получения итоговой карты глубин с высоким уровнем детализации поверхностей.

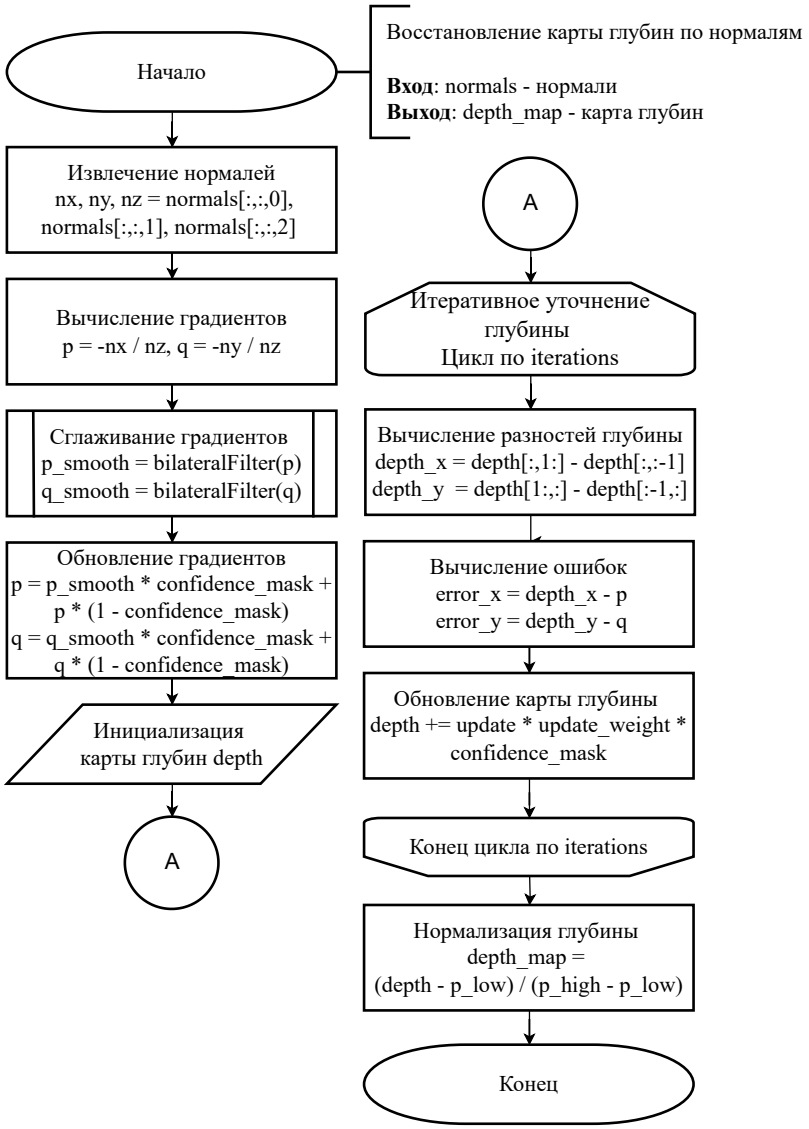


Рисунок 2.9 – Восстановление карты глубин по нормалям

Вывод

В конструкторском разделе представлена детальная структура разработанного гибридного метода восстановления трехмерной информации из архивных фотографий.

Представленные схемы алгоритмов являются основой для последующей программной реализации метода, которая будет рассмотрена в технологическом разделе работы.

3 Технологический раздел

Технологический раздел посвящен практической реализации гибридного метода восстановления глубины из монокулярных изображений. В данном разделе рассматриваются ключевые аспекты программной реализации и тестирования разработанного решения. Особое внимание уделяется обоснованию выбора программных средств и библиотек, необходимых для реализации алгоритмов.

3.1 Выбор программных средств

Для реализации методов восстановления глубины из монокулярных изображений был выбран язык программирования Python. Этот выбор обусловлен наличием в его экосистеме всех необходимых инструментов для комплексного решения поставленных задач, а именно:

— OpenCV [32], scikit-image [33] и PIL/Pillow [34] для обработки изображений, включая фильтрацию, сегментацию и работу с различными форматами файлов;

— PyTorch [35] и scikit-learn [36] для применения предобученной модели MiDaS, что исключает необходимость обучения собственной нейронной сети;

— NumPy [37], SciPy [38], Matplotlib [39] и Open3D [40] организуют работу с многомерными массивами, визуализацию результатов и обработку трехмерных данных.

Таким образом, совокупность доступных инструментов Python делает его достаточным инструментом для решения всех аспектов задачи восстановления глубины монокулярного изображения.

3.2 Реализация метода

В листинге 3.1 представлен код предварительной обработки входного изображения, включающий методы шумоподавления, нормализации освещения и коррекции артефактов, характерных для архивных фотографий.

Листинг 3.1 – Предварительная обработка изображения

```
import cv2
import numpy as np


def preprocess_archival_photo(image_path, brightness_boost=1.5,
    contrast_boost=1.2):
    if isinstance(image_path, str):
        image = cv2.imread(image_path)
        if image is not None and len(image.shape) == 3:
            image = cv2.cvtColor(image, cv2.COLOR_BGR2RGB)
    else:
        image = image_path.copy()

    # Проверяем, является ли изображение цветным или оттенков сер
        ого
    if len(image.shape) == 3:
        gray = cv2.cvtColor(image, cv2.COLOR_RGB2GRAY)
    else:
        gray = image.copy()

    # Выявление и маскирование дефектов
    blur = cv2.GaussianBlur(gray, (5, 5), 0)
    diff = cv2.absdiff(gray, blur)
    _, artifact_mask = cv2.threshold(diff, 25, 255,
        cv2.THRESH_BINARY)

    kernel = np.ones((3, 3), np.uint8)
    artifact_mask = cv2.morphologyEx(artifact_mask,
        cv2.MORPH_CLOSE, kernel)
    artifact_mask = cv2.dilate(artifact_mask, kernel,
        iterations=1)

    # Инпейнтинг для удаления дефектов
    cleaned = cv2.inpaint(gray, artifact_mask.astype(np.uint8),
        3, cv2.INPAINT_TELEA)

    # Повышение контраста
    clahe = cv2.createCLAHE(clipLimit=2.0, tileGridSize=(8, 8))
    enhanced = clahe.apply(cleaned)

```

```
35      # Повышение яркости
36      mean_brightness = np.mean(enhanced)
37      target_brightness = 80
38
39      brightness_factor = min((target_brightness /
            (mean_brightness + 1e-6)), brightness_boost)
40      brightened = np.clip(enhanced * brightness_factor, 0,
            255).astype(np.uint8)
41
42      # Улучшение контраста
43      alpha = min(contrast_boost, 1.1)
44      beta = 128 * (1 - alpha)
45      enhanced_contrast = np.clip(alpha * brightened + beta, 0,
            255).astype(np.uint8)
46
47      # Билатеральная фильтрация для сохранения краев при устранени
            и шума
48      denoised = cv2.bilateralFilter(enhanced_contrast, 7, 25, 25)
49
50      # Нормализация до [0, 1]
51      preprocessed = denoised.astype(np.float32) / 255.0
52
53      # Гамма-коррекция для улучшения контраста в средних тонах
54      gamma = 1.1
55      preprocessed = np.power(preprocessed, gamma)
56
57      return preprocessed, artifact_mask
```

Листинг 3.2 иллюстрирует основной алгоритм извлечения глубины, который объединяет нейросетевой метод для первичной оценки глубины с последующим уточнением деталей.

Листинг 3.2 – Извлечение глубины из подготовленного изображения

```
import numpy as np
import cv2

from scipy.ndimage import gaussian_filter, sobel

def depth_extract(self, image_path):

    # Шаг 1: Получение базовой карты глубины
    print("Получение базовой карты глубины через MiDaS...")
    midas_results = self.process_midas(image_path)
    base_depth = midas_results['depth_map']
    preprocessed = midas_results['preprocessed']
    artifact_mask = np.zeros_like(preprocessed, dtype=np.uint8)

    # Шаг 2: Сегментация изображения
    print("Сегментация изображения для детализации...")
    segments_mask, bboxes = segment_by_color(
        preprocessed,
        self.n_color_segments
    )

    # Шаг 3: Инициализация карт деталей
    detail_depth = np.zeros_like(base_depth)
    detail_weight = np.zeros_like(base_depth)

    # Шаг 4: Цикл по сегментам
    print("Детализация каждого сегмента...")
    for segment_id, bbox in bboxes.items():
        y1, y2, x1, x2 = bbox

        segment_mask = (segments_mask[y1:y2, x1:x2] ==
           segment_id).astype(np.float32)

        # Пропускаем слишком маленькие сегменты
        if np.sum(segment_mask) < 100:
            continue

        segment_img = preprocessed[y1:y2, x1:x2].copy()
        segment_base_depth = base_depth[y1:y2, x1:x2].copy()

```

```
40          # Оценка условий освещения
41          lighting_params = estimate_lighting(segment_img)
42
43          # Разделение альбедо и затенения
44          albedo, shading = separate_albedo_shading(segment_img,
                lighting_params)
45
46          # Оценка нормалей поверхности
47          normals, confidence_mask = estimate_normals(shading,
                lighting_params)
48
49          # Восстановление деталей
50          segment_details = recover_depth(
51              normals,
52              confidence_mask,
53              iterations=self.iterations // 2,
54              initial_depth=segment_base_depth
55          )
56
57          segment_weight = confidence_mask *
                np.abs(sobel(segment_img, axis=0)) *
                np.abs(sobel(segment_img, axis=1))
58          segment_weight = gaussian_filter(segment_weight,
                sigma=1.0)
59          if np.max(segment_weight) > 0:
60              segment_weight = segment_weight /
                    np.max(segment_weight)
61          detail_depth[y1:y2, x1:x2] += segment_details *
                segment_mask * segment_weight
62          detail_weight[y1:y2, x1:x2] += segment_mask *
                segment_weight
63
64      # Шаг 5: Комбинация базовой карты и деталей
65      detail_weight = np.maximum(detail_weight, 1e-6)
66      detail_depth = detail_depth / detail_weight
67
68      alpha_base = 0.7
69      alpha_map = alpha_base - (detail_weight * 0.4)
70      alpha_map = np.clip(alpha_map, 0.3, 0.9)
71
72      final_depth = alpha_map * base_depth + (1 - alpha_map) *
```

```
        detail_depth
73
74
75      # Формирование результатов
76      results = {
77          'preprocessed': preprocessed,
78          'segments_mask': segments_mask,
79          'depth_map': base_depth,
80          'detail_depth': detail_depth,
81          'detail_weight': detail_weight,
82          'final_depth': final_depth,
83          'bboxes': bboxes,
84      }
85
86      return results
```

В листинге 3.3 представлен код сегментации изображения, позволяющий выделить различные объекты сцены для их дальнейшей раздельной обработки методом Shape From Shading.

Листинг 3.3 – Сегментация изображения

```
 1 import cv2
 2 import numpy as np
 3 from skimage.measure import regionprops
 4 from sklearn.cluster import KMeans
 5
 6 def segmentation(img, n_color_segments=6):
 7     # Преобразование изображения в цветное
 8     if len(img.shape) == 2:
 9         image_for_cluster = np.stack([img] * 3, axis=2)
10     else:
11         image_for_cluster = img.copy()
12
13     pixels = image_for_cluster.reshape(-1, 3)
14
15     # Группировка пикселей по цветам
16     kmeans = KMeans(n_clusters=n_color_segments,
           random_state=42, n_init=10)
17     labels = kmeans.fit_predict(pixels)
18
```

```
19      segmented = labels.reshape(img.shape[:2])
20
21      h, w = segmented.shape[:2]
22      bboxes = {}
23
24      # Цикл по цветовым сегментам
25      for label in range(n_color_segments):
26          # Создание бинарной маски для текущего цвета
27          mask = (segmented == label).astype(np.uint8)
28
29          # Поиск связных компонентов
30          num_labels, labels_img = cv2.connectedComponents(mask)
31
32          for region_id in range(1, num_labels):
33              region_mask = (labels_img ==
                    region_id).astype(np.uint8)
34
35              # Получение прямоугольной ограничивающей рамки
36              props = regionprops(region_mask)
37              if not props:
38                  continue
39
40              y1, x1, y2, x2 = props[0].bbox
41
42              margin = 5
43              y1 = max(0, y1 - margin)
44              y2 = min(h, y2 + margin)
45              x1 = max(0, x1 - margin)
46              x2 = min(w, x2 + margin)
47
48              # Если область слишком маленькая, она пропускается
49              if (y2 - y1) < 20 or (x2 - x1) < 20:
50                  continue
51
52              # Создание уникального идентификатора для этого прямо
                    угольного сегмента
53              segment_id = label * 1000 + region_id
54
55              segmented[y1:y2, x1:x2][region_mask[y1:y2, x1:x2] >
                    0] = segment_id
56
```

```
57              # Сохранение ограничивающей рамки
58              bboxes[segment_id] = (y1, y2, x1, x2)
59
60      return segmented, bboxes
```

Листинг 3.4 представляет реализацию алгоритма оценки параметров освещения сцены, необходимых для корректного применения метода Shape from Shading.

Листинг 3.4 – Оценка освещения

```
1 import cv2
2 import numpy as np
3
4
5 def estimate_lighting(image):
6     # Расчет гистограммы
7     hist = cv2.calcHist([image * 255], [0], None, [256], [0,
          256])
8     hist_normalized = hist / (image.shape[0] * image.shape[1])
9
10    # Расчёт статистики яркости
11    brightness_mean = np.mean(image)
12    brightness_std = np.std(image)
13
14    # Вычисление градиентов
15    grad_x = cv2.Sobel(image, cv2.CV_32F, 1, 0, ksize=5)
16    grad_y = cv2.Sobel(image, cv2.CV_32F, 0, 1, ksize=5)
17    gradient_magnitude = np.sqrt(grad_x ** 2 + grad_y ** 2)
18
19    # Определение области с постоянным освещением
20    smooth_regions = gradient_magnitude <
          np.percentile(gradient_magnitude, 25)
21
22    # Расчёт средних градиентов градиентам
23    avg_grad_x = np.mean(grad_x)
24    avg_grad_y = np.mean(grad_y)
25
26    light_x = -avg_grad_x
27    light_y = -avg_grad_y
28    light_z = 1.0
```

```
29
30      # Оценка вектора направления света
31      light_direction = np.array([light_x, light_y, light_z])
32      norm = np.linalg.norm(light_direction)
33      if norm > 0:
34          light_direction = light_direction / norm
35
36      lighting_params = {
37          'direction': light_direction,
38          'brightness_mean': brightness_mean,
39          'brightness_std': brightness_std,
40          'hist': hist_normalized,
41          'smooth_regions': smooth_regions
42      }
43
44      return lighting_params
```

В листинге 3.5 представлен код разделения альбедо и затенения метода Shape from Shading, позволяющий отделить собственные цвета поверхностей от эффектов освещения.

Листинг 3.5 – Разделение альбедо и затенения

```
1 import numpy as np
2 from scipy.ndimage import gaussian_filter
3
4 def separate_albedo_shading(image, lighting_params):
5     # Усиление деталей
6     log_image = np.log1p(image)
7
8     # Вычисление коэффициента фильтра Гаусса
9     sigma_large = max(image.shape) * 0.08
10    sigma_small = max(image.shape) * 0.02
11
12    # Применение фильтра Гаусса
13    illumination_large = gaussian_filter(log_image,
          sigma=sigma_large)
14    illumination_small = gaussian_filter(log_image,
          sigma=sigma_small)
15
```

```
16      illumination = 0.7 * illumination_large + 0.3 *
            illumination_small
17
18      # Вычитание компоненты освещения
19      log_albedo = log_image - illumination
20
21      # Восстанавление альбедо
22      albedo = np.exp(log_albedo) - 1.0
23
24      albedo = np.clip(albedo, 0.01, 1.0)
25
26      # Нормализация альбедо
27      p_low, p_high = np.percentile(albedo, [2, 98])
28      albedo_norm = (albedo - p_low) / (p_high - p_low + 1e-6)
29      albedo = np.clip(albedo_norm, 0.01, 1.0)
30
31      # Вычисление затенения
32      shading = image / (albedo + 1e-6)
33
34      # Нормализация затенение
35      shading = np.clip(shading, 0.01, 1.0)
36
37      p_low, p_high = np.percentile(shading, [2, 98])
38      shading = (shading - p_low) / (p_high - p_low + 1e-6)
39      shading = np.clip(shading, 0.01, 1.0)
40
41      # Сглаживание затенения
42      shading = gaussian_filter(shading, sigma=1.0)
43
44      return albedo, shading
```

Листинг 3.6 содержит код вычисления нормалей к поверхности на основе полученного разделения альбедо и затенения.

Листинг 3.6 – Оценка нормалей

```
1 import cv2
2 import numpy as np
3 from scipy.ndimage import gaussian_filter
4
5 def estimate_normals(shading, lighting_params):
```

```
6       h, w = shading.shape
7       light_direction = lighting_params['direction']
8
9       normals = np.zeros((h, w, 3), dtype=np.float32)
10
11      # Оценка градиентов
12      grad_x = cv2.Sobel(shading, cv2.CV_32F, 1, 0, ksize=3)
13      grad_y = cv2.Sobel(shading, cv2.CV_32F, 0, 1, ksize=3)
14
15      # Расчет коэффициента масштабирования градиентов
16      brightness_std = lighting_params['brightness_std']
17      alpha = 0.2 * (1.0 / (brightness_std + 0.05))
18
19      # Расчет нормалей
20      normals[:, :, 0] = -alpha * grad_x
21      normals[:, :, 1] = -alpha * grad_y
22      normals[:, :, 2] = 1.0
23
24      # Сглаживание нормалей
25      for c in range(3):
26          normals[:, :, c] = gaussian_filter(normals[:, :, c],
            sigma=0.8)
27
28      # Нормализация
29      norm = np.sqrt(np.sum(normals ** 2, axis=2, keepdims=True))
30      normals = normals / (norm + 1e-10)
31
32      gradient_magnitude = np.sqrt(grad_x ** 2 + grad_y ** 2)
33      max_magnitude = np.max(gradient_magnitude)
34      if max_magnitude > 0:
35          gradient_magnitude = gradient_magnitude / max_magnitude
36
37      edge_correction = 1.0 - gradient_magnitude ** 2
38      edge_correction = np.clip(edge_correction, 0.1, 1.0)
39
40      confidence_mask = gradient_magnitude * edge_correction
41
42      brightness_weight = np.clip(shading * 1.5, 0.3, 1.0)
43      confidence_mask = confidence_mask * brightness_weight
44
45      # Сглаживание маски
```

```
46      confidence_mask = gaussian_filter(confidence_mask, sigma=1.5)
47
48      return normals, confidence_mask
```

Заключительный этап обработки представлен в листинге 3.7 — алгоритм интеграции поля нормалей для получения итоговой карты глубины с высоким уровнем детализации поверхностей.

Листинг 3.7 – Восстановление карты глубин по нормалям

```
1 import cv2
2 import numpy as np
3
4 def recover_depth(normals, confidence_mask, iterations=200,
      initial_depth=None):
5     h, w = normals.shape[:2]
6
7     # Извлечение нормалей
8     nx = normals[:, :, 0]
9     ny = normals[:, :, 1]
10    nz = normals[:, :, 2] + 1e-10
11
12    # Вычисление градиентов
13    p = -nx / nz
14    q = -ny / nz
15
16    # Сглаживание градиентов
17    p_smooth = cv2.bilateralFilter(p, 5, 0.1, 5)
18    q_smooth = cv2.bilateralFilter(q, 5, 0.1, 5)
19
20    # Обновление градиентов
21    p = p_smooth * confidence_mask + p * (1 - confidence_mask)
22    q = q_smooth * confidence_mask + q * (1 - confidence_mask)
23
24    # Инициализация карты глубин
25    if initial_depth is not None:
26        depth = initial_depth.copy()
27    else:
28        depth = np.zeros((h, w), dtype=np.float32)
29
30    # Итеративное уточнение глубины
```

```
31      for iter in range(iterations):
32          depth_x = np.zeros_like(depth)
33          depth_y = np.zeros_like(depth)
34
35          # Вычисление разностей глубины
36          depth_x[:, 1:] = depth[:, 1:] - depth[:, :-1]
37          depth_y[1:, :] = depth[1:, :] - depth[:-1, :]
38
39          # Вычисление ошибок
40          error_x = depth_x - p
41          error_y = depth_y - q
42
43          update = np.zeros_like(depth)
44
45          update[:-1, :] += error_y[:-1, :]
46          update[:, :-1] += error_x[:, :-1]
47          update[1:, :] -= error_y[1:, :]
48          update[:, 1:] -= error_x[:, 1:]
49
50          # Обновление карты глубин
51          update_weight = 0.5 / iterations
52          weighted_update = update * update_weight *
                confidence_mask
53          depth += weighted_update
54
55      depth = cv2.bilateralFilter(depth.astype(np.float32), 9, 75,
            75)
56
57      # Нормализация
58      p_low, p_high = np.percentile(depth, [2, 98])
59      depth = (depth - p_low) / (p_high - p_low + 1e-6)
60      depth = np.clip(depth, 0, 1)
61
62      depth_map = np.power(depth, 0.85)
63
64      depth_map = (depth_map - depth_map.min()) / (depth_map.max()
            - depth_map.min() + 1e-6)
65
66      return depth_map
```

3.3 Описание входных и выходных данных

Входными данными для алгоритма восстановления глубины является путь к существующему в файловой системе изображению в формате, поддерживаемом OpenCV [32]: JPEG, PNG, BMP, TIFF, WebP, PPM, PGM, PBM, SR, RAS.

Результатом работы алгоритма восстановления глубины является нормализованная карта глубин в виде двумерного массива NumPy со значениями в диапазоне [0, 1], где значения, близкие к 0, соответствуют точкам, расположенным ближе к камере, а значения, приближающиеся к 1, указывают на объекты, удалённые от камеры.

Для визуализации результатов используется цветовая схема «plasma» [39], согласно которой ближайшие объекты отображаются в темно-синих или фиолетовых цветах, а дальние — в желто-оранжевых.

Пример визуализации представлен на рисунке 3.1, где показано исходное изображение и предсказанная алгоритмом карта глубин.



Рисунок 3.1 – Пример визуализации карты глубин: слева – входное изображение [41], справа – предсказанная карта глубин

3.4 Тестирование

Для проверки корректности разработанного метода восстановления глубины проведено модульное тестирование по методологии «черного ящика».

Процесс верификации включает следующие последовательные этапы:

— подготовка тестовых изображений, соответствующих каждому классу эквивалентности;

— передача входных данных методу восстановления глубины;

— обработка изображения предложенным методом;

— визуализация полученной карты глубин в цветовой схеме «plasma»;

— сравнение результата с ожидаемым выводом.

Тестирование также включает негативные сценарии с целью подтверждения корректной реакции разработанного метода на нестандартные ситуации и ошибки ввода.

В таблице 3.1 представлены классы эквивалентности модульного тестирования.

Таблица 3.1 – Классы эквивалентности тестирования

Класс	**Общее описание**	**Примеры входных данных**
Позитивные тесты		
А1	Обработка изображений	Пути к существующим изображениям в допустимых форматах
Негативные тесты		
Б1	Обработка отсутствующих файлов	Несуществующие пути к файлам (’/nonexistent.jpg’)
Б2	Обработка неподдерживаемых форматов	Пути к файлам с недопустимыми расширениями (.txt, .doc)
Б3	Обработка поврежденных изображений	Поврежденные файлы изображений с некорректными данными

Результаты проведенного тестирования представлены в таблице 3.2.

Таблица 3.2 – Результаты тестирования

Класс	**Описание входных данных**	**Ожидаемый результат**	**Полученный результат**	**Статус**
А1	Черно-белое изображение в формате JPEG	Успешная загрузка и генерация карты глубины	Карта глубины сгенерирована, сохранена и визуализирована	Пройден
А1	Изображение с эффектом сепии в формате BMP	Успешная загрузка и генерация карты глубины	Карта глубины сгенерирована, сохранена и визуализирована	Пройден
А1	Цветное изображение в формате PNG	Успешная загрузка и генерация карты глубины	Карта глубины сгенерирована, сохранена и визуализирована	Пройден
Б1	Путь к несуществующему файлу (’/nonexistent.jpg’)	Сообщение об ошибке с указанием на отсутствие файла	"Ошибка: файл ’/nonexistent.jpg’ не существует"	Пройден
Б2	Путь к файлу с расширением .txt	Сообщение о неподдерживаемом формате файла	"Ошибка: формат ’.txt’ не поддерживается"	Пройден
Б3	Поврежденный JPEG-файл	Сообщение о невозможности декодирования изображения	"Ошибка при декодировании изображения"	Пройден

Тестирование показало, что разработанный метод корректно обрабатывает изображения различных поддерживаемых форматов, а также адекватно реагирует на некорректные входные данные, предоставляя пользователю информативные сообщения об ошибках.

Вывод

В технологическом разделе выполнена полная программная реализация гибридного метода восстановления глубины из монокулярных изображений.

В качестве средств программной реализации алгоритмов выбран язык Python, предоставляющий достаточный набор специализированных инструментов для обработки изображений, использования моделей машинного обучения и визуализации трехмерных данных.

Разработанный алгоритм успешно прошел тестирование на различных типах изображений (цветных, черно-белых, с эффектом сепии) и продемонстрировал корректную обработку исключительных ситуаций, что подтверждает работоспособность созданного решения.

4 Исследовательский раздел

Цель данного исследования — объективная оценка качества реконструкции глубины посредством разработанного гибридного метода по сравнению с современными подходами, с особым вниманием к устойчивости методов при работе с деградировавшими изображениями. Исследование направлено на определение сильных и слабых сторон разработанного метода, а также его применимости к архивным фотографиям с различными характеристиками.

Основные задачи исследования:

— проанализировать влияние различных типов деградации изображений на качество реконструкции;

— сравнить точность восстановления глубины разработанного метода с современными подходами на эталонных наборах данных;

— определить наиболее подходящие области применения каждого метода.

4.1 Описание входных данных

Ввиду отсутствия эталонных данных о глубине для архивных фотографий, разработан методологический подход с использованием современных датасетов с верифицированными картами глубины и алгоритмов искусственного старения, позволяющий количественно оценивать результаты реконструкции в контролируемых условиях.

Для проведения исследования были выбраны следующие датасеты, обеспечивающих разнообразие тестовых сцен:

1. **NYU Depth v2** — 1449 изображений внутренних помещений с глубиной, полученной с помощью сенсора Kinect [42].

2. **4D Light Field Benchmark** — 24 синтетические сцены с глубиной, полученной с помощью рендеринга 3D-моделей [43].

3. **BIWI Kinect Head Pose** — набор из более 15000 изображений 20 человек, полученных с помощью сенсора Kinect [44].

Из каждого датасета было случайным образом отобрано по 20 изображений, обеспечивая статистическую значимость результатов при сохранении выполнимости тестирования в разумные сроки.

Для имитации состаривания изображений был разработан программный модуль, реализующий следующие эффекты с параметрически задаваемой интенсивностью (от 0 до 1):

— **сепия** — преобразование RGB в тонированное монохромное изображение,

— **виньетирование** — затемнение краев изображения,

— **шум и зернистость** — добавление шума, имитирующего фотопленку,

— **выцветание** — снижение контраста и насыщенности,

— **случайные пятна и царапины** — добавление локальных дефектов.

4.2 Метрики оценки качества

Для объективной оценки качества восстановления глубины используются метрики, которые позволяют количественно оценить, насколько точно модель предсказывает карту глубины, сравнивая предсказанные значения с истинными.

Для корректного сравнения методов, формирующих результаты в разных масштабах, в работе используется предварительная нормализация карт глубин, которая выполняется по формуле:

$$d_{\text{norm}} = \frac{d - d_{\min}}{d_{\max} - d_{\min}}, \tag{4.1}$$

d_{norm} — нормализованное значение глубины, d — исходное значение глубины, $d_{\min}$ — минимальное значение глубины в карте глубин, $d_{\max}$ — максимальное значение глубины в карте глубин.

Для определения среднего отклонения результата используется метрика $RMSE$ — среднеквадратичное отклонение результата (от англ. Root Mean Square Error), которая позволяет оценить, насколько предсказанные значения глубины отличны от истинных значений в среднем по всем пикселям изображения [25; 26; 31]. $RMSE$ вычисляется согласно формуле:

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(d_i^{\text{pred}} - d_i^{\text{gt}})^2}, \tag{4.2}$$

где n – общее количество пикселей изображения, d_i^{pred} – предсказанное значение глубины для i-го пикселя, d_i^{gt} – истинное (эталонное) значение глубины для i-го пикселя.

С учетом нормализации, минимальное значение RMSE — 0, максимальное — 1. Чем ближе значение метрики к 0, тем точнее предсказание.

С целью определения количества предсказанных значений глубины, которые находятся в пределах допустимого отклонения используется пороговая относительная точность (δ_λ) [25; 26; 31]. Эта метрика измеряет долю пикселей, для которых предсказанные и истинные значения глубины удовлетворяют следующему условию:

$$\max\left(\frac{d_i^{\text{pred}}}{d_i^{\text{gt}}}, \frac{d_i^{\text{gt}}}{d_i^{\text{pred}}}\right) = \delta < t_\lambda \tag{4.3}$$

где d_i^{gt} — истинное значение глубины для i-го пикселя, d_i^{pred} — предсказанное значение глубины для i-го пикселя, δ — значение, показывающее отклонение предсказанного значения от истинного, t_λ — пороговое значение, при котором отклонение считается допустимым.

В работе используются пороги $\lambda = 1, 2, 3$, что соответствует отклонению в 25%, 56.25% и 95.3% соответственно.

С учетом нормализации значения метрики δ_λ лежат в диапазоне от 0 до 1. Чем ближе значение метрики к 1, тем большая доля пикселей имеет точное предсказание глубины в пределах соответствующего порога.

4.3 Исследование устойчивости метода к деградации изображений

Исследуется эффективность гибридного метода в зависимости от интенсивности различных эффектов старения, применённых к тестовым изображениям изолированно.

Для каждого эффекта (сепия, виньетирование, шум, выцветание, пятна) применялись различные уровни интенсивности от 0.0 до 1.0 с шагом 0.2.

Гипотеза заключается в том, что различные эффекты старения будут поразному влиять на точность реконструкции глубины: эффекты, изменяющие только цветовую гамму изображения (сепия, выцветание), окажут меньшее влияние на точность, чем эффекты, искажающие структурную информацию

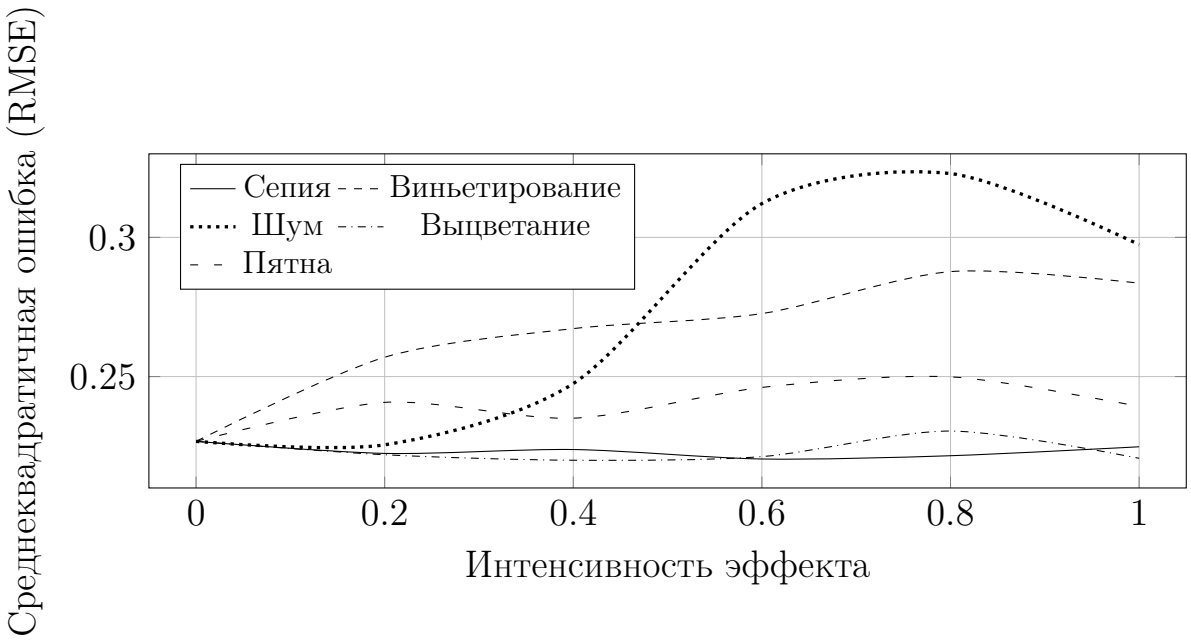


Рисунок 4.1 – Влияние эффектов старения на среднеквадратичную ошибку (RMSE)

изображения (шум, пятна, виньетирование).

На рисунке 4.1 представлены графики зависимости среднеквадратичной ошибки от интенсивности применения различных эффектов старения к тестовым изображениям.

Анализ полученных данных подтверждает выдвинутую гипотезу о том, что эффекты, изменяющие только цветовую гамму изображения (сепия, выцветание), оказывают меньшее влияние на точность реконструкции, чем эффекты, искажающие структурную информацию (шум, виньетирование, пятна).

1. **Сепия и выцветание** оказывают минимальное влияние на точность метода: при максимальной интенсивности эффектов для сепии отклонение RMSE составляет 0.0006 (0.26%), для выцветания — 0.004 (1.6%). Это объясняется тем, что преобразования цветовой гаммы не изменяют структурную информацию изображения, а алгоритмы восстановления глубины опираются преимущественно на структурные, а не цветовые характеристики.

2. **Виньетирование** демонстрирует значительно более выраженное влияние: при интенсивности 0.8 наблюдается максимальное увеличение RMSE на 0.061 (26.8%). Затемнение по краям изображения существенно влияет на восприятие глубины, особенно в периферийных областях,

что подтверждает гипотезу о важности равномерного освещения для структурного анализа изображения.

3. **Шум** показывает наиболее сильное влияние на точность реконструкции: при интенсивности 0.8 RMSE возрастает на 0.096 (42.4%). Шум разрушает текстуры и размывает границы объектов, что критически затрудняет анализ формы из затенения и работу нейросетевых алгоритмов.

4. **Пятна и царапины** демонстрируют умеренное, но устойчивое влияние на точность: максимальное увеличение RMSE на 0.023 (10.2%) наблюдается при интенсивности 0.8. Локальные искажения структуры изображения влияют на алгоритм менее критично, чем равномерный шум, но более существенно, чем изменения цветовой гаммы.

Результаты позволяют определить наиболее эффективные области применения разработанного метода: реконструкция трёхмерной информации из фотографий с преимущественно цветовой деградацией (сепия, выцветание) и умеренными локальными дефектами. В то же время для изображений с сильным шумом или виньетированием необходима более тщательная предварительная обработка.

4.4 Сравнительный анализ методов

В данном исследовании сравнивалась три метода восстановления глубины из монокулярных изображений:

— **восстановление глубины по закраске изображения (SFS)** — метод, основанный на анализе формы из затенения (Shape From Shading), использующий информацию о характере освещения для восстановления формы объектов;

— **MiDaS** — метод восстановления глубины на основе глубоких нейронных сетей, обученный на разнородных данных для повышения обобщающей способности;

— **гибридный метод** — разработанный в рамках исследования подход, адаптивно интегрирующий нейросетевой метод MiDaS и классический метод Shape From Shading.

С целью комплексного исследования влияния деградации изображений на качество восстановления глубины применялась методика контролируемого искусственного старения. Эффекты деградации моделировались с различными интенсивностями: для виньетирования и пятен — в диапазоне от 0 до 0.6, а для сепии и выцветания — от 0 до 1.0, что основано на результатах предыдущего исследования.

Гипотеза заключается в том, что гибридный метод будет объединять преимущества обоих подходов: стабильность MiDaS при работе с деградированными изображениями и высокую детализацию SFS на качественных изображениях. Ожидается, что при увеличении степени деградации изображений гибридный метод будет демонстрировать большую устойчивость, чем чистый SFS, сохраняя при этом лучшую точность восстановления геометрических деталей по сравнению с чистым MiDaS.

В таблице 4.1 представлены результаты сравнения трех методов по метрикам RMSE и δ_λ при различных уровнях деградации изображений.

Таблица 4.1 – Сравнение методов восстановления глубины при различных уровнях деградации изображений

Метод	**Уровень**	**RMSE**	δ_1	δ_2	δ_3
Гибридный	0	0.2854	0.6376	0.8739	0.9760
	1	0.2954	0.6380	0.8666	0.9677
	2	0.2931	0.6849	0.8863	0.9667
	3	0.2918	0.6415	0.8638	0.9565
MiDaS	0	0.2914	0.6425	0.8597	0.9542
	1	0.2947	0.6399	0.8607	0.9542
	2	0.2983	0.6715	0.8735	0.9522
	3	0.2979	0.6438	0.8646	0.9427
SFS	0	0.2867	0.6768	0.8866	0.9790
	1	0.3832	0.3664	0.5749	0.7588
	2	0.3959	0.3749	0.6144	0.7667
	3	0.4170	0.4133	0.6090	0.7622

На рисунках 4.2, 4.3 представлены графики, визуализирующие результаты исследования.

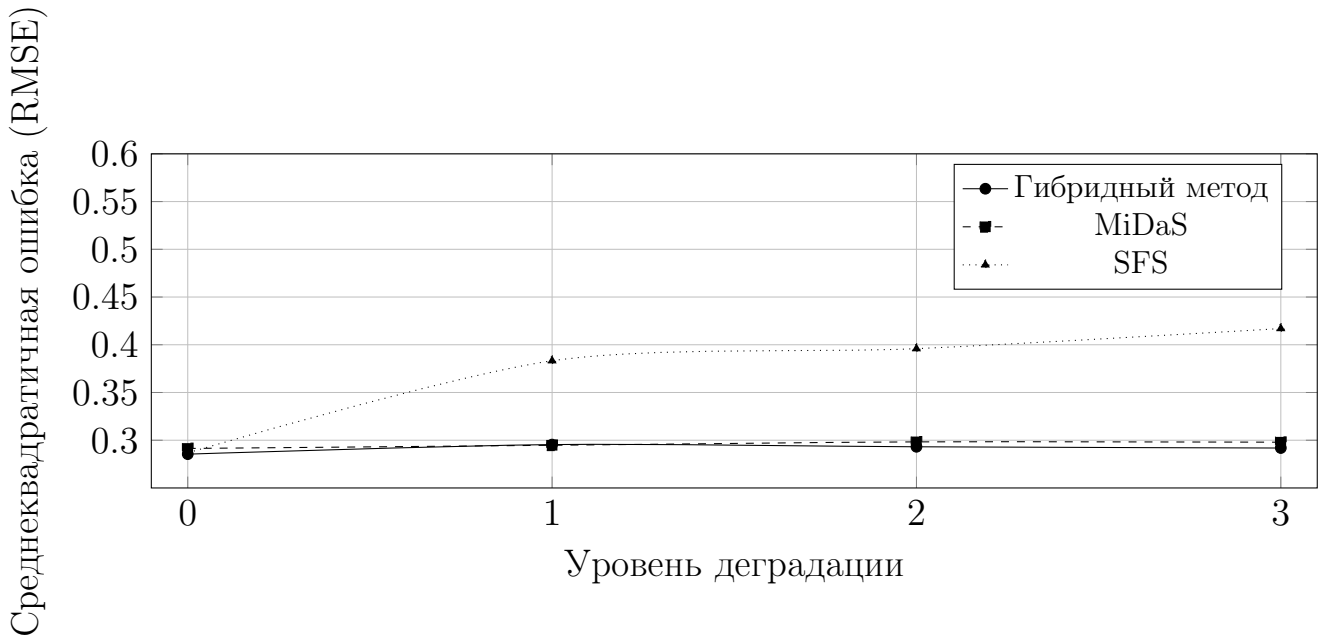


Рисунок 4.2 – Сравнение методов по метрике RMSE при различных уровнях деградации

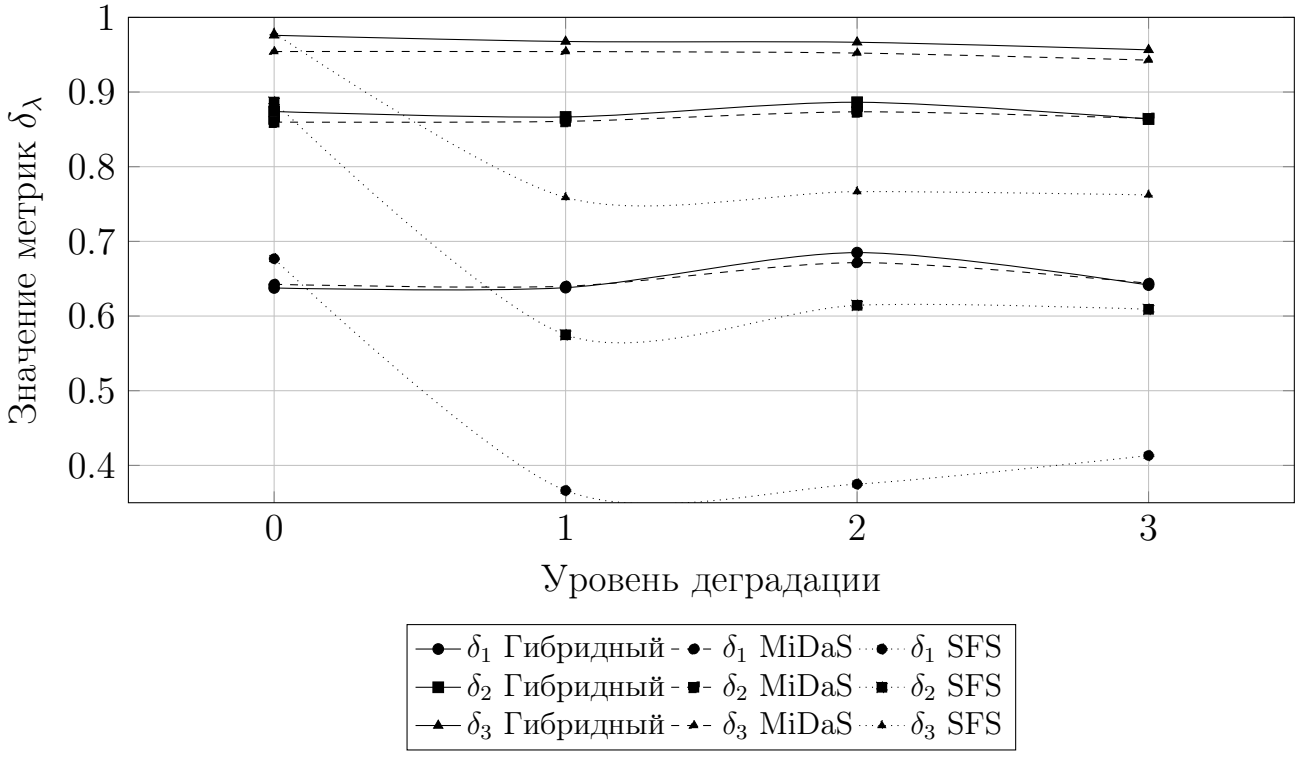


Рисунок 4.3 – Сравнение методов по метрикам δ_λ при различных уровнях деградации

На качественных изображениях (уровень деградации 0) все три метода показывают сопоставимые результаты по метрике RMSE: гибридный метод (0.2854), SFS (0.2867) и MiDaS (0.2914). При этом SFS демонстрирует

наилучшие показатели по метрикам δ_1, δ_2 и δ_3.

При увеличении уровня деградации (уровни 1-3) наблюдается следующая динамика:

— метод SFS критически теряет в точности: RMSE возрастает на 45.4%, а метрики δ_1, δ_2 и δ_3 падают на 39-41%;

— MiDaS демонстрирует стабильные показатели: RMSE практически не изменяется (0.2947-0.2983), как и метрики δ_λ;

— гибридный метод сохраняет устойчивость на уровне MiDaS, но с лучшими абсолютными показателями: RMSE в диапазоне 0.2918-0.2954 и метрики δ_2 и δ_3 в пределах 0.8638-0.8863 и 0.9565-0.9677 соответственно.

Результаты сравнительного анализа трех методов восстановления глубины подтверждают выдвинутую гипотезу: по сравнению с базовыми методами гибридный демонстрирует незначительное повышение точности (около 1-2%), которое стабильно наблюдается на всех уровнях деградации изображений.

Полученные результаты позволяют определить оптимальные области применения каждого из методов.

— **SFS** наиболее эффективен при работе с качественными изображениями без деградации, где обеспечивает высокую детализацию поверхностей. Рекомендуется для применения в контролируемых условиях, например, в промышленных системах контроля качества или при работе с современными цифровыми изображениями высокого разрешения;

— **MiDaS** демонстрирует универсальность и устойчивость к различным типам искажений, что делает его подходящим для обработки разнородных коллекций изображений. Оптимален для задач, где важна стабильность результатов, но высокая детализация не является критичной;

— **Гибридный метод** обеспечивает оптимальный баланс между устойчивостью к деградации и детализацией при восстановлении трёхмерной информации из архивных фотографий. Метод повышает точность реконструкции без необходимости переобучения нейросетевых моделей, что существенно снижает вычислительные затраты.

Вывод

В исследовательском разделе проведено исследование с использованием стандартных датасетов, алгоритмов искусственного старения изображений и объективных метрик оценки для количественной оценки эффективности разработанного гибридного метода восстановления глубины.

Проведено исследование устойчивости гибридного метода к различным эффектам старения изображений, которое подтвердило гипотезу о дифференцированном влиянии различных типов деградации на точность реконструкции глубины:

— эффекты, изменяющие структурную информацию (шум и виньетирование), оказывают наиболее сильное негативное влияние (26.8-42.4% увеличения RMSE);

— эффекты, затрагивающие только цветовую гамму (сепия и выцветание), влияют минимально (0.26-1.6% увеличения RMSE);

— локальные искажения (пятна и царапины) оказывают умеренное влияние (около 10.2% увеличения RMSE).

Результаты позволяют определить наиболее эффективные области применения разработанного метода: реконструкция трёхмерной информации из фотографий с преимущественно цветовой деградацией (сепия, выцветание) и умеренными локальными дефектами. В то же время для изображений с сильным шумом или виньетированием необходима более тщательная предварительная обработка.

Выполнен сравнительный анализ разработанного гибридного метода с базовыми подходами (MiDaS и SFS) при различных уровнях деградации изображений:

— на качественных изображениях все три метода демонстрируют сопоставимые результаты по метрике RMSE;

— при увеличении уровня деградации метод SFS критически теряет в точности (RMSE возрастает на 45.4%);

— MiDaS сохраняет стабильность на всех уровнях деградации;

— гибридный метод демонстрирует устойчивость на уровне MiDaS с улучшенными на 1-2% абсолютными показателями точности.

Полученные результаты позволяют определить оптимальные области применения каждого из методов.

— **SFS** наиболее эффективен при работе с качественными изображениями без деградации, где обеспечивает высокую детализацию поверхностей. Рекомендуется для применения в контролируемых условиях, например, в промышленных системах контроля качества или при работе с современными цифровыми изображениями высокого разрешения;

— **MiDaS** демонстрирует универсальность и устойчивость к различным типам искажений, что делает его подходящим для обработки разнородных коллекций изображений. Оптимален для задач, где важна стабильность результатов, но высокая детализация не является критичной;

— **Гибридный метод** обеспечивает оптимальный баланс между устойчивостью к деградации и детализацией при восстановлении трёхмерной информации из архивных фотографий. Метод повышает точность реконструкции без необходимости переобучения нейросетевых моделей, что существенно снижает вычислительные затраты.

Результаты исследования подтверждают эффективность разработанного гибридного метода, который успешно сочетает в себе устойчивость нейросетевого подхода к деградации изображений с детализирующими возможностями метода Shape from Shading.

Полученные данные позволяют определить оптимальные области применения метода: восстановление трёхмерной информации из архивных фотографий для задач цифровой реставрации и трёхмерной реконструкции исторических объектов, когда доступны только архивные фотоматериалы различного качества, но с минимальным уровнем шумовых искажений. Метод позволяет получить более точные и детализированные карты глубины по сравнению с существующими подходами.

ЗАКЛЮЧЕНИЕ

В аналитической части работы был проведен анализ существующих методов конвертации двумерных изображений в трехмерные представления. Методы были классифицированы по ключевым критериям: способу получения данных, типу исходных изображений, необходимости в дополнительной информации, результатам реконструкции, масштабу сцены и уровню автоматизации.

В ходе исследования были изучены различные подходы к восстановлению 3D-информации, включая методы структурированного освещения, стерео сопоставления, DFD, Shape from Shading, Comfortable Depth Generation и нейросетевые методы, такие как MiDaS.

Проведенный анализ привел к выводу, что оптимальным решением для восстановления глубины из архивных фотографий является гибридный метод, объединяющий преимущества нейросетевого подхода (MiDaS) и классического метода Shape from Shading. Такое решение позволит обеспечить как общую точность восстановления геометрии сцены, так и детализацию отдельных элементов, сохраняя при этом устойчивость к дефектам, характерным для исторических изображений.

Представленная формальная модель задачи и декомпозиция метода на функциональные блоки предобработки, гибридного восстановления и постобработки формируют теоретическую основу для разработки практического решения в следующих разделах работы.

В конструкторском разделе была представлена детальная структура разработанного гибридного метода восстановления трехмерной информации из архивных фотографий. Разработка включает семь основных алгоритмических блоков, последовательное выполнение которых обеспечивает преобразование входного изображения в детализированную карту глубины.

Представленные схемы алгоритмов являются основой для последующей программной реализации метода, которая будет рассмотрена в технологическом разделе работы.

В технологическом разделе выполнена полная программная реализация гибридного метода восстановления глубины из монокулярных изображений.

Для решения поставленной задачи был выбран язык Python с экосистемой специализированных библиотек (OpenCV, PyTorch, NumPy и др.), что обеспечило эффективную работу с изображениями, применение моделей

машинного обучения и визуализацию трехмерных данных.

Разработанный алгоритм успешно прошел тестирование на различных типах изображений (цветных, черно-белых, с эффектом сепии) и продемонстрировал корректную обработку исключительных ситуаций, что подтверждает работоспособность созданного решения.

В исследовательском разделе проведено исследование с использованием стандартных датасетов, алгоритмов искусственного старения изображений и объективных метрик оценки для количественной оценки эффективности разработанного гибридного метода восстановления глубины.

Проведено исследование устойчивости гибридного метода к различным эффектам старения изображений, которое подтвердило гипотезу о дифференцированном влиянии различных типов деградации на точность реконструкции глубины:

— эффекты, изменяющие структурную информацию (шум и виньетирование), оказывают наиболее сильное негативное влияние (26.8-42.4% увеличения RMSE);

— эффекты, затрагивающие только цветовую гамму (сепия и выцветание), влияют минимально (0.26-1.6% увеличения RMSE);

— локальные искажения (пятна и царапины) оказывают умеренное влияние (около 10.2% увеличения RMSE).

Выполнен сравнительный анализ разработанного гибридного метода с базовыми подходами (MiDaS и SFS) при различных уровнях деградации изображений:

— на качественных изображениях все три метода демонстрируют сопоставимые результаты по метрике RMSE;

— при увеличении уровня деградации метод SFS критически теряет в точности (RMSE возрастает на 45.4%);

— MiDaS сохраняет стабильность на всех уровнях деградации;

— гибридный метод демонстрирует устойчивость на уровне MiDaS с улучшенными на 1-2% абсолютными показателями точности.

Результаты исследования подтверждают эффективность разработанного гибридного метода, который успешно сочетает в себе устойчивость нейросетевого подхода к деградации изображений с детализирующими возможностями метода Shape from Shading. Полученные данные позволяют определить оптимальные области применения метода: восстановление трёхмерной информации из архивных фотографий для задач цифровой реставрации и трёхмерной реконструкции исторических объектов, когда доступны только архивные фотоматериалы различного качества. Метод позволяет получить более точные и детализированные карты глубины по сравнению с существующими подходами при работе с деградированными изображениями.

экономическую эффективность или значимость работы; прогнозы и предположения о возможных направлениях развития объекта исследования.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *А. В. Бобков, И. Дай.* Реконструкция поверхности Марса по видеоизображению в задаче навигации робота-марсохода // XLVII Академические чтения по космонавтике 2023. — 2023. — С. 198—201.
2. The diagnostic contribution of CT volumetric rendering techniques in routine practice / S. Perandini [и др.] // Indian Journal of Radiology and Imaging. — 2010. — Т. 20, № 02. — С. 92—97.
3. *Буданцев А.* Объемная реконструкция анатомических структур мозга // Журнал высшей нервной деятельности им. ИП Павлова. — 2009. — Т. 59, № 1. — С. 116—119.
4. *Баландин А.* Векторные сферические гармоники в 3-D векторной томографии // Сибирский журнал вычислительной математики. — 2009. — Т. 12, № 2. — С. 131—143.
5. *Могаричев Ю., Ергина А.* Пещерная церковь скита в Георгиевской балке (Инкерман): опыт составления 3-D реконструкции // Изучение и сохранение древних сакральных пространств в современном мире (к 1365-летию ссылки папы Мартина в Херсонес). — 2020. — С. 46—49.
6. *Корюгин Р.* 3-D моделирование памятников архитектуры города Иркутска с применением ГИС // Интерэкспо Гео-Сибирь. — 2007. — Т. 1, № 1. — С. 242—245.
7. *Hartung Julia Dold P. M., Jahn A., Heizmann M.* Analysis of AI-based single-view 3D reconstruction methods for an industrial application // Sensors. — 2022. — Т. 22, № 17. — С. 6425.
8. *Шубников В. Г., Беляев С. Ю.* Реконструкция пространственной формы стопы человека на основе цифровых изображений // Информатика, телекоммуникации и управление. — 2015. — 6 (234). — С. 45—55.
9. *Isakov A. S.* Features of architecture of factories-kitchens of the south of Russia // Urban construction and architecture. — 2023. — Т. 13, № 2. — С. 133—146.
10. *Kargas Antonios Loumos Georgios V. D.* Using different ways of 3D reconstruction of historical cities for gaming purposes: The case study of Nafplio // Heritage. — 2019. — Т. 2, № 3.

11. Real-Time 3-D Reconstruction for Facilitating the Development of Game-based Virtual Laboratories / Z. Zhang [и др.] // 2015 ASEE Annual Conference & Exposition. — 2015. — С. 26—1305.

12. Rapid 3D reconstruction of indoor environments to generate virtual reality serious games scenarios / Z. Feng [и др.] // arXiv preprint arXiv:1812.01706. — 2018.

13. *Харитонов Л.* Трёхмерная реконструкция объекта по нескольким изображениям как задача компьютерного зрения // Цифровизация и кибербезопасность: современная теория и практика. — 2021. — С. 64—67.

14. *Ham Hanry Wesley Julian H. H.* Computer vision based 3D reconstruction: A review // International Journal of Electrical and Computer Engineering. — 2019. — Т. 9, № 4. — С. 2394.

15. *Fathi Habib Dai Fei L. M.* Automated as-built 3D reconstruction of civil infrastructure using computer vision: Achievements, opportunities, and challenges // Advanced Engineering Informatics. — 2015. — Т. 29, № 2. — С. 149—161.

16. *Хворостов Д., Кутузова А.* 3D реконструкция живописного произведения в теории и методике профессионального образования дизайнера // Ученые записки Орловского государственного университета. Серия: Гуманитарные и социальные науки. — 2019. — 2 (83). — С. 333—335.

17. *Деготинский Н., Луцив В.* Измерение расстояния по единственному дефокусированному снимку //. Т. 16. — Федеральное государственное автономное образовательное учреждение высшего . . ., 2016. — С. 663—669.

18. *Захаров А., Стулов Н., Самсонова Н.* Описание трехмерных форм на основе контурного представления // Алгоритмы, методы и системы обработки данных. — 2011. — № 3. — С. 3—3.

19. *Захаров А. А., Тужилкин А. Ю.* Трехмерная реконструкция визуальной обстановки по видеоизображениям на основе вероятностного подхода // Радиотехнические и телекоммуникационные системы. — 2014. — 2 (14). — С. 45—49.

20. *Щекин С. Б.* Восстановление формы трехмерных объектов методами структурированного освещения //. — Федеральное государственное автономное образовательное учреждение высшего ..., 2007. — С. 302—308.

21. *Никитина М. Г.*, *Кошелева Н. Н.* Вклад в современную науку основоположника операционного и векторного исчисления Оливера Хэвисайда. — 2015.

22. *Волкова Т.*, *Афанасьева Ю.* Минимальные остовные деревья // Современное научное знание: теория, методология, практика. — 2018. — С. 76—80.

23. *Cheng C.-C.*, *Li C.-T.*, *Chen L.-G.* A 2D-to-3D conversion system using edge information // 2010 Digest of Technical Papers International Conference on Consumer Electronics (ICCE). — IEEE. 2010. — С. 377—378.

24. *Кадяева И.* Построение минимального остовного дерева с помощью алгоритма Прима // Информационные технологии и прикладная математика. — 2019. — С. 79—82.

25. *Шестопалов Р. П.*, *Заславский М. М.*, *Лисс А. А.* Сравнительный анализ моделей искусственного интеллекта для 3D-реконструкции объектов реального мира // Известия Тульского государственного университета. Технические науки. — 2024. — № 5. — С. 267—273.

26. *Истомин В. И.*, *Привалов А. Н.* К вопросу применимости методов монокулярной оценки глубины для 3D-реконструкции геометрии документов // Известия Тульского государственного университета. Технические науки. — 2024. — № 9. — С. 401—405.

27. Depth Anything: Unleashing the Power of Large-Scale Unlabeled Data / L. Yang [и др.]. — 06.2024.

28. Towards robust monocular depth estimation: Mixing datasets for zero-shot cross-dataset transfer / K. Lasinger [и др.] // arXiv preprint arXiv:1907.01341. — 2019.

29. *Stanowski K.* Stability and instability of perceived shape from shading : дис. ... канд. / Stanowski Kosma. — 2024.

30. Photometric-Constrained Reconstruction of Lunar Landing Site Topography Using Orbiter and Descent Images : тех. отч. / X. Xie [и др.] ; Copernicus Meetings. — 2025.

31. Review of monocular depth estimation methods / Z. Zhang [и др.] // Journal of Electronic Imaging. — 2025. — Т. 34, № 2. — С. 020901—020901.

32. *OpenCV C. E. D.* OpenCV - Open Computer Vision Library. — URL: https://opencv.org/ ; Электронный ресурс. Дата обращения: 22.05.2025.

33. scikit-image: image processing in Python / S. van der Walt [и др.] // PeerJ. — 2014. — Июнь. — Т. 2. — e453. — ISSN 2167-8359. — DOI: 10.7717/peerj.453. — URL: https://doi.org/10.7717/peerj.453.

34. *Кларк А. и. д.* Pillow: дружественная альтернатива библиотеке PIL. — 2023. — URL: https://pillow.readthedocs.io ; Электронный ресурс. Дата обращения: 22.05.2025.

35. *Пашке А. и. д.* PyTorch. — 2019. — URL: https://pytorch.org/ ; Электронный ресурс. Дата обращения: 22.05.2025.

36. Scikit-learn: Machine Learning in Python / F. Pedregosa [и др.] // Journal of Machine Learning Research. — 2011. — Т. 12. — С. 2825—2830.

37. Array programming with NumPy / C. R. Harris [и др.]. — 09.2020. — DOI: 10.1038/s41586-020-2649-2. — URL: https://doi.org/10.1038/s41586-020-2649-2.

38. SciPy 1.0: Fundamental Algorithms for Scientific Computing in Python / P. Virtanen [и др.]. — 2020. — DOI: 10.1038/s41592-019-0686-2.

39. *Hunter J. D.* Matplotlib: A 2D graphics environment. — 2007. — DOI: 10.1109/MCSE.2007.55.

40. *Zhou Q.-Y.*, *Park J.*, *Koltun V.* Open3D: A Modern Library for 3D Data Processing. — 2018.

41. История МГТУ им. Г.И. Носова в фотографиях. — 2025. — URL: https://vk.com/album-118300359_302316543 ; Электронный ресурс. Дата обращения: 22.05.2025.

42. NYU Depth Dataset V2: набор данных для сегментации и оценки глубины изображений в помещении / N. Silberman [и др.]. — 2012. — URL: https://cs.nyu.edu/~silberman/datasets/nyu_depth_v2.html ; Электронный ресурс. Дата обращения: 22.05.2025.

43. A dataset and evaluation methodology for depth estimation on 4D light fields / K. Honauer [и др.] // Computer Vision–ACCV 2016: 13th Asian Conference on Computer Vision, Taipei, Taiwan, November 20-24, 2016, Revised Selected Papers, Part III 13. — Springer. 2017. — С. 19—34.

44. Random Forests for Real Time 3D Face Analysis / G. Fanelli [и др.] // Int. J. Comput. Vision. — 2013. — Февр. — Т. 101, № 3. — С. 437—458.

ПРИЛОЖЕНИЕ А

Презентация к выпускной квалификационной работе содержит 11 слайдов.